รายงานการวิเคราะห์ข้อมูลเพื่อพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วน

(Estimation of Obesity Levels Based on Eating Habits and Physical Condition)

จัดทำโดย

116610906074-7 นายวิศวะ ช้างแก้ว

116610906016-8 นายธนนันธ์ ใจกาวิน

116610906024-2 นางสาววรารัตน์ พิริยะอำรุง

เสนอ

ผู้ช่วยศาสตราจารย์ ดร.วิภารัตน์ บุษยาตรัส

โครงงานฉบับนี้เป็นส่วนนึงของรายวิชา การวิเคราะห์ข้อมูลขนาดใหญ่และการทำเหมืองข้อมูล

สาขาวิชาเทคโนโลยีสารสนเทศและการสื่อสารดิจิทัล

คณะวิทยาศาสตร์และเทคโนโลยีมหาวิทยาลัยเทคโนโลยีราชมงคลธัญบุรี

ปีการศึกษา 2568

บทคัดย่อ

โครงงานวิจัยนี้มีวัตถุประสงค์เพื่อศึกษาและวิเคราะห์ปัจจัยที่มีอิทธิพลต่อระดับภาวะน้ำหนักเกินและโรคอ้วน โดยใช้เทคนิคการวิเคราะห์ข้อมูลและปัญญาประดิษฐ์เพื่อจำแนกกลุ่มเสี่ยงและพยากรณ์ค่าสรีระเชิงปริมาณ ปัญหาโรคอ้วนถือเป็นวิกฤตการณ์ด้านสาธารณสุขที่ส่งผลให้เกิดโรคไม่ติดต่อเรื้อรัง (NCDs) และภาระค่าใช้จ่ายในการรักษาที่สูงขึ้น การวิจัยนี้จึงมุ่งเน้นการเปรียบเทียบประสิทธิภาพของอัลกอริทึม Machine Learning 3 รูปแบบ ได้แก่ Deep Learning, Random Forest และ Decision Tree เพื่อค้นหาแบบจำลองที่เหมาะสมที่สุดในการระบุระดับความรุนแรงของภาวะร่างกายทั้ง 7 ระดับ จากพฤติกรรมการใช้ชีวิตและพันธุกรรมของประชากรในแถบละตินอเมริกาจำนวน 2,111 รายการ

กระบวนการดำเนินงานเริ่มต้นจากการเตรียมข้อมูลอย่างละเอียด (Data Preprocessing) ทั้งการจัดการข้อมูลซ้ำ การแปลงตัวแปรหมวดหมู่ให้เป็นตัวเลข และการปรับมาตรฐานข้อมูล (Standardization) เพื่อลดอคติของแบบจำลอง จากนั้นจึงนำชุดข้อมูลเข้าสู่ระบบ Auto Model ใน Altair AI Studio เพื่อทดสอบประสิทธิภาพใน 2 ภารกิจหลัก ได้แก่ การวิเคราะห์แบบจำแนกประเภท (Classification) เพื่อทำนายระดับความอ้วน เพศ และประวัติครอบครัว และการวิเคราะห์แบบถดถอย (Regression) เพื่อพยากรณ์ค่าต่อเนื่อง ได้แก่ อายุ น้ำหนัก และส่วนสูง โดยใช้เกณฑ์ความคลาดเคลื่อนสัมพัทธ์ (Relative Error) และความแม่นยำ (Accuracy) เป็นดัชนีชี้วัดหลักในการเปรียบเทียบขีดความสามารถของแต่ละแบบจำลอง

ผลการวิจัยพบว่าแบบจำลอง Decision Tree เป็นอัลกอริทึมที่ทรงประสิทธิภาพที่สุดในภาพรวม โดยเฉพาะในงาน Regression ที่มีค่าความคลาดเคลื่อนต่ำที่สุดเพียง 1.4% ในงานพยากรณ์ส่วนสูง และ 2.6% ในงานพยากรณ์น้ำหนักตัว อีกทั้งยังประมวลผลได้รวดเร็วที่สุดในระดับมิลลิวินาที สำหรับงาน Classification พบว่า Decision Tree ให้ความแม่นยำสูงสุดในการทำนายระดับความอ้วนที่ 83.4% ในขณะที่ Deep Learning แสดงศักยภาพโดดเด่นในการจำแนกเพศด้วยความแม่นยำ 90.1% สรุปได้ว่าการเลือกใช้แบบจำลองต้องพิจารณาสมดุลระหว่างความแม่นยำเชิงสถิติและความเร็วในการประมวลผล ซึ่งผลลัพธ์นี้สามารถนำไปต่อยอดเป็นระบบประเมินความเสี่ยงสุขภาพส่วนบุคคลเพื่อการเฝ้าระวังโรคอ้วนเชิงรุกได้อย่างมีประสิทธิภาพ

คำนำ

รายงานฉบับนี้เป็นส่วนหนึ่งของวิชา การวิเคราะห์ข้อมูลขนาดใหญ่และการทำเหมืองข้อมูล โดยมีวัตถุประสงค์หลักเพื่อศึกษาและประยุกต์ใช้เทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence) และการเรียนรู้ของเครื่อง (Machine Learning) ในการวิเคราะห์และพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วน ซึ่งถือเป็นปัญหาสาธารณสุขที่สำคัญในระดับโลก ข้อมูลที่นำมาศึกษาประกอบด้วยพฤติกรรมการบริโภคอาหาร สภาพทางร่างกาย และปัจจัยทางพันธุกรรม ซึ่งเป็นตัวแปรสำคัญที่ส่งผลต่อสุขภาพและคุณภาพชีวิตของประชากรในยุคปัจจุบัน

เนื้อหาในรายงานฉบับนี้ครอบคลุมตั้งแต่ขั้นตอนการเตรียมข้อมูล (Data Preprocessing) การจัดระเบียบคุณลักษณะของข้อมูล (Data Dictionary) ไปจนถึงการเปรียบเทียบประสิทธิภาพของอัลกอริทึม 3 รูปแบบหลัก ได้แก่ Deep Learning, Random Forest และ Decision Tree ผ่านโปรแกรม Altair AI Studio เพื่อค้นหาแบบจำลองที่แม่นยำที่สุดสำหรับการจำแนกประเภทความเสี่ยงและการพยากรณ์ค่าทางสรีระเชิงปริมาณ ผลลัพธ์ที่ได้จากการศึกษาครั้งนี้ไม่เพียงแต่แสดงให้เห็นถึงขีดความสามารถของเทคโนโลยีในการวิเคราะห์ข้อมูลสุขภาพ แต่ยังสามารถนำไปต่อยอดเพื่อเป็นแนวทางในการเฝ้าระวังและป้องกันโรคไม่ติดต่อเรื้อรัง (NCDs) ได้อย่างมีประสิทธิภาพ

ผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อผู้ที่สนใจศึกษางานด้านวิทยาการข้อมูล (Data Science) และการประยุกต์ใช้ Machine Learning ในงานด้านการแพทย์และสาธารณสุข หากมีข้อผิดพลาดประการใด ผู้จัดทำขอน้อมรับคำติชมเพื่อนำไปปรับปรุงและพัฒนาผลงานในโอกาสต่อไป

จัดทำโดย

วิศวะ ช้างแก้ว

ธนนันธ์ ใจกาวิน

วรารัตน์ พิริยะอำรุง

สารบัญ

หัวข้อ	หน้า
บทคัดย่อ	ก
คำนำ	ข
บทที่ 1 บทนำ	1
1.1 ที่มาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์ของโครงงาน	2
1.3 ขอบเขตของโครงงาน	3
1.3.1 ขอบเขตเชิงเนื้อหา	3
1.3.2 ขอบเขตเชิงเทคนิค	3
1.4 เครื่องมือที่ใช้ในการดำเนินงาน	4
1.5 ประโยชน์ที่คาดว่าจะได้รับ	4
บทที่ 2 ข้อมูลและการเตรียมข้อมูล	5
2.1 การเตรียมข้อมูลและความหมายของข้อมูล (Data Preparation and Dictionary)	5
2.1.1 ความหมายของข้อมูล (Data Dictionary)	5
2.2 ขั้นตอนการเตรียมข้อมูล (Data Preprocessing)	8
2.1.2.1 การจัดการค่าสูญหาย (Missing Values)	8
2.1.2.2 การตรวจสอบข้อมูลซ้ำ (Duplicate Data)	8
2.1.2.3 การแปลงข้อมูลหมวดหมู่ (Categorical Encoding)	8
2.1.2.4 การปรับมาตรฐานข้อมูล (Feature Scaling)	9
บทที่ 3 วิธีการดำเนินงานและโมเดลที่ใช้ในการวิเคราะห์	10
3.1 วิธีการดำเนินงานและขั้นตอนการเตรียมระบบ (System Setup)	10
3.1.1 วิธีการนำเข้าข้อมูล (Data Ingestion)	10
3.1.2 กระบวนการวิเคราะห์และทดสอบแบบจำลองอัตโนมัติ (Automated Modeling and Testing Workflow)	10

3.1.2.1 การวิเคราะห์แบบจำแนกประเภท (Classification Task) 15

3.1.2.2 การวิเคราะห์แบบถดถอย (Regression Task) 19

3.2 โมเดลที่ใช้ในการวิเคราะห์ (Modeling) 23

3.2.1 การวิเคราะห์แบบจำแนกประเภท (Classification Task) 24

3.2.1.1 ตัวแปรเป้าหมายที่ใช้ทำนาย (Classification Targets) 25

3.2.1.2 Deep Learning (ANN) 25

3.2.1.3 Random Forest Classifier 27

3.2.1.4 Decision Tree Classifier 28

3.2.2 การวิเคราะห์แบบถดถอย (Regression Task) 29

3.2.2.1 ตัวแปรเป้าหมายที่ใช้ทำนาย (Regression Targets) 30

3.2.2.2 Decision Tree Regressor 30

3.2.2.3 Random Forest Regressor 32

3.2.2.4 Deep Learning (Regression Mode) 33

บทที่ 4 ผลการวิจัย 35

4.1 ผลการวิจัยและวิเคราะห์ข้อมูล (Results and Discussion) 35

4.1.1 การวิเคราะห์แบบจำแนกประเภท (Classification) 35

4.1.1.1 การพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วน (NObeyesdad) 35

4.1.1.2 การพยากรณ์ประวัติสมาชิกในครอบครัวที่มีภาวะน้ำหนักเกิน 41

4.1.1.3 การพยากรณ์เพศของผู้ทำแบบทดสอบ (Gender) 47

4.1.2 สรุปโมเดลที่เหมาะสมที่สุดของการวิเคราะห์แบบจำแนกประเภท 53

4.1.3 การวิเคราะห์แบบถดถอย (Regression) 54

4.1.3.1 การพยากรณ์อายุ (Age) 54

4.1.3.2 การพยากรณ์น้ำหนัก (Weight) 60

4.1.3.3 การพยากรณ์ส่วนสูง (Height) 66

4.1.4 สรุปโมเดลที่เหมาะสมที่สุดของการวิเคราะห์แบบถดถอย 72

4.2 บทสรุปและอภิปรายผลการเปรียบเทียบประสิทธิภาพระดับมหภาพ 73

บทที่ 5 สรุปผลการวิจัยและข้อเสนอแนะ 74

5.1 สรุปผลการดำเนินงานและข้ออภิปราย 74

5.2 แนวทางการนำโมเดลไปใช้ประโยชน์ในเชิงปฏิบัติ 75

5.3 ข้อเสนอแนะสำหรับการศึกษาในอนาคต 76

บรรณานุกรม 77

สารบัญรูปภาพ

ภาพที่ 2.1 ตัวอย่างฐานข้อมูลที่ใช้พยากรณ์ 7

ภาพที่ 3.1 การเริ่มต้นเข้าสู่ฟังก์ชัน Auto Model บนหน้าต่างต้อนรับของโปรแกรม Altair AI Studio 10

ภาพที่ 3.2 การเลือกแหล่งที่มาของข้อมูลจากหน่วยความจำภายในเครื่องคอมพิวเตอร์ (My Computer) 11

ภาพที่ 3.3 การเลือกไฟล์ชุดข้อมูลเป้าหมายในรูปแบบนามสกุล .csv 11

ภาพที่ 3.4 การตรวจสอบความถูกต้องของโครงสร้างไฟล์ข้อมูล (Data Format) และการตั้งค่าตัวแบ่งคอลัมน์ 12

ภาพที่ 3.5 การตรวจสอบและกำหนดประเภทของข้อมูล (Data Types) ให้เหมาะสมกับแต่ละคุณลักษณะ 13

ภาพที่ 3.6 การเลือกตำแหน่งจัดเก็บชุดข้อมูลภายใน Local Repository และการตั้งชื่อไฟล์ 13

ภาพที่ 3.7 หน้าต่างแสดงผลลัพธ์ (Results View) หลังการนำเข้าข้อมูลสำเร็จ 14

ภาพที่ 3.8 การเลือกภารกิจการพยากรณ์ (Predict) เพื่อเข้าสู่กระบวนการ Auto Model 15

ภาพที่ 3.9 การเลือกตัวแปรเป้าหมาย (Target) และการตรวจสอบกราฟการกระจายตัวของระดับภาวะน้ำหนักตัว 16

ภาพที่ 3.10 การวิเคราะห์คุณภาพของปัจจัยนำเข้า (Inputs) เพื่อคัดกรองตัวแปรที่มีความสัมพันธ์สูงสุด 16

ภาพที่ 3.11 การคัดเลือกและกำหนดพารามิเตอร์สำหรับโมเดล Deep Learning, Decision Tree และ Random Forest 17

ภาพที่ 3.12 ตารางสรุปผลลัพธ์ภาพรวม (Overview) เปรียบเทียบค่าความผิดพลาดและเวลาที่ใช้ 18

ภาพที่ 3.13 การใช้กราฟเส้นโค้ง ROC และ Lift Chart เพื่อประเมินประสิทธิภาพความน่าเชื่อถือ 19

ภาพที่ 3.14 การกำหนดเป้าหมายการพยากรณ์เชิงปริมาณในโหมดการวิเคราะห์แบบถดถอย 20

ภาพที่ 3.15 การตรวจสอบกราฟฮิสโตแกรมแสดงการกระจายตัวของข้อมูลตัวเลขต่อเนื่อง 20

ภาพที่ 3.16 การตรวจสอบค่าสหสัมพันธ์ (Correlation) ระหว่างตัวแปรต้นกับตัวแปรเป้าหมายเชิงตัวเลข 21

ภาพที่ 3.17 การเลือกใช้อัลกอริทึมสำหรับงาน Regression เพื่อเปรียบเทียบประสิทธิภาพในการประมาณค่า 22

ภาพที่ 3.18 การแสดงค่า Relative Error เพื่อเปรียบเทียบเปอร์เซ็นต์ความคลาดเคลื่อนระหว่างโมเดลต่างๆ 22

ภาพที่ 3.21 การวิเคราะห์ค่า RMSE (Root Mean Squared Error) เพื่อวัดระยะห่างระหว่างค่าพยากรณ์และค่าจริง 23

ภาพที่ 4.1 การกำหนดตัวแปรเป้าหมายและตรวจสอบการกระจายตัวของข้อมูลพยากรณ์ระดับความอ้วน 36

ภาพที่ 4.2 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของการพยากรณ์ระดับความอ้วน 38

ภาพที่ 4.3 ตาราง Performance แสดงค่า Accuracy และ SD เพื่อยืนยันเสถียรภาพของโมเดล Decision Tree (NObeyesdad) 39

ภาพที่ 4.4 ตาราง Performance แสดงค่า Accuracy และ SD เพื่อยืนยันเสถียรภาพของโมเดล Random Forest (NObeyesdad) 40

ภาพที่ 4.5 ตาราง Performance แสดงค่า Accuracy และ SD เพื่อยืนยันเสถียรภาพของโมเดล Deep Learning (NObeyesdad) 41

ภาพที่ 4.6 การกำหนดตัวแปรเป้าหมายและตรวจสอบการกระจายตัวของข้อมูลพยากรณ์ประวัติครอบครัว 42

ภาพที่ 4.7 ตารางเปรียบเทียบค่าความผิดพลาดและเวลาประมวลผลของการพยากรณ์ประวัติครอบครัว 44

ภาพที่ 4.8 กราฟ ROC Comparison แสดงขีดความสามารถในการแยกแยะข้อมูลของการพยากรณ์ประวัติครอบครัว 44

ภาพที่ 4.9 ตาราง Performance ยืนยันคุณภาพการพยากรณ์ประวัติครอบครัวของโมเดล Decision Tree 45

ภาพที่ 4.10 ตาราง Performance ยืนยันคุณภาพการพยากรณ์ประวัติครอบครัวของโมเดล Random Forest 46

ภาพที่ 4.11 ตาราง Performance ยืนยันคุณภาพการพยากรณ์ประวัติครอบครัวของโมเดล Deep Learning 47

ภาพที่ 4.12 การกำหนดตัวแปรเป้าหมายและตรวจสอบการกระจายตัวของข้อมูลพยากรณ์เพศ 48

ภาพที่ 4.13 ตารางเปรียบเทียบค่าความผิดพลาดและเวลาประมวลผลของการพยากรณ์เพศ 50

ภาพที่ 4.14 กราฟ ROC Comparison แสดงขีดความสามารถในการแยกแยะข้อมูลของการพยากรณ์เพศ 50

ภาพที่ 4.15 ตาราง Performance ยืนยันคุณภาพการพยากรณ์เพศของโมเดล Decision Tree 51

ภาพที่ 4.16 ตาราง Performance ยืนยันคุณภาพการพยากรณ์เพศของโมเดล Random Forest 52

ภาพที่ 4.17 ตาราง Performance ยืนยันคุณภาพการพยากรณ์เพศของโมเดล Deep Learning 53

ภาพที่ 4.18 การกำหนดตัวแปรเป้าหมายและตรวจสอบการกระจายตัวของข้อมูลพยากรณ์อายุ 55

ภาพที่ 4.19 ตารางเปรียบเทียบค่าความผิดพลาดและเวลาประมวลผลของการพยากรณ์อายุ 57

ภาพที่ 4.20 ตาราง Performance ยืนยันคุณภาพการพยากรณ์อายุของโมเดล Decision Tree 58

ภาพที่ 4.21 ตาราง Performance ยืนยันคุณภาพการพยากรณ์อายุของโมเดล Random Forest 59

ภาพที่ 4.22 ตาราง Performance ยืนยันคุณภาพการพยากรณ์อายุของโมเดล Deep Learning 60

ภาพที่ 4.23 การกำหนดตัวแปรเป้าหมายและตรวจสอบการกระจายตัวของข้อมูลพยากรณ์น้ำหนัก 61

ภาพที่ 4.24 ตารางเปรียบเทียบค่าความผิดพลาดและเวลาประมวลผลของการพยากรณ์น้ำหนัก 63

ภาพที่ 4.25 ตาราง Performance ยืนยันคุณภาพการพยากรณ์น้ำหนักของโมเดล Decision Tree 64

ภาพที่ 4.26 ตาราง Performance ยืนยันคุณภาพการพยากรณ์น้ำหนักของโมเดล Random Forest 65

ภาพที่ 4.27 ตาราง Performance ยืนยันคุณภาพการพยากรณ์น้ำหนักของโมเดล Deep Learning **66**

ภาพที่ 4.28 การกำหนดตัวแปรเป้าหมายและตรวจสอบการกระจายตัวของข้อมูลพยากรณ์ส่วนสูง 67

ภาพที่ 4.29 ตารางเปรียบเทียบค่าความผิดพลาดและเวลาประมวลผลของการพยากรณ์ส่วนสูง 69

ภาพที่ 4.30 ตาราง Performance ยืนยันคุณภาพการพยากรณ์ส่วนสูงของโมเดล Decision Tree 70

ภาพที่ 4.31 ตาราง Performance ยืนยันคุณภาพการพยากรณ์ส่วนสูงของโมเดล Random Forest 71

ภาพที่ 4.32 ตาราง Performance ยืนยันคุณภาพการพยากรณ์ส่วนสูงของโมเดล Deep Learning 72

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญของปัญหา

ในทศวรรษปัจจุบัน วิกฤตการณ์ด้านสาธารณสุขที่ทวีความรุนแรงและส่งผลกระทบในวงกว้างระดับโลกคือปัญหาภาวะน้ำหนักเกิน (Overweight) และโรคอ้วน (Obesity) ซึ่งไม่ได้เป็นเพียงปัญหารูปลักษณ์ภายนอก แต่เป็นต้นเหตุสำคัญของกลุ่มโรคไม่ติดต่อเรื้อรัง (Non-Communicable Diseases: NCDs) เช่น โรคเบาหวานประเภทที่ 2 โรคความดันโลหิตสูง โรคหัวใจและหลอดเลือด รวมถึงผลกระทบต่อสุขภาพจิต ภาวะเหล่านี้เกิดจากปัจจัยพฤติกรรมการใช้ชีวิตที่เปลี่ยนแปลงไปอย่างรวดเร็วตามบริบทของสังคมเมือง ทั้งการบริโภคอาหารที่มีพลังงานและแคลอรีสูงเกินความจำเป็น การมีกิจกรรมทางกายที่ลดลงจากการทำงานในออฟฟิศ และพฤติกรรมการใช้เทคโนโลยีที่ทำให้การเคลื่อนไหวร่างกายลดน้อยลง ปัญหานี้สร้างภาระค่าใช้จ่ายมหาศาลให้กับระบบสาธารณสุขทั่วโลก รวมถึงประเทศในแถบละตินอเมริกา เช่น เม็กซิโก เปรู และโคลอมเบีย ซึ่งเป็นกลุ่มประชากรหลักที่นำมาศึกษาในงานวิจัยนี้

ความซับซ้อนของโรคอ้วนนั้นไม่ได้เกิดจากปริมาณการบริโภคอาหารเพียงอย่างเดียว แต่ยังมีความสัมพันธ์เชิงลึกที่เชื่อมโยงกับปัจจัยทางพันธุกรรม (Family History) พฤติกรรมการดื่มน้ำ การสูบบุหรี่ ระยะเวลาการใช้หน้าจออุปกรณ์เทคโนโลยี และรูปแบบการเดินทางในชีวิตประจำวัน ปัจจัยเหล่านี้มีความสัมพันธ์แบบไม่เป็นเส้นตรง (Non-linear) และมีมิติทับซ้อนกันสูง ทำให้การประเมินความเสี่ยงด้วยวิธีการคำนวณแบบเดิมอาจไม่เพียงพอและขาดความแม่นยำในการจำแนกกลุ่มเสี่ยงที่มีความแตกต่างกันถึง 7 ระดับ ตั้งแต่น้ำหนักน้อยกว่าเกณฑ์ไปจนถึงโรคอ้วนระดับรุนแรงสูงสุด

ด้วยเหตุนี้ การนำเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence) และเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) มาประยุกต์ใช้ในการวิเคราะห์ข้อมูลเชิงลึกจึงมีความสำคัญอย่างยิ่ง โดยเฉพาะการเปรียบเทียบขีดความสามารถของอัลกอริทึมที่มีโครงสร้างต่างกัน เช่น โครงข่ายประสาทเทียมระดับลึก (Deep Learning), แบบจำลองแบบกลุ่มต้นไม้ (Random Forest) และต้นไม้ตัดสินใจ (Decision Tree) เพื่อค้นหาแบบจำลองที่ทรงประสิทธิภาพที่สุด ทั้งในด้านการจำแนกประเภท

(Classification) และการพยากรณ์ค่าทางสรีระเชิงตัวเลข (Regression) ซึ่งผลลัพธ์ที่ได้จะช่วยให้บุคลากรทางการแพทย์สามารถระบุกลุ่มเสี่ยงและกำหนดแนวทางการปรับเปลี่ยนพฤติกรรมได้อย่างตรงจุด ลดอัตราการเจ็บป่วย และส่งเสริมสุขภาวะที่ดีขึ้นในระดับประชากรอย่างยั่งยืน

1.2 วัตถุประสงค์ของโครงงาน

1.2.1 เพื่อวิเคราะห์และระบุปัจจัยสำคัญ (Feature Importance): มุ่งเน้นการสกัดและค้นหาตัวแปรที่มีอิทธิพลสูงที่สุดจากทั้ง 17 คุณลักษณะ เพื่อทำความเข้าใจว่าพฤติกรรมหรือปัจจัยใดที่ส่งผลต่อการเปลี่ยนแปลงของระดับภาวะน้ำหนักเกินและโรคอ้วนอย่างมีนัยสำคัญ

1.2.2 เพื่อสร้างและเปรียบเทียบประสิทธิภาพของแบบจำลอง Machine Learning: พัฒนาแบบจำลอง 3 รูปแบบหลัก ได้แก่ Deep Learning, Random Forest และ Decision Tree เพื่อประเมินขีดความสามารถในการจำแนกประเภทระดับความอ้วนทั้ง 7 ระดับ (Multi-class Classification) รวมถึงการจำแนกเพศและปัจจัยทางพันธุกรรม

1.2.3 เพื่อพยากรณ์ค่าสรีระเชิงปริมาณ (Regression Task): มุ่งเป้าในการทำนายค่าตัวเลขต่อเนื่อง ได้แก่ อายุ น้ำหนัก และส่วนสูง เพื่อศึกษาความคลาดเคลื่อนระหว่างค่าพยากรณ์และค่าจริง โดยใช้เกณฑ์ความคลาดเคลื่อนสัมพัทธ์ (Relative Error) เป็นตัวตัดสิน

1.2.4 เพื่อค้นหาแบบจำลองที่เหมาะสมที่สุด (Best Model) ในแต่ละภารกิจ: พิจารณาสมดุลระหว่างความแม่นยำเชิงสถิติ (Accuracy/RMSE) และประสิทธิภาพด้านเวลาในการประมวลผล (Computational Efficiency) เพื่อนำไปสู่การประยุกต์ใช้ในเชิงปฏิบัติได้อย่างเหมาะสม

1.3 ขอบเขตของโครงงาน

1.3.1 ขอบเขตเชิงเนื้อหา

1.3.1.1 ศึกษาและวิเคราะห์ชุดข้อมูลสุขภาพจากกลุ่มประชากรในประเทศเม็กซิโก เปรู และโคลอมเบีย จำนวนทั้งสิ้น 2,111 รายการ

1.3.1.2 ครอบคลุมการวิเคราะห์ปัจจัยนำเข้า (Input Features) จำนวน 17 ด้าน ประกอบด้วยข้อมูลพื้นฐาน (เพศ, อายุ) พฤติกรรมการบริโภค (ความถี่การกินผัก, จำนวนมื้อ, การดื่มน้ำ) กิจกรรมทางกาย และข้อมูลด้านพันธุกรรม

1.3.1.3 ครอบคลุมการจำแนกตัวแปรเป้าหมาย (Targets) ในงาน Classification ได้แก่ ระดับภาวะน้ำหนักเกิน (7 ระดับ), ประวัติครอบครัว และเพศ

1.3.1.4 ครอบคลุมการพยากรณ์ค่าเป้าหมายในงาน Regression ได้แก่ อายุ, น้ำหนักตัว และส่วนสูง

1.3.2 ขอบเขตเชิงเทคนิค

1.3.2.1 เทคนิคการจำแนกประเภท (Classification): มุ่งเน้นการทำ Multi-class Classification สำหรับระดับความอ้วน และ Binary Classification สำหรับปัจจัยเพศและพันธุกรรม

1.3.2.2 เทคนิคการถดถอย (Regression): มุ่งเน้นการพยากรณ์ค่าตัวเลขต่อเนื่องเพื่อลดค่าความคลาดเคลื่อนสัมพัทธ์ให้เหลือน้อยที่สุด

1.3.2.3 อัลกอริทึมที่ใช้เปรียบเทียบ: เปรียบเทียบ 3 อัลกอริทึมหลัก ได้แก่ โครงข่ายประสาทเทียม (Deep Learning/ANN), แบบจำลองป่าสุ่ม (Random Forest) และต้นไม้ตัดสินใจ (Decision Tree) ผ่านระบบ Auto Model ของ Altair AI Studio

1.4 เครื่องมือที่ใช้ในการดำเนินงาน

1.4.1 Altair AI Studio (RapidMiner): เครื่องมือหลักที่ใช้ในกระบวนการเตรียมข้อมูล (Data Preprocessing), การจัดการค่าสูญหาย, การทำ Feature Scaling, การสร้างและทดสอบแบบจำลองด้วยระบบอัตโนมัติ (Auto Model)

1.4.2 Obesity Levels Dataset: ชุดข้อมูลมาตรฐานจาก UCI Machine Learning Repository ซึ่งรวมข้อมูลจริงจากการสำรวจและข้อมูลสังเคราะห์ด้วยเทคนิค SMOTE เพื่อความสมบูรณ์ของข้อมูล

1.4.3 Microsoft Word & Canva: เครื่องมือในการรวบรวมข้อมูล จัดทำเอกสารรายงานฉบับสมบูรณ์ และออกแบบภาพประกอบเพื่อนำเสนอผลการวิจัย

1.5 ประโยชน์ที่คาดว่าจะได้รับ

1.5.1 ความเข้าใจเชิงลึกในปัจจัยเสี่ยง: สามารถระบุปัจจัยหลักที่มีผลกระทบสูงสุดต่อโรคอ้วน ช่วยให้หน่วยงานที่เกี่ยวข้องสามารถออกแบบแคมเปญรณรงค์สุขภาพที่ตรงเป้าหมาย (Targeted Intervention)

1.5.2 แบบจำลองพยากรณ์ที่มีความเชื่อถือสูง: ได้รับโมเดลที่มีความแม่นยำสูงเพื่อใช้เป็นเครื่องมือสนับสนุนการตัดสินใจเบื้องต้นสำหรับบุคลากรทางการแพทย์ในการคัดกรองกลุ่มเสี่ยงได้อย่างรวดเร็ว

1.5.3 การส่งเสริมการเฝ้าระวังสุขภาพด้วยตนเอง: ช่วยให้บุคคลทั่วไปสามารถนำโมเดลไปประเมินความเสี่ยงและพยากรณ์แนวโน้มน้ำหนักตัวของตนเอง เพื่อการปรับเปลี่ยนพฤติกรรมก่อนที่จะเข้าสู่ภาวะโรคแทรกซ้อน

1.5.4 การบริหารจัดการทรัพยากรสาธารณสุข: ช่วยลดภาระค่าใช้จ่ายและงบประมาณในการรักษาโรค NCDs ในระยะยาว ผ่านกระบวนการป้องกันและคัดกรองเชิงรุกที่มีประสิทธิภาพจากเทคโนโลยีปัญญาประดิษฐ์

บทที่ 2

ข้อมูลและการเตรียมข้อมูล

2.1 การเตรียมข้อมูลและความหมายของข้อมูล (Data Preparation and Dictionary)

ในกระบวนการวิเคราะห์ข้อมูลเพื่อพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วนนั้น ปัจจัยที่มีความสำคัญสูงสุดคือคุณภาพของข้อมูลนำเข้าและความเข้าใจอย่างลึกซึ้งในตัวแปรต่างๆ ที่ส่งผลกระทบต่อสรีระร่างกายมนุษย์ ชุดข้อมูลที่นำมาศึกษาในครั้งนี้ได้รับการคัดเลือกและจัดระเบียบเพื่อให้ครอบคลุมมิติที่หลากหลาย ทั้งด้านชีวสถิติพื้นฐาน พฤติกรรมการบริโภคอาหารในชีวิตประจำวัน และลักษณะการทำกิจกรรมทางกาย เพื่อให้แบบจำลองปัญญาประดิษฐ์สามารถเรียนรู้และสร้างรูปแบบความสัมพันธ์ที่สะท้อนความเป็นจริงของประชากรในแถบละตินอเมริกาได้อย่างแม่นยำที่สุด

2.1.1 ความหมายของข้อมูล (Data Dictionary)

ชุดข้อมูลนี้ประกอบด้วยคุณลักษณะทั้งหมด 17 รายการ (Attributes) และมีจำนวนรายการข้อมูลทั้งสิ้น 2,111 รายการ ซึ่งเป็นข้อมูลที่ผสมผสานระหว่างข้อมูลจริงจากการสำรวจและข้อมูลที่สร้างขึ้นด้วยกระบวนการทางสถิติ (Synthetic Data) เพื่อขยายขนาดข้อมูลให้เพียงพอต่อการเรียนรู้ของโมเดลซับซ้อน โดยแบ่งตัวแปรออกเป็นประเภทต่างๆ ดังนี้

1. Gender ข้อมูลระบุเพศของผู้ทำแบบทดสอบ แบ่งเป็น เพศชาย และ เพศหญิง เพื่อวิเคราะห์ความแตกต่างทางโครงสร้างร่างกายที่สัมพันธ์กับเพศ

2. Age ข้อมูลอายุของผู้เข้าร่วมการทดสอบ จัดเป็นข้อมูลเชิงปริมาณรายปี ซึ่งมีความสำคัญต่ออัตราการเผาผลาญพื้นฐาน

3. Height ข้อมูลส่วนสูงของผู้ทดสอบ มีหน่วยวัดเป็นเมตร ใช้สำหรับคำนวณสัดส่วนทางกายภาพร่วมกับตัวแปรอื่น

4. Weight ข้อมูลน้ำหนักตัวปัจจุบันของผู้ทดสอบ มีหน่วยวัดเป็นกิโลกรัม เป็นตัวแปรหลักที่ใช้ในการวิเคราะห์เชิงถดถอย

5. family_history_with_overweight ข้อมูลด้านพันธุกรรม โดยระบุว่ามีประวัติสมาชิกในครอบครัวที่มีภาวะน้ำหนักเกินหรือไม่ ซึ่งเป็นปัจจัยแฝงที่ส่งผลต่อการสะสมไขมัน

6. FAVC พฤติกรรมการบริโภคอาหารที่มีค่าพลังงานหรือแคลอรีสูงเป็นประจำ (Frequent consumption of high caloric food)

7. FCVC ระดับความถี่ในการรับประทานผักในมื้ออาหาร (1 = ไม่เคย, 2 = บางครั้ง, 3 = ตลอดเวลา) สะท้อนถึงคุณภาพของอาหารที่บริโภค

8. NCP จำนวนมื้ออาหารหลักเฉลี่ยที่บริโภคต่อวัน เพื่อวิเคราะห์รูปแบบความถี่ในการรับพลังงาน

9. CAEC พฤติกรรมการรับประทานอาหารว่าง ขนม หรือของจุบจิบระหว่างมื้ออาหารหลัก ซึ่งมักเป็นแหล่งแคลอรีส่วนเกิน

10. SMOKE ข้อมูลพฤติกรรมการสูบบุหรี่ของผู้ทดสอบ เพื่อดูความสัมพันธ์กับพฤติกรรมสุขภาพโดยรวม

11. CH2O ปริมาณการดื่มน้ำเปล่าบริสุทธิ์ต่อวัน ซึ่งส่งผลต่อระบบการเผาผลาญและการลดน้ำหนัก

12. SCC พฤติกรรมการเฝ้าเช็คหรือควบคุมปริมาณแคลอรีที่บริโภคในแต่ละวัน สะท้อนถึงระดับความใส่ใจในสุขภาพ

13. FAF ความถี่ของการทำกิจกรรมทางกายหรือการออกกำลังกายต่อสัปดาห์ เป็นปัจจัยหลักในการเผาผลาญพลังงานส่วนเกิน

14. TUE ระยะเวลาที่ใช้ไปกับอุปกรณ์เทคโนโลยีต่อวัน สะท้อนถึงพฤติกรรมเนือยนิ่ง (Sedentary Behavior) ที่สัมพันธ์กับโรคอ้วน

15. CALC ความถี่ในการบริโภคเครื่องดื่มที่มีแอลกอฮอล์ ซึ่งเป็นปัจจัยที่ให้พลังงานสูงและส่งผลต่อการสะสมไขมันหน้าท้อง

16. MTRANS พาหนะหลักที่ใช้ในการเดินทางในชีวิตประจำวัน เพื่อวิเคราะห์ระดับการเคลื่อนไหวร่างกายจากการเดินทาง

17. NObeyesdad (Target Variable) ตัวแปรเป้าหมายหลักที่ใช้ในการทำนายระดับความรุนแรงของภาวะร่างกาย แบ่งออกเป็น 7 ระดับตามดัชนีมวลกาย ได้แก่:

- Insufficient Weight ภาวะน้ำหนักน้อยกว่าเกณฑ์มาตรฐาน
- Normal Weight ภาวะน้ำหนักอยู่ในเกณฑ์ปกติ
- Overweight Level I ภาวะน้ำหนักเกินระดับเริ่มต้น
- Overweight Level II ภาวะน้ำหนักเกินระดับอันตราย
- Obesity Type I โรคอ้วนระดับที่ 1
- Obesity Type II โรคอ้วนระดับที่ 2
- Obesity Type III โรคอ้วนระดับรุนแรงสูงสุด (Morbid Obesity)

Age	Gender	Height	Weight	CALC	FAVC	FCVC	NCP	SCC	SMOKE	CH2O	family_history_with_overweight	FAF	TUE	CAEC	MTRANS	NObeyesdad
21	Female	1.62	64	no	no	2	3	no	no	2	yes	0	1	Sometimes	Public_Transportation	Normal_Weight
21	Female	1.52	56	Sometimes	no	3	3	yes	yes	3	yes	3	0	Sometimes	Public_Transportation	Normal_Weight
23	Male	1.8	77	Frequently	no	2	3	no	no	2	yes	2	1	Sometimes	Public_Transportation	Normal_Weight
27	Male	1.8	87	Frequently	no	3	3	no	no	2	no	2	0	Sometimes	Walking	Overweight_Level_I
22	Male	1.78	89.8	Sometimes	no	2	1	no	no	2	no	0	0	Sometimes	Public_Transportation	Overweight_Level_II
29	Male	1.62	53	Sometimes	yes	2	3	no	no	2	no	0	0	Sometimes	Automobile	Normal_Weight
23	Female	1.5	55	Sometimes	yes	3	3	no	no	2	yes	1	0	Sometimes	Motorbike	Normal_Weight
22	Male	1.64	53	Sometimes	no	2	3	no	no	2	no	3	0	Sometimes	Public_Transportation	Normal_Weight
24	Male	1.78	64	Frequently	yes	3	3	no	no	2	yes	1	1	Sometimes	Public_Transportation	Normal_Weight
22	Male	1.72	68	no	yes	2	3	no	no	2	yes	1	1	Sometimes	Public_Transportation	Normal_Weight
26	Male	1.85	105	Sometimes	yes	3	3	no	no	3	yes	2	2	Frequently	Public_Transportation	Obesity_Type_I
21	Female	1.72	80	Sometimes	yes	2	3	yes	no	2	yes	2	1	Frequently	Public_Transportation	Overweight_Level_II
22	Male	1.65	56	Sometimes	no	3	3	no	no	3	no	2	0	Sometimes	Public_Transportation	Normal_Weight
41	Male	1.8	99	Frequently	yes	2	3	no	no	2	no	2	1	Sometimes	Automobile	Obesity_Type_I
21	Male	1.77	60	Sometimes	yes	3	1	no	no	1	yes	1	1	Sometimes	Public_Transportation	Normal_Weight
22	Female	1.7	66	Sometimes	no	3	3	yes	no	2	yes	2	1	Always	Public_Transportation	Normal_Weight
27	Male	1.93	102	Sometimes	yes	2	1	no	no	1	yes	1	0	Sometimes	Public_Transportation	Overweight_Level_II
29	Female	1.53	78	no	yes	2	1	no	no	2	no	0	0	Sometimes	Automobile	Obesity_Type_I
30	Female	1.71	82	no	yes	3	4	no	yes	1	yes	0	0	Frequently	Automobile	Overweight_Level_II
23	Female	1.65	70	Sometimes	no	2	1	no	no	2	yes	0	0	Sometimes	Public_Transportation	Overweight_Level_I
22	Male	1.65	80	no	no	2	3	no	no	2	yes	3	2	Sometimes	Walking	Overweight_Level_II
52	Female	1.69	87	no	yes	3	1	no	yes	2	yes	0	0	Sometimes	Automobile	Obesity_Type_I
22	Female	1.65	60	Sometimes	yes	3	3	no	no	2	yes	1	0	Sometimes	Automobile	Normal_Weight
22	Female	1.6	82	Sometimes	yes	1	1	no	no	2	yes	0	2	Sometimes	Public_Transportation	Obesity_Type_I
21	Male	1.85	68	Sometimes	yes	2	3	no	no	2	yes	0	1	Sometimes	Public_Transportation	Normal_Weight
20	Male	1.6	50	no	no	2	4	no	yes	2	yes	3	2	Frequently	Public_Transportation	Normal_Weight
21	Male	1.7	65	Always	yes	2	1	no	no	2	yes	1	2	Frequently	Walking	Normal_Weight
23	Female	1.6	52	Sometimes	yes	2	4	no	no	2	no	2	1	Frequently	Automobile	Normal_Weight
19	Male	1.75	76	Sometimes	yes	3	3	yes	no	2	yes	3	1	Sometimes	Public_Transportation	Normal_Weight
23	Male	1.68	70	Frequently	yes	2	3	no	no	2	no	2	2	Sometimes	Walking	Normal_Weight
29	Male	1.77	83	no	yes	1	4	no	no	3	no	0	1	Frequently	Motorbike	Overweight_Level_I
31	Female	1.58	68	Sometimes	no	2	1	no	no	1	yes	1	0	Sometimes	Public_Transportation	Overweight_Level_II
24	Female	1.77	76	Sometimes	no	2	3	no	no	3	no	1	1	Sometimes	Walking	Normal_Weight
39	Male	1.79	90	Sometimes	no	2	1	no	no	2	no	0	0	Sometimes	Public_Transportation	Overweight_Level_II
22	Male	1.65	62	Sometimes	yes	2	4	no	no	2	no	2	0	Frequently	Public_Transportation	Normal_Weight
21	Female	1.5	65	Sometimes	no	2	3	no	no	2	yes	2	2	Sometimes	Public_Transportation	Overweight_Level_II
22	Female	1.56	49	no	yes	2	3	yes	no	1	no	2	0	Sometimes	Walking	Normal_Weight
21	Female	1.6	48	Sometimes	yes	2	3	no	no	1	no	1	0	Sometimes	Public_Transportation	Normal_Weight
23	Male	1.65	67	Sometimes	yes	2	3	no	no	2	yes	1	1	Sometimes	Public_Transportation	Normal_Weight
21	Female	1.75	88	Sometimes	yes	2	3	no	no	3	yes	3	0	Sometimes	Public_Transportation	Overweight_Level_II
21	Female	1.67	75	Sometimes	yes	2	3	no	no	2	yes	1	0	Sometimes	Public_Transportation	Overweight_Level_I
23	Male	1.68	60	no	no	2	4	no	no	2	no	0	0	Frequently	Walking	Normal_Weight
21	Female	1.66	64	no	yes	1	3	no	no	1	yes	0	0	Sometimes	Public_Transportation	Normal_Weight
21	Male	1.66	62	Frequently	yes	2	3	no	yes	2	yes	1	1	Sometimes	Public_Transportation	Normal_Weight
21	Male	1.81	80	no	no	1	3	no	no	2	no	2	0	no	Public_Transportation	Normal_Weight
21	Female	1.53	65	no	no	2	3	no	no	1	yes	0	1	Sometimes	Public_Transportation	Overweight_Level_II

ภาพที่ 2.1 ตัวอย่างฐานข้อมูลที่ใช้พยาการณ์

2.1.2 ขั้นตอนการเตรียมข้อมูล (Data Preprocessing)

เพื่อให้ชุดข้อมูลมีความพร้อมสมบูรณ์สำหรับการนำไปเข้าสู่กระบวนการฝึกสอนของโมเดล Machine Learning ที่มีความซับซ้อนสูง ผู้จัดทำได้ดำเนินการผ่านกระบวนการจัดการข้อมูลอย่างละเอียดเพื่อเพิ่มคุณภาพและความแม่นยำ ดังนี้

2.1.2.1 การจัดการค่าสูญหาย (Missing Values) จากการสำรวจเชิงลึกพบว่าชุดข้อมูลมีความสมบูรณ์สูงมาก เนื่องจากการเก็บรวบรวมข้อมูลต้นทางมีการใช้เทคนิค SMOTE (Synthetic Minority Over-sampling Technique) เพื่อเติมเต็มข้อมูลในกลุ่มตัวอย่างที่น้อย (Minority Class) ให้สมดุลกับกลุ่มอื่น ส่งผลให้ไม่พบค่าว่าง (Null) ที่เป็นอุปสรรคต่อการประมวลผล ทำให้ข้อมูลชุดนี้มีความต่อเนื่องและลดการเกิดความคลาดเคลื่อนจากการเดาค่าข้อมูลที่หายไป

2.1.2.2 การตรวจสอบข้อมูลซ้ำ (Duplicate Data) ผู้จัดทำดำเนินการตรวจสอบและลบแถวข้อมูลที่มีลักษณะซ้ำซ้อนกันอย่างสมบูรณ์ออกจากฐานข้อมูล ขั้นตอนนี้มีความสำคัญอย่างยิ่งในการป้องกันปัญหาการจดจำข้อมูลแม่แบบ (Overfitting) ซึ่งจะทำให้โมเดลให้ค่าน้ำหนักกับข้อมูลชุดใดชุดหนึ่งมากเกินความจริง จนส่งผลให้ประสิทธิภาพในการทำนายข้อมูลใหม่ที่โมเดลไม่เคยเห็นมาก่อนลดลงอย่างมีนัยสำคัญ

2.1.2.3 การแปลงข้อมูลหมวดหมู่ (Categorical Encoding) เนื่องจากอัลกอริทึมอย่าง ANN และ Random Forest ไม่สามารถประมวลผลข้อมูลที่เป็นข้อความได้โดยตรง จึงต้องทำการแปลงข้อมูลประเภทหมวดหมู่ (Categorical Data) ให้เป็นตัวเลขผ่านเทคนิคที่เหมาะสม โดยใช้ Label Encoding สำหรับข้อมูลที่มีลำดับชัดเจน (Ordinal) เช่น ระดับความถี่ในการกินผัก และใช้ One-Hot Encoding สำหรับข้อมูลที่ไม่มีความสัมพันธ์ด้านลำดับ (Nominal) เช่น เพศ หรือประเภทพาหนะ เพื่อป้องกันไม่ให้โมเดลเข้าใจผิดว่าตัวแปรหนึ่งมีค่ามากกว่าอีกตัวแปรหนึ่งในเชิงปริมาณ

2.1.2.4 การปรับมาตรฐานข้อมูล (Feature Scaling) ดำเนินการปรับจูนตัวแปรที่มีมาตรวัดและขอบเขตตัวเลขที่แตกต่างกันอย่างสิ้นเชิงผ่านเทคนิค Standardization (Z-score Normalization) โดยปรับให้ตัวแปรทุกตัวมีค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1 ขั้นตอนนี้จำเป็นอย่างยิ่งสำหรับโมเดล Deep Learning เพื่อป้องกันไม่ให้ตัวแปรที่มีค่าตัวเลขสูง (เช่น น้ำหนักเป็นกิโลกรัม) เข้าไปกลบอิทธิพลของตัวแปรที่มีค่าตัวเลขต่ำ (เช่น ส่วนสูงเป็นเมตร) ช่วยให้อัลกอริทึมลู่เข้าสู่จุดคำตอบ (Convergence) ได้รวดเร็วและแม่นยำยิ่งขึ้น

บทที่ 3

วิธีการดำเนินงานและโมเดลที่ใช้ในการวิเคราะห์

3.1 วิธีการดำเนินงานและขั้นตอนการเตรียมระบบ (System Setup)

เพื่อให้การวิเคราะห์ข้อมูลด้วยเทคนิคการเรียนรู้ของเครื่อง (Machine Learning) เป็นไปอย่างมีประสิทธิภาพ ผู้จัดทำได้ใช้ซอฟต์แวร์ Altair AI Studio ในการดำเนินงาน โดยมีขั้นตอนการนำเข้าข้อมูลและการเตรียมความพร้อมของระบบดังนี้

3.1.1 วิธีการนำเข้าข้อมูล (Data Ingestion)

กระบวนการนำเข้าชุดข้อมูลเข้าสู่โปรแกรม Altair AI Studio เพื่อเตรียมความพร้อมสำหรับการสร้างแบบจำลอง มีขั้นตอนดังต่อไปนี้

3.1.1.1 การเริ่มต้นใช้งานซอฟต์แวร์: เมื่อเปิดโปรแกรม Altair AI Studio จะพบหน้าต่างต้อนรับ ให้เลือกเมนู **"Auto Model"** เพื่อเข้าสู่กระบวนการสร้างและปรับแต่งโมเดลแบบอัตโนมัติ

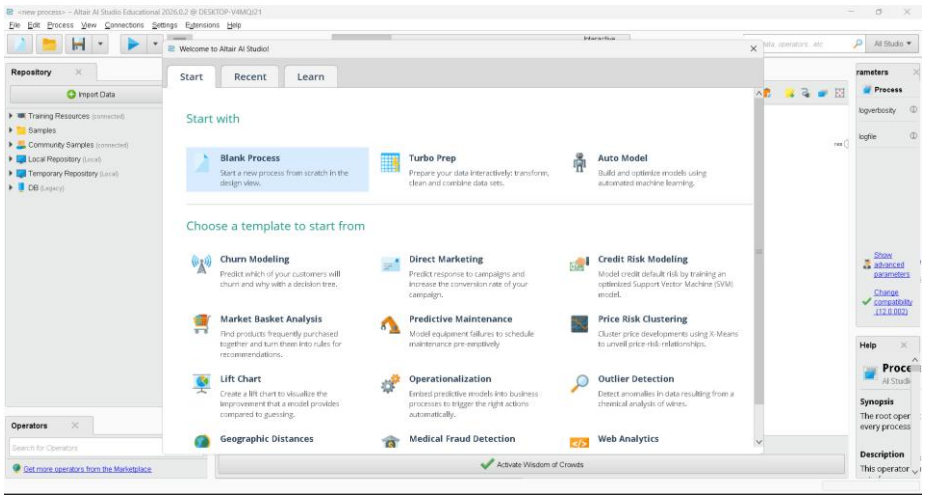

ภาพที่ 3.1 การเริ่มต้นเข้าสู่ฟังก์ชัน Auto Model บนหน้าต่างต้อนรับของโปรแกรม Altair AI Studio

3.1.1.2 การเลือกแหล่งที่มาของข้อมูล: ระบบจะแสดงหน้าต่างแหล่งเก็บข้อมูล ให้คลิกที่ปุ่ม **"My Computer"** เพื่อทำการเลือกไฟล์ชุดข้อมูลที่จัดเก็บไว้ในเครื่องคอมพิวเตอร์

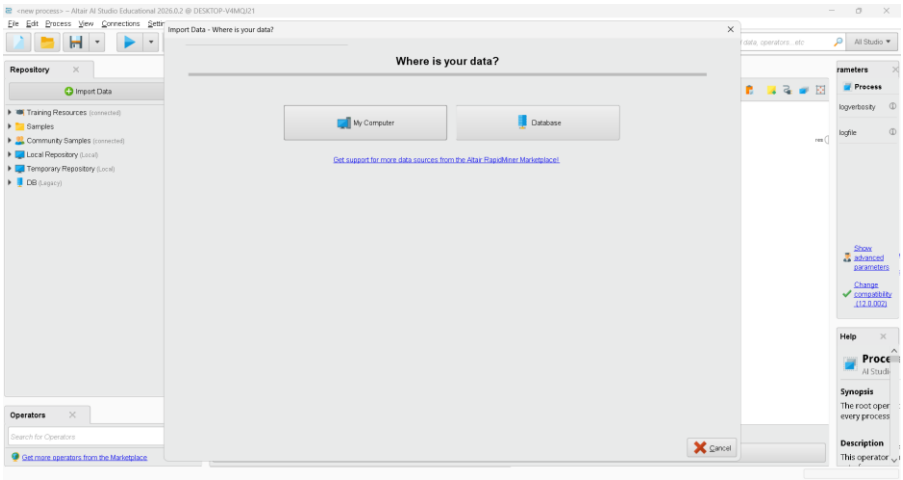

ภาพที่ 3.2 การเลือกแหล่งที่มาของข้อมูลจากหน่วยความจำภายในเครื่องคอมพิวเตอร์ (My Computer)

3.1.1.3 การเลือกไฟล์ชุดข้อมูล: ดำเนินการค้นหาและเลือกไฟล์ที่มีชื่อว่า **"ObesityDataSet_raw_and_data_sinthetic.csv"** จากโฟลเดอร์ที่จัดเก็บ จากนั้นคลิกปุ่ม **"Next"** เพื่อดำเนินการต่อ

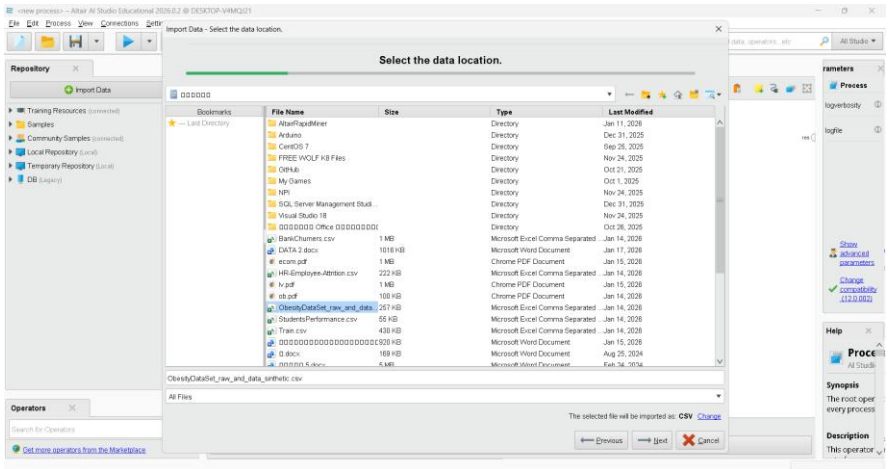

ภาพที่ 3.3 การเลือกไฟล์ชุดข้อมูลเป้าหมายในรูปแบบนามสกุล .csv เพื่อนำเข้าสู่ระบบประมวลผล

3.1.1.4 การตรวจสอบรูปแบบไฟล์ (Specify Data Format): โปรแกรมจะแสดงตัวอย่างข้อมูลเพื่อให้ผู้ใช้ตรวจสอบความถูกต้องของโครงสร้างไฟล์ เช่น แถวส่วนหัว (Header Row) ตัวแบ่งคอลัมน์ (Column Separator) และการเข้ารหัสไฟล์ (Encoding) เมื่อตรวจสอบว่าข้อมูลถูกต้องแล้วให้คลิก **"Next"**

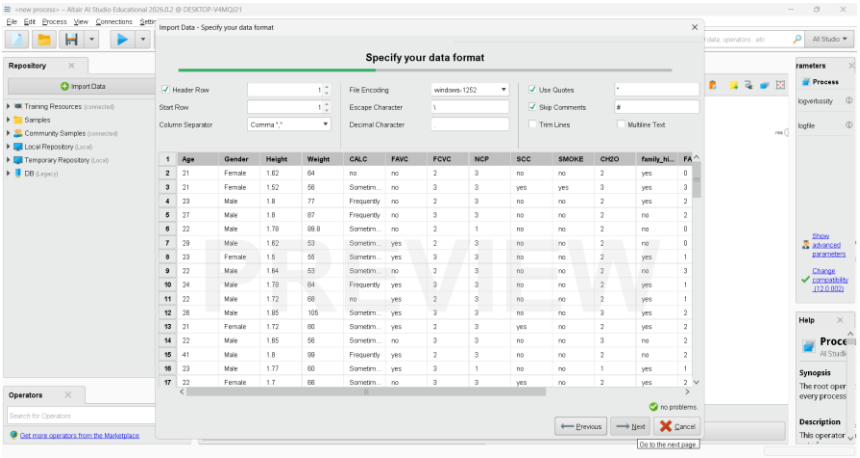

ภาพที่ 3.4 การตรวจสอบความถูกต้องของโครงสร้างไฟล์ข้อมูล (Data Format) และการตั้งค่าตัวแบ่งคอลัมน์

3.1.1.5 การกำหนดประเภทคอลัมน์ (Format Your Columns): ในขั้นตอนนี้ระบบจะแสดงคอลัมน์ทั้งหมดพร้อมประเภทข้อมูลที่ตรวจพบ (เช่น integer, real, polynominal) ผู้ใช้สามารถตรวจสอบและปรับเปลี่ยนประเภทข้อมูลให้เหมาะสมกับแต่ละคุณลักษณะ (Attributes) ได้ หากม่มีข้อผิดพลาดให้คลิก **"Next"**

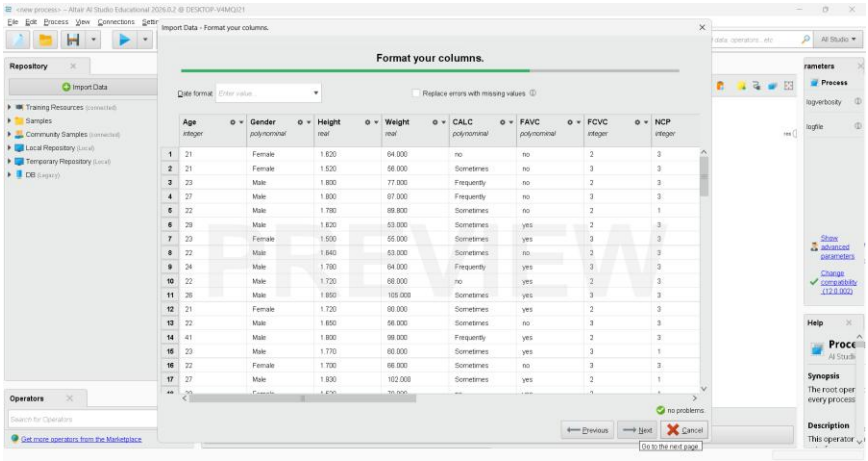

ภาพที่ 3.5 การตรวจสอบและกำหนดประเภทของข้อมูล (Data Types) ให้เหมาะสมกับแต่ละคุณลักษณะของตัว

3.1.1.6 การกำหนดพื้นที่จัดเก็บข้อมูล (Store Data Location): เลือกตำแหน่งที่ต้องการบันทึกชุดข้อมูลที่นำเข้ามาใน Repository ของโปรแกรม โดยแนะนำให้เลือกที่ **"Local Repository"** จากนั้นตรวจสอบชื่อไฟล์ที่ช่อง Name ให้ถูกต้องและคลิก **"Finish"**

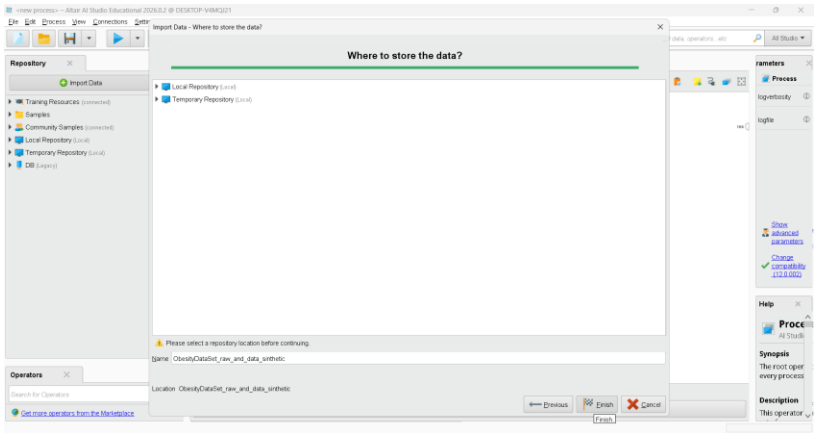

ภาพที่ 3.6 การเลือกตำแหน่งจัดเก็บชุดข้อมูลภายใน Local Repository และการตั้งชื่อไฟล์ก่อนกระบวนการบันทึก

3.1.1.7 การแสดงผลชุดข้อมูลในระบบ: เมื่อการนำเข้าเสร็จสมบูรณ์ โปรแกรมจะแสดงหน้าต่าง **Results** เพื่อแสดงตารางข้อมูลทั้งหมดที่พร้อมสำหรับการนำไปวิเคราะห์ในขั้นตอนถัดไป โดยในตัวอย่างนี้จะมีจำนวนข้อมูลทั้งหมด 2,111 รายการ และ 17 คุณลักษณะ

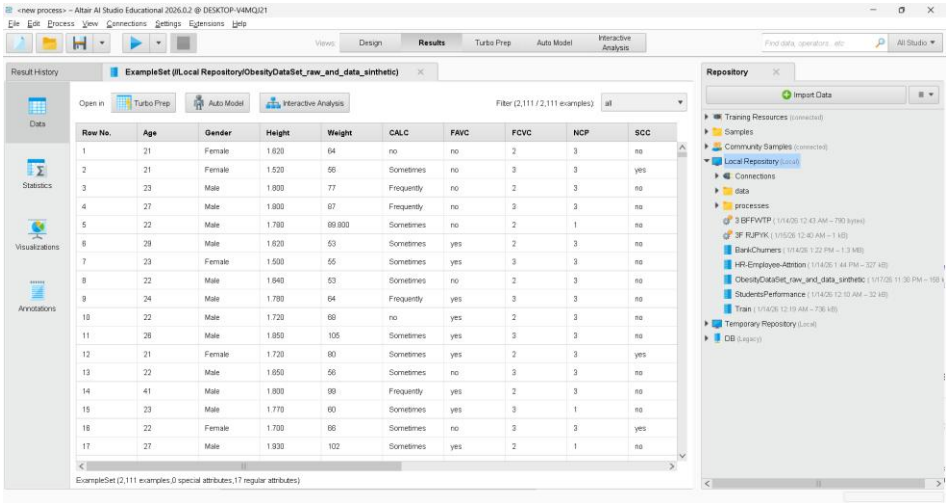

ภาพที่ 3.7 หน้าต่างแสดงผลลัพธ์ (Results View) หลังการนำเข้าข้อมูลสำเร็จ เพื่อตรวจสอบความครบถ้วนของรายการข้อมูลทั้ง 2,111 รายการ

3.1.2 กระบวนการวิเคราะห์และทดสอบแบบจำลองอัตโนมัติ (Automated Modeling and Testing Workflow)

เพื่อให้เห็นลำดับขั้นตอนการทำงานที่ชัดเจน ผู้จัดทำได้แบ่งกระบวนการดำเนินงานผ่านระบบ **Auto Model** ในโปรแกรม Altair AI Studio ออกเป็น 2 รูปแบบตามภารกิจการวิเคราะห์ดังนี้

3.1.2.1 การวิเคราะห์แบบจำแนกประเภท (Classification Task)

ใช้สำหรับทำนายตัวแปรเป้าหมายที่เป็นกลุ่มหรือหมวดหมู่ (เช่น ระดับความอ้วน, เพศ) มีขั้นตอนดังนี้:

3.1.2.1.1 การเลือกภารกิจ (Select Task): เมื่อนำเข้าข้อมูลแล้ว ให้เลือกภารกิจแบบ **"Predict"** เพื่อทำนายค่าในคอลัมน์ที่ต้องการ

3.1.2.1.2 การกำหนดตัวแปรเป้าหมาย (Prepare Target): เลือกคอลัมน์ที่เป็นหมวดหมู่ เช่น **'NObeyesdad'** ระบบจะแสดงกราฟแท่งความถี่ของแต่ละกลุ่มข้อมูลเพื่อให้ตรวจสอบความสมดุล

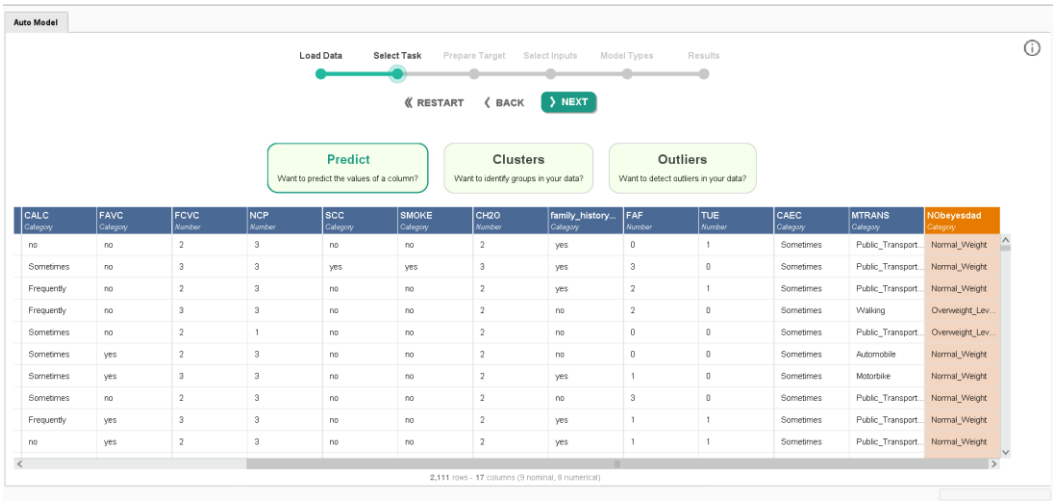

ภาพที่ 3.8 การเลือกภารกิจการพยากรณ์ (Predict) เพื่อเข้าสู่กระบวนการ Auto Model

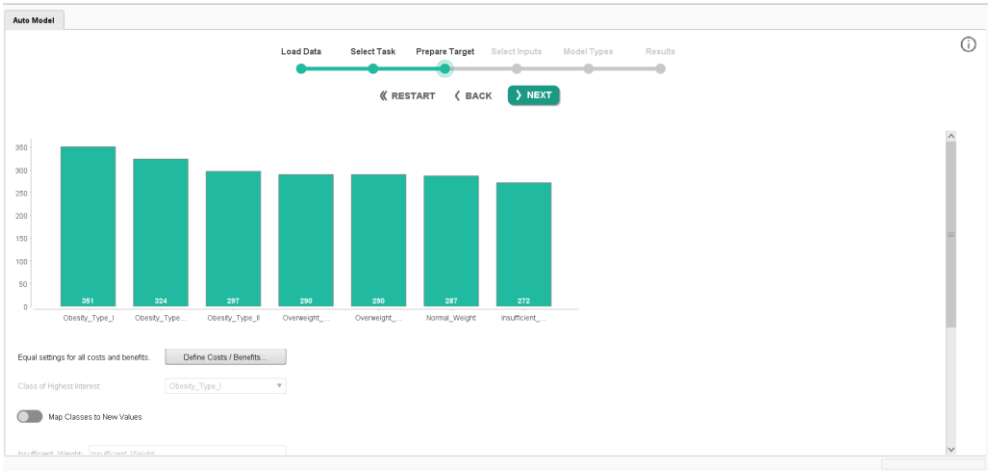

ภาพที่ 3.9 การเลือกตัวแปรเป้าหมาย (Target) และการตรวจสอบกราฟการกระจายตัวของระดับภาวะน้ำหนักตัว

3.1.2.1.3 การคัดเลือกปัจจัยนำเข้า (Select Inputs): ระบบจะคำนวณค่า Quality, Correlation และ ID-ness ของแต่ละตัวแปร โดยผู้ใช้สามารถเลือกคงไว้หรือคัดตัวแปรที่มีความสัมพันธ์ต่ำออกได้ (เช่น SCC หรือ SMOKE)

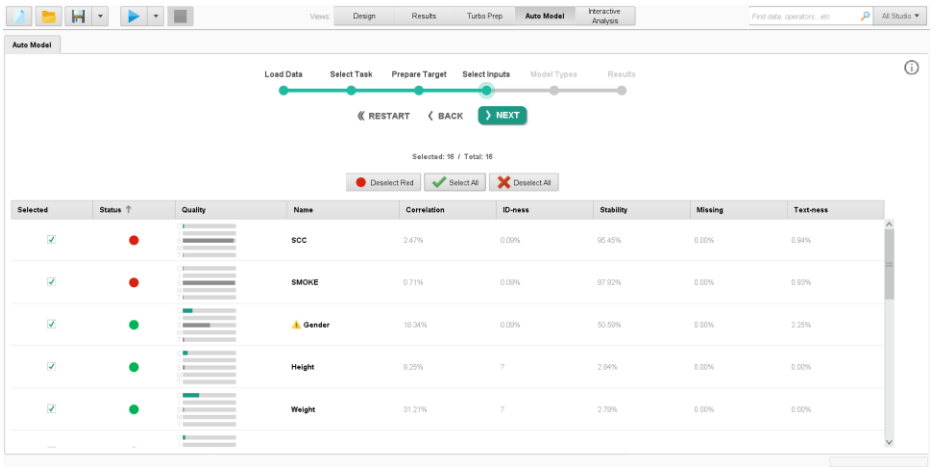

ภาพที่ 3.10 การวิเคราะห์คุณภาพของปัจจัยนำเข้า (Inputs) เพื่อคัดกรองตัวแปรที่มีความสัมพันธ์สูงสุด

3.1.2.1.4 การเลือกประเภทโมเดล (Model Types): ทำการเลือกอัลกอริทึมที่ต้องการเปรียบเทียบ ได้แก่ **Deep Learning, Decision Tree** และ **Random Forest** พร้อมตั้งค่าการปรับปรุงพารามิเตอร์แบบอัตโนมัติ

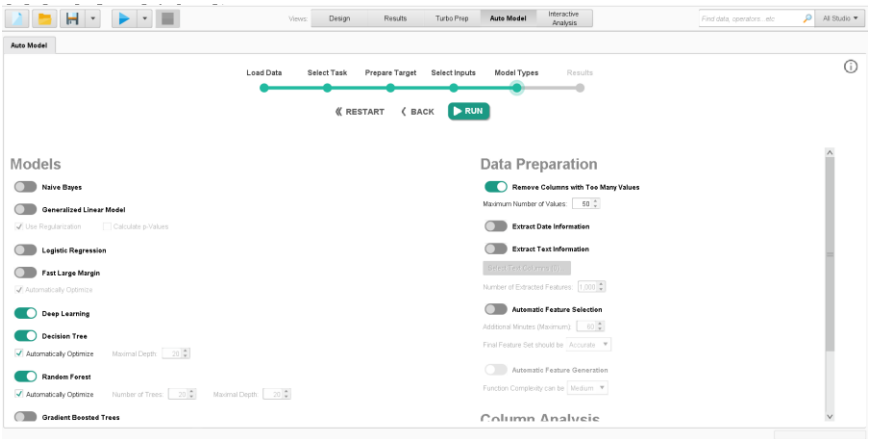

ภาพที่ 3.11 การคัดเลือกและกำหนดพารามิเตอร์สำหรับโมเดล Deep Learning, Decision Tree และ Random Forest

3.1.2.1.5 การประมวลผลและแสดงผลภาพรวม (Results Overview): เมื่อกด Run ระบบจะแสดงตารางเปรียบเทียบค่า Classification Error และ Total Time เพื่อระบุโมเดลที่แม่นยำและรวดเร็วที่สุด

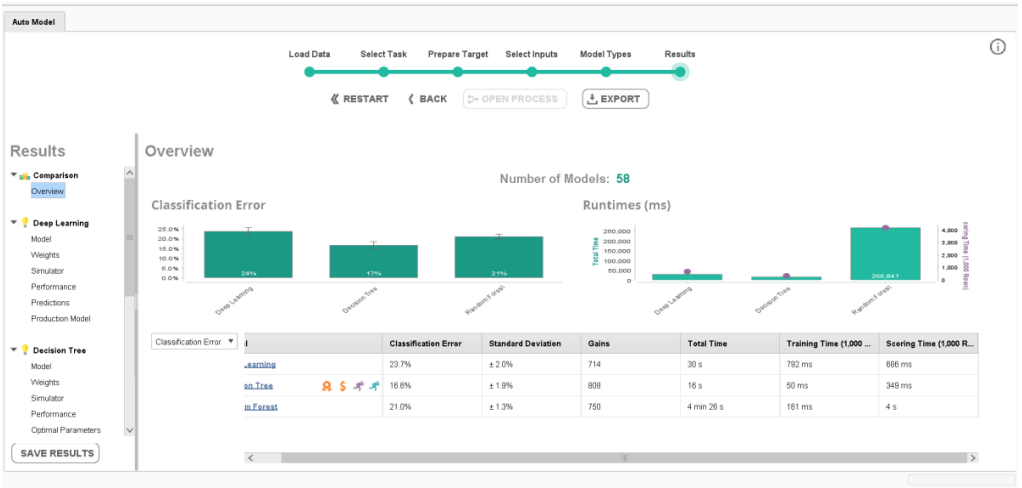

ภาพที่ 3.12 ตารางสรุปผลลัพธ์ภาพรวม (Overview) เปรียบเทียบค่าความผิดพลาดและเวลาที่ใช้ในการประมวลผล

3.1.2.1.6 การตรวจสอบความแม่นยำ (Performance Measurement): วิเคราะห์ค่าความถูกต้อง (Accuracy) และค่า Classification Error แยกตามโมเดล เช่น Decision Tree ให้ค่าแม่นยำ 83.4%

3.1.2.1.7 การวิเคราะห์ความคลาดเคลื่อน (Confusion Matrix): ตรวจสอบการทำนายถูก/ผิดในแต่ละคลาส เพื่อดูว่าโมเดลสับสนข้อมูลในกลุ่มใดมากที่สุด

3.1.2.1.8 การเปรียบเทียบประสิทธิภาพเชิงกราฟ (ROC Comparison): ใช้กราฟ ROC เพื่อดูขีดความสามารถในการแยกแยะข้อมูลของแต่ละโมเดล

ภาพที่ 3.13 การใช้กราฟเส้นโค้ง ROC และ Lift Chart เพื่อประเมินประสิทธิภาพความน่าเชื่อถือของแต่ละโมเดล

3.1.2.2 การวิเคราะห์แบบถดถอย (Regression Task)

ใช้สำหรับทำนายตัวแปรเป้าหมายที่เป็นตัวเลขต่อเนื่อง (เช่น อายุ, น้ำหนัก, ส่วนสูง) มีขั้นตอนดังนี้

3.1.2.2.1 การเลือกภารกิจ (Select Task): เลือกฟังก์ชัน **"Predict"** บนข้อมูลชุดเดียวกันเพื่อเข้าสู่กระบวนการพยากรณ์เชิงปริมาณ

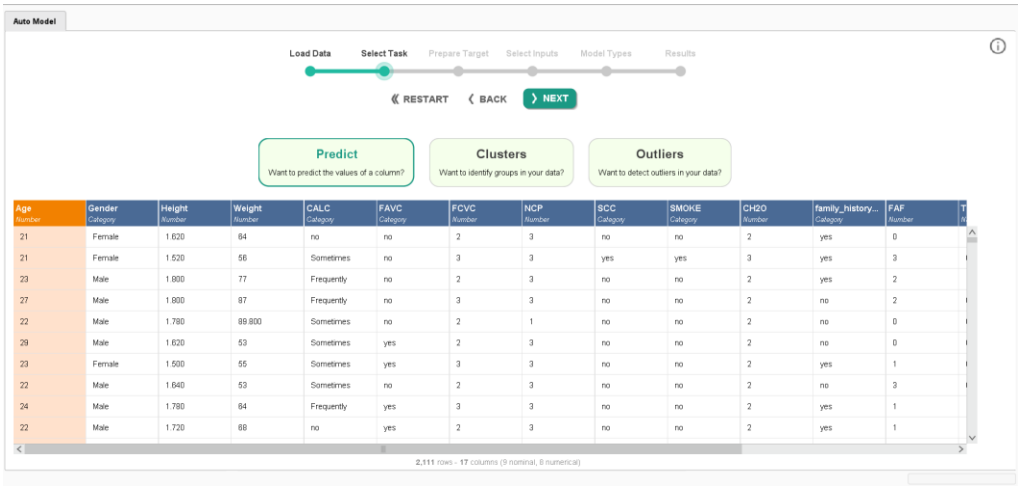

ภาพที่ 3.14 การกำหนดเป้าหมายการพยากรณ์เชิงปริมาณ (เช่น อายุ หรือ น้ำหนัก) ในโหมดการวิเคราะห์แบบถดถอย

3.1.2.2.2 การกำหนดตัวแปรเป้าหมาย (Prepare Target): เลือกคอลัมน์ที่เป็นตัวเลข เช่น **'Age'** หรือ **'Weight'** ระบบจะแสดงกราฟฮิสโตแกรมการกระจายตัวของตัวเลขเป้าหมาย

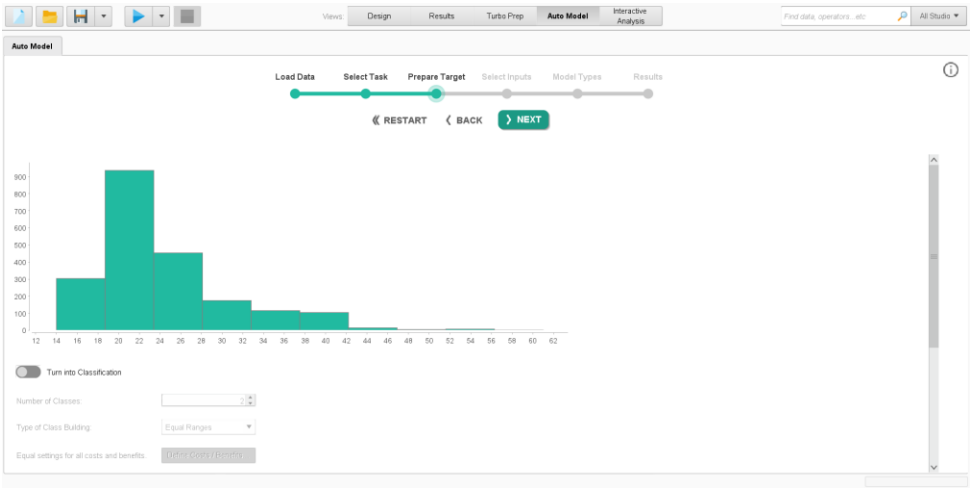

ภาพที่ 3.15 การตรวจสอบกราฟฮิสโตแกรมแสดงการกระจายตัวของข้อมูลตัวเลขต่อเนื่องเพื่อประเมินความสมดุล

3.1.2.2.3 การตรวจสอบคุณภาพข้อมูลนำเข้า (Select Inputs): ตรวจสอบความสัมพันธ์ระหว่างตัวแปรต้นกับตัวแปรเป้าหมายเชิงตัวเลข เพื่อเลือกคุณลักษณะที่มีผลต่อการคำนวณมากที่สุด

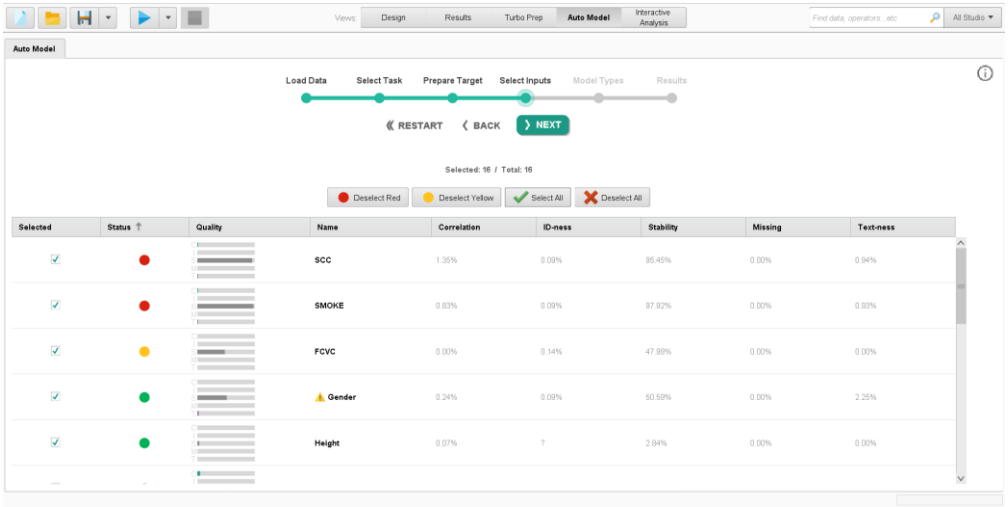

ภาพที่ 3.16 การตรวจสอบค่าสหสัมพันธ์ (Correlation) ระหว่างตัวแปรต้นกับตัวแปรเป้าหมายเชิงตัวเลข

3.1.2.2.4 การตั้งค่าอัลกอริทึม (Model Selection): เลือกโมเดลที่รองรับงาน Regression เช่น Deep Learning, Decision Tree และ Random Forest เพื่อเปรียบเทียบค่าความผิดพลาด

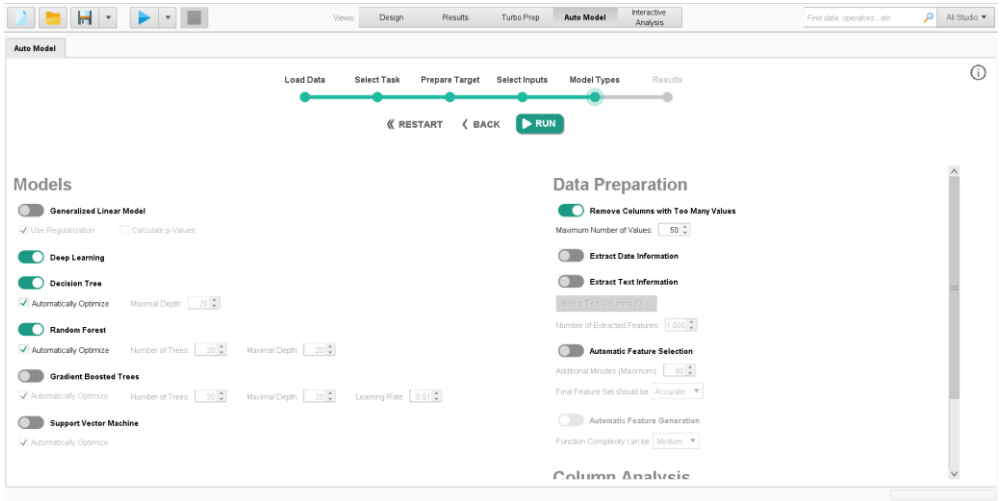

ภาพที่ 3.17 การเลือกใช้อัลกอริทึมสำหรับงาน Regression เพื่อเปรียบเทียบประสิทธิภาพในการประมาณค่า

3.1.2.2.5 การวิเคราะห์ผลลัพธ์ภาพรวม (Overview): ระบบจะแสดงค่า **Relative Error** (ความคลาดเคลื่อนสัมพัทธ์) โดย Decision Tree มักครองตำแหน่งเหรียญทองในด้านความแม่นยำและเวลาที่สั้นที่สุด

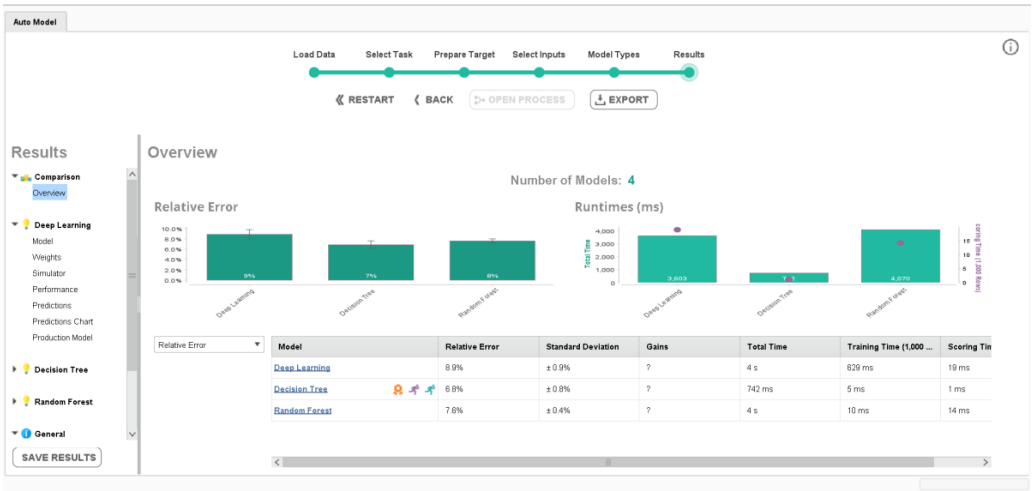

ภาพที่ 3.18 การแสดงค่า Relative Error เพื่อเปรียบเทียบเปอร์เซ็นต์ความคลาดเคลื่อนระหว่างโมเดลต่างๆ

3.1.2.2.6 การตรวจสอบความผิดพลาดแบบ RMSE (Performance): ดูค่า Root Mean Squared Error เพื่อระบุระยะห่างเฉลี่ยระหว่างค่าจริงกับค่าที่ทำนายได้

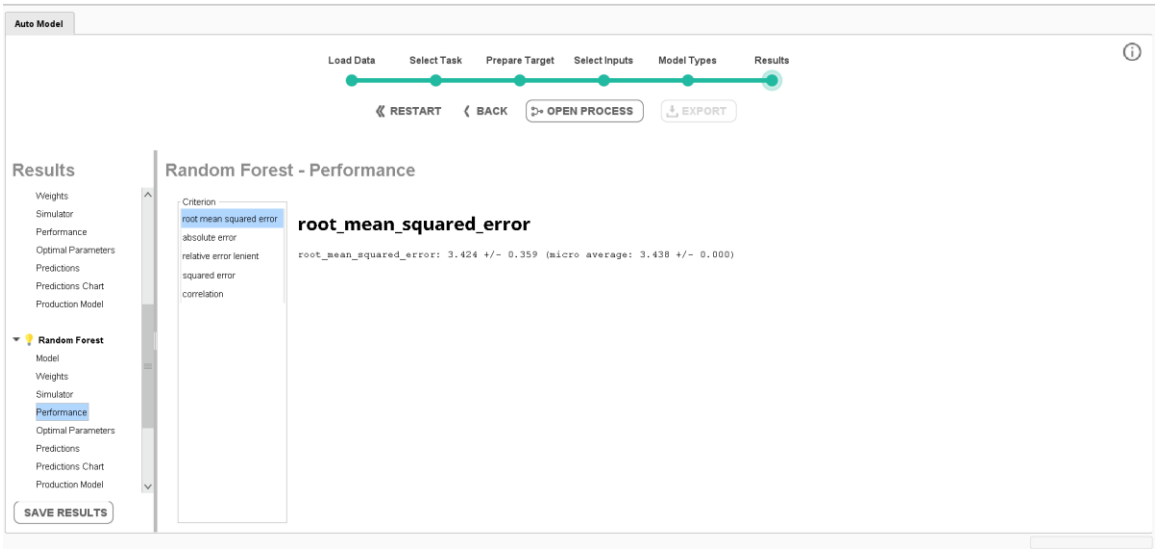

ภาพที่ 3.21 การวิเคราะห์ค่า RMSE (Root Mean Squared Error) เพื่อวัดระยะห่างระหว่างค่าพยากรณ์และค่าจริง

3.2 โมเดลที่ใช้ในการวิเคราะห์ (Modeling)

สำหรับการดำเนินงานในขั้นตอนการสร้างแบบจำลองนั้น ภารกิจหลักมุ่งเน้นไปที่การเปรียบเทียบขีดความสามารถของอัลกอริทึมที่แตกต่างกันภายใต้สภาพแวดล้อมและข้อมูลชุดเดียวกัน เพื่อค้นหาแนวทางที่ให้ความแม่นยำสูงสุดในการระบุความเสี่ยงทางสุขภาพ การทดสอบผ่านระบบ Auto Model ในโปรแกรม Altair AI Studio ช่วยให้สามารถประมวลผลโมเดลทั้ง 3 รูปแบบหลักที่รองรับทั้งงานการจำแนกประเภทและการถดถอยได้อย่างเป็นระบบ ข้อมูลที่ได้จากการทดลองจะถูกนำมาวิเคราะห์เปรียบเทียบทั้งในด้านความถูกต้องเชิงสถิติและประสิทธิภาพด้านเวลาที่ใช้ในการประมวลผลจริง

การคัดเลือกโมเดลที่มีโครงสร้างต่างกันอย่าง Deep Learning, Random Forest และ Decision Tree มีวัตถุประสงค์เพื่อตรวจสอบความสัมพันธ์ของข้อมูลที่มีความซับซ้อนในมิติที่หลากหลาย แบบจำลองแต่ละชนิดจะทำหน้าที่ในการสกัดคุณลักษณะเด่นของพฤติกรรมการบริโภคและกิจกรรมทางกายออกมาเพื่อคาดการณ์ผลกระทบที่มีต่อร่างกาย ผลลัพธ์จากการวิเคราะห์เชิงลึกนี้จะช่วยสร้างความเข้าใจที่ชัดเจนยิ่งขึ้นเกี่ยวกับปัจจัยที่มีอิทธิพลต่อระดับภาวะน้ำหนักเกิน ซึ่งเป็นประโยชน์ต่อการวางแผนการเฝ้าระวังสุขภาพเชิงรุกในระดับบุคคลและประชากรได้อย่างยั่งยืน

3.2.1 การวิเคราะห์แบบจำแนกประเภท (Classification Task)

การวิเคราะห์ในลักษณะนี้มุ่งเน้นการจัดกลุ่มข้อมูลเชิงคุณภาพเพื่อระบุสถานะทางสุขภาพรายบุคคล โดยใช้เกณฑ์มาตรฐานทางการแพทย์ในการแบ่งประเภทระดับภาวะน้ำหนักเกินและโรคอ้วนออกเป็นหมวดหมู่ที่ชัดเจน กระบวนการจำแนกประเภทช่วยให้สามารถคัดกรองบุคคลเข้าสู่ระดับความเสี่ยงที่ถูกต้อง เพื่อประโยชน์ในการวินิจฉัยและวางแนวทางป้องกันโรคแทรกซ้อนที่อาจเกิดขึ้นในอนาคต การดำเนินงานจะอาศัยความสัมพันธ์ระหว่างตัวแปรนำเข้าจำนวน 17 คุณลักษณะในการตัดสินใจจัดหมวดหมู่เป้าหมาย

กลไกการทำงานของภารกิจการจำแนกประเภทอาศัยการเรียนรู้รูปแบบพฤติกรรมสะสมที่มีนัยสำคัญต่อการสะสมไขมันในร่างกาย ระบบจะคำนวณหาจุดตัดสินใจที่มีค่าน้ำหนักสูงสุดในการจำแนกกลุ่มประชากรออกจากกันอย่างสมเหตุสมผลภายใต้เกณฑ์ Classification Error ข้อมูลจากพฤติกรรมการกินอาหารและการมีกิจกรรมทางกายจะถูกประมวลผลเพื่อหาความน่าจะเป็นที่บุคคลหนึ่งจะจัดอยู่ในกลุ่มโรคอ้วนระดับใดระดับหนึ่งอย่างแม่นยำ

การเลือกใช้แนวทางนี้มีเป้าหมายเพื่อสร้างระบบช่วยเหลือบุคลากรทางการแพทย์ในการระบุกลุ่มเสี่ยงได้อย่างรวดเร็วและตรงจุด การจำแนกประเภทไม่ได้แสดงเพียงแค่ผลลัพธ์ว่าอ้วนหรือไม่ แต่ยังแสดงถึงระดับความรุนแรงของสภาวะร่างกายเพื่อให้การช่วยเหลือมีประสิทธิภาพสูงสุด นอกจากนี้ยังสามารถใช้เป็นเครื่องมือคัดกรองในระดับสาธารณสุขเพื่อลดอัตราการเจ็บป่วยและภาระค่าใช้จ่ายในการรักษาโรคไม่ติดต่อเรื้อรังในระยะยาว

3.2.1.1 ตัวแปรเป้าหมายที่ใช้ทำนาย (Classification Targets)

การกำหนดเป้าหมายในการจำแนกประเภทมุ่งเน้นไปที่ข้อมูลสถานะทางร่างกายและปัจจัยแฝงทางกายภาพที่มีลักษณะเป็นหมวดหมู่ชัดเจน เพื่อให้แบบจำลองเรียนรู้วิธีการจัดกลุ่มประชากรตามคุณลักษณะร่วมที่ตรวจพบ ข้อมูลเป้าหมายเหล่านี้ทำหน้าที่เป็นตัวชี้วัดสำคัญในการประเมินระดับความเสี่ยงและลักษณะเฉพาะของบุคคลจากพฤติกรรมการบริโภค โดยมีตัวแปรเป้าหมายหลักดังนี้

3.2.1.1.1 NObeyesdad: ระดับภาวะน้ำหนักเกินและโรคอ้วน แบ่งเป็น 7 ระดับ ตั้งแต่น้ำหนักน้อยไปจนถึงโรคอ้วนขั้นสูงสุด

3.2.1.1.2 family_history_with_overweight: ข้อมูลประวัติสมาชิกในครอบครัวที่มีภาวะน้ำหนักเกิน (ใช่/ไม่ใช่)

3.2.1.1.3 Gender: ข้อมูลเพศของผู้ทำแบบทดสอบ (ชาย/หญิง)

3.2.1.2 Deep Learning (ANN)

การประมวลผลผ่านโครงข่ายประสาทเทียมระดับลึกถูกนำมาใช้เพื่อจัดการกับชุดข้อมูลที่มีความสัมพันธ์ซับซ้อนและมีมิติของข้อมูลที่ทับซ้อนกันอย่างหนาแน่น แบบจำลองนี้มุ่งเน้นการจำลองพฤติกรรมระบบประสาทเพื่อสกัดคุณลักษณะแฝงจากพฤติกรรมการบริโภคที่ส่งผลกระทบต่อเนื่องต่อสภาพร่างกาย ความสามารถในการประมวลผลเชิงลึกช่วยให้ระบบเห็นรูปแบบความสัมพันธ์ที่แบบจำลองพื้นฐานอาจมองข้ามไป

กลไกการทำงานอาศัยการส่งต่อข้อมูลผ่านชั้นนำเข้าข้อมูลไปยังชั้นซ่อนหลายชั้นเพื่อคำนวณค่าน้ำหนักและปรับจูนความแม่นยำผ่านกระบวนการ Backpropagation การทำงานในลักษณะนี้ช่วยให้ระบบสามารถเรียนรู้ลักษณะการกระจายตัวของข้อมูลที่มีความผันผวนสูงได้เป็นอย่างดี จนได้ผลลัพธ์สุดท้ายในชั้นการแสดงผลที่สามารถจำแนกกลุ่มความเสี่ยงโรคอ้วนได้อย่างละเอียดถี่ถ้วนภายใต้เงื่อนไขข้อมูลที่หลากหลาย

เหตุผลสำคัญในการเลือกใช้ Deep Learning คือขีดความสามารถในการเรียนรู้รูปแบบความสัมพันธ์ที่มีลักษณะไม่เป็นเส้นตรง โดยเฉพาะระหว่างปัจจัยทางกรรมพันธุ์และพฤติกรรมการกินอาหารแคลอรีสูง ข้อมูลที่มีความหนาแน่นและซับซ้อนในชุดข้อมูลนี้ต้องการกระบวนการคิดวิเคราะห์ที่สามารถตรวจจับนัยสำคัญของตัวแปรขนาดเล็กได้ การใช้ ANN จึงช่วยยกระดับความแม่นยำในการทำนายภาวะสุขภาพที่มีผลกระทบจากหลายปัจจัยพร้อมกันอย่างมีประสิทธิภาพ

3.2.1.2.1 ข้อดี

3.2.1.2.1.1 มีความสามารถสูงในการเรียนรู้รูปแบบความสัมพันธ์ที่ซับซ้อนและไม่เป็นเส้นตรง

3.2.1.2.1.2 ให้ความแม่นยำสูงเมื่อทำงานกับชุดข้อมูลที่มีความหลากหลายและมีมิติจำนวนมาก

3.2.1.2.1.3 สามารถพัฒนาต่อยอดเพื่อพยากรณ์ทั้งแบบหมวดหมู่และแบบตัวเลขต่อเนื่องได้

3.2.1.2.2 ข้อเสีย

3.2.1.2.2.1 เป็นแบบจำลองในลักษณะ "Black Box" ซึ่งยากต่อการอธิบายเหตุผลในการตัดสินใจเชิงลึก

3.2.1.2.2.1 ใช้เวลาในการฝึกสอนและทรัพยากรในการประมวลผลสูงกว่าแบบจำลองอื่น

3.2.1.3 Random Forest Classifier

การประยุกต์ใช้เทคนิคการเรียนรู้แบบรวมกลุ่มมีเป้าหมายเพื่อสร้างความมั่นคงและความสถิตเสถียรในการพยากรณ์ภายใต้สถานการณ์ที่มีความผันผวนของข้อมูล แนวคิดนี้มุ่งเน้นการแก้ข้อจำกัดของต้นไม้ตัดสินใจเดี่ยวที่มักประสบปัญหาความผิดพลาดจากข้อมูลบางส่วนที่อาจผิดปกติ ทำให้ได้ระบบการจำแนกประเภทที่ให้ผลลัพธ์สม่ำเสมอและมีความแม่นยำในระดับที่น่าเชื่อถือแม้ในกรณีที่ข้อมูลมีการกระจายตัวกว้าง

กระบวนการทำงานเริ่มต้นจากการสุ่มเลือกกลุ่มข้อมูลย่อยและตัวแปรขึ้นมาเพื่อสร้างต้นไม้ตัดสินใจจำนวนมากที่ทำงานเป็นอิสระต่อกัน เมื่อถึงขั้นตอนการแสดงผล ระบบจะทำการลงคะแนนเสียงข้างมากจากต้นไม้ทั้งหมดในระบบเพื่อสรุปคำตอบสุดท้ายที่ได้รับการยอมรับสูงสุด กลไกนี้ช่วยให้ระบบสามารถกำจัดสัญญาณรบกวนในข้อมูลและรักษาความถูกต้องของหมวดหมู่เป้าหมายได้อย่างยอดเยี่ยม

เหตุผลในการเลือกใช้ Random Forest คือความต้องการลดปัญหาการจดจำข้อมูลแม่แบบเกินไป ซึ่งเป็นอุปสรรคสำคัญในการนำโมเดลไปใช้งานจริง ด้วยลักษณะของชุดข้อมูลโรคอ้วนที่มีตัวแปรแวดล้อมจำนวนมาก การรวมการตัดสินใจจากต้นไม้หลายต้นจึงช่วยเพิ่มความแม่นยำในการจำแนกข้อมูลที่มีหลายระดับ ทำให้เป็นแบบจำลองที่ให้ประสิทธิภาพโดดเด่นในการระบุตัวแปรด้านเพศได้อย่างแม่นยำที่สุด

3.2.1.3.1 ข้อดี

3.2.1.3.1.1 ให้ความแม่นยำสูงและมีความเสถียรในการทำนายข้อมูลที่มีความผันผวน

3.2.1.3.1.1 สามารถจัดการกับข้อมูลที่มีความสำคัญของตัวแปรที่หลากหลายได้ดี

3.2.1.3.1.1 ลดโอกาสการเกิดปัญหา Overfitting ได้อย่างมีนัยสำคัญ

3.2.1.3.2 ข้อเสีย

3.2.1.3.2.1 ใช้เวลาในการประมวลผลนานที่สุดเมื่อเทียบกับแบบจำลองอื่น

3.2.1.3.2.1 ความซับซ้อนของแบบจำลองทำให้ยากต่อการนำเสนอแผนภาพการตัดสินใจออกมาในภาพเดียว

3.2.1.4 Decision Tree Classifier

การนำเสนอแนวทางวิเคราะห์ในรูปแบบโครงสร้างต้นไม้ตัดสินใจมีวัตถุประสงค์เพื่อสร้างความโปร่งใสในกระบวนการทำงานของเทคโนโลยี แบบจำลองนี้มุ่งเน้นการถ่ายทอดขั้นตอนการประมวลผลข้อมูลสุขภาพออกมาเป็นลำดับขั้นที่ชัดเจนและสมเหตุสมผล ความเรียบง่ายของโครงสร้างช่วยให้ผู้ใช้งานสามารถติดตามร่องรอยการตัดสินใจของระบบตั้งแต่วรรณะแรกจนถึงผลลัพธ์สุดท้ายได้อย่างเข้าใจง่าย

กลไกการทำงานอาศัยการแบ่งส่วนข้อมูลตามเงื่อนไขของตัวแปรที่มีอิทธิพลต่อผลลัพธ์สูงที่สุดเป็นลำดับ โดยพิจารณาจากเกณฑ์ทางสถิติเพื่อคัดเลือกจุดตัดสินใจที่ดีที่สุด ข้อมูลจะถูกแยกกิ่งก้านออกไปตามเงื่อนไขของพฤติกรรม เช่น ความถี่ในการบริโภคผัก หรือการควบคุมแคลอรี จนเข้าสู่ส่วนสุดท้ายคือใบที่เป็นตัวแทนของระดับความอ้วน กระบวนการนี้ช่วยให้เห็นลำดับความสำคัญของตัวแปรที่มีต่อสุขภาพได้อย่างชัดเจน

เหตุผลหลักในการเลือกใช้ Decision Tree คือความโดดเด่นในด้านความสามารถในการอธิบายผลลัพธ์ซึ่งมีความสำคัญยิ่งในงานวิทยาศาสตร์ข้อมูลสุขภาพ การแสดงแผนภาพการตัดสินใจช่วยให้บุคลากรทางการแพทย์สามารถมองเห็นเงื่อนไขสำคัญที่นำไปสู่ภาวะโรคอ้วนและทำความเข้าใจพฤติกรรมเสี่ยงของผู้ป่วยได้ง่ายขึ้น อีกทั้งยังเป็นโมเดลที่ทำงานได้อย่างรวดเร็วและรักษาความแม่นยำให้อยู่ในเกณฑ์ดีภายใต้เงื่อนไขเวลาที่สั้นที่สุด

3.2.1.4.1 ข้อดี

3.2.1.4.1.1 เป็นแบบจำลองที่อธิบายผลลัพธ์และความหมายของข้อมูลได้ง่ายที่สุด

3.2.1.4.1.2 ใช้เวลาในการประมวลผลน้อยที่สุดและมีความรวดเร็วสูงมาก

3.2.1.4.1.3 เหมาะสำหรับการสื่อสารผลลัพธ์กับบุคคลทั่วไปผ่านแผนภาพต้นไม้

3.2.1.4.2 ข้อเสีย

3.2.1.4.2.1 มีความอ่อนไหวต่อข้อมูลสูง หากข้อมูลเปลี่ยนเพียงเล็กน้อยอาจส่งผลต่อโครงสร้างต้นไม้ทั้งหมด

3.2.1.4.2.2 หากต้นไม้มีความซับซ้อนเกินไปอาจเกิดปัญหาความแม่นยำลดลงในงานจำแนกประเภท

3.2.2 การวิเคราะห์แบบถดถอย (Regression Task)

ภารกิจการวิเคราะห์แบบถดถอยถูกกำหนดขึ้นเพื่อพยากรณ์ข้อมูลเชิงปริมาณที่มีลักษณะเป็นตัวเลขต่อเนื่องและมีความละเอียดสูง เป้าหมายสำคัญคือการคาดการณ์ค่าน้ำหนัก ส่วนสูง และอายุในรูปแบบเชิงลึกซึ่งเป็นข้อมูลพื้นฐานสำคัญในการประเมินสภาวะทางกายภาพรายบุคคล กระบวนการนี้ช่วยให้ผู้ใช้งานสามารถทราบแนวโน้มของตัวเลขร่างกายที่จะเกิดขึ้นจริงภายใต้เงื่อนไขพฤติกรรมและสิ่งแวดล้อมที่กำหนดไว้

การทำงานในโหมดถดถอยมุ่งเน้นไปที่การลดค่าความคลาดเคลื่อนสัมพัทธ์ระหว่างตัวเลขพยากรณ์กับตัวเลขจริงให้เหลือน้อยที่สุด ระบบจะคำนวณหาจุดสมดุลระหว่างตัวแปรอิสระจำนวนมากกับค่าเชิงตัวเลขที่เป็นเป้าหมาย เพื่อสร้างฟังก์ชันการทำนายที่มีความเที่ยงตรง ข้อมูลที่ได้จะเป็นตัวเลขที่มีความละเอียดสูง ช่วยให้สามารถวิเคราะห์แนวโน้มการเติบโตหรือการเพิ่มขึ้นของน้ำหนักได้อย่างต่อเนื่อง

วัตถุประสงค์ของการเลือกใช้ Regression Task คือการสร้างระบบพยากรณ์แนวโน้มสุขภาพส่วนบุคคลที่สามารถบอกตัวเลขน้ำหนักที่ควรจะเป็นในอนาคต ข้อมูลเชิงปริมาณเหล่านี้มีประโยชน์อย่างมากในการติดตามความคืบหน้าของการปรับเปลี่ยนพฤติกรรมและกำหนดเป้าหมายทางสุขภาพที่เป็นรูปธรรม นอกจากนี้ยังช่วยให้สามารถวิเคราะห์ผลกระทบของอายุและส่วนสูงที่สัมพันธ์กับพฤติกรรมการมีกิจกรรมทางกายได้อย่างสมจริงที่สุด

3.2.2.1 ตัวแปรเป้าหมายที่ใช้ทำนาย (Regression Targets)

การกำหนดเป้าหมายในการวิเคราะห์แบบถดถอยมุ่งเน้นไปที่ค่าตัวเลขทางสรีรวิทยาที่มีความต่อเนื่อง เพื่อให้ได้ผลลัพธ์เชิงปริมาณที่แม่นยำสำหรับงานด้านการติดตามสุขภาพ ข้อมูลเหล่านี้ทำหน้าที่เป็นดัชนีชี้วัดสำคัญในการเปรียบเทียบประสิทธิภาพของแบบจำลองผ่านเกณฑ์ความคลาดเคลื่อนสัมพัทธ์ โดยมีตัวแปรเป้าหมายหลักดังนี้

3.2.2.1.1 Age: ข้อมูลอายุเชิงปริมาณรายปี

3.2.2.1.2 Weight: ข้อมูลน้ำหนักตัวหน่วยกิโลกรัม

3.2.2.1.3 Height: ข้อมูลส่วนสูงหน่วยเมตร

3.2.2.2 Decision Tree Regressor

การประยุกต์ใช้แผนผังต้นไม้ในรูปแบบการคำนวณเชิงปริมาณมีจุดประสงค์เพื่อสร้างระบบพยากรณ์ที่รวดเร็วและมีความแม่นยำสูงสำหรับตัวแปรเป้าหมายที่เป็นตัวเลข แนวคิดนี้อาศัยความสามารถในการจำแนกกลุ่มข้อมูลตามเงื่อนไขเพื่อหาค่าเฉลี่ยตัวเลขที่เป็นตัวแทนที่ดีที่สุดของกลุ่มนั้นๆ ทำให้เป็นแบบจำลองที่ให้ผลลัพธ์ที่จับต้องได้และสะท้อนความจริงของข้อมูลสรีรวิทยาในรูปแบบเชิงปริมาณได้อย่างมีประสิทธิภาพสูงสุด

กลไกการทำงานอาศัยการแบ่งส่วนข้อมูลตามเกณฑ์ทางสถิติที่เหมาะสม แล้วทำการพยากรณ์ค่าเป้าหมายโดยพิจารณาจากค่าเฉลี่ยเชิงปริมาณภายในกลุ่มข้อมูลย่อย

กระบวนการนี้ส่งผลให้ได้ค่าพยากรณ์เชิงตัวเลขที่มีความคลาดเคลื่อนต่ำมากเมื่อทดสอบกับข้อมูลน้ำหนักและสัดส่วนร่างกายรายบุคคล โครงสร้างที่ชัดเจนของต้นไม้ยังช่วยให้สามารถระบุลำดับความสำคัญของปัจจัยที่ส่งผลต่อการเปลี่ยนแปลงของน้ำหนักตัวได้ทันที

เหตุผลที่เลือกใช้ Decision Tree Regressor สืบเนื่องมาจากผลการทดสอบที่แสดงให้เห็นว่านี่คือโมเดลที่ให้ความแม่นยำสูงสุดอย่างเป็นเอกฉันท์ในงานพยากรณ์ข้อมูลเชิงตัวเลข ด้วยค่า Relative Error ที่ต่ำที่สุดรวมถึงความเร็วในการประมวลผลที่ยอดเยี่ยม ทำให้เป็นเครื่องมือที่เหมาะสมที่สุดสำหรับการพยากรณ์น้ำหนักตัว ส่วนสูง และอายุ ช่วยลดช่องว่างความผิดพลาดระหว่างค่าที่ทำนายได้กับค่าจริงได้อย่างดีเยี่ยมภายใต้ทรัพยากรที่จำกัด

3.2.2.2.1 ข้อดี

3.2.2.2.1.1ให้ความแม่นยำสูงสุดเป็นเอกฉันท์ในงานด้านการพยากรณ์เชิงตัวเลข

3.2.2.2.1.2 ใช้เวลาในการประมวลผลน้อยที่สุดและมีความรวดเร็วสูงมาก

3.2.2.2.1.3 ให้ความแม่นยำสูงสุดโดยเฉพาะในการพยากรณ์น้ำหนักและส่วนสูง

3.2.2.2.2 ข้อเสีย

3.2.2.2.2.1 ค่าพยากรณ์อาจมีความแปรปรวนหากข้อมูลมีการกระจายตัวกว้างเกินไป

3.2.2.2.2.2 มีความอ่อนไหวต่อข้อมูลสูง หากข้อมูลเปลี่ยนเพียงเล็กน้อยอาจส่งผลต่อโครงสร้างต้นไม้ทั้งหมด

3.2.2.3 Random Forest Regressor

การนำเทคนิคการรวมกลุ่มของต้นไม้ตัดสินใจมาใช้ในงานถดถอยมีวัตถุประสงค์เพื่อสร้างค่าประมาณการณ์ที่มีเสถียรภาพและมีความคลาดเคลื่อนต่ำจากการเฉลี่ยผลลัพธ์ แบบจำลองนี้มุ่งเน้นการสร้างความมั่นคงให้กับการพยากรณ์ค่าน้ำหนักตัวภายใต้ความหลากหลายของพฤติกรรมการบริโภคสะสม ทำให้ได้ผลลัพธ์เชิงตัวเลขที่มีความละเอียดและมีความน่าเชื่อถือสูงกว่าการประมวลผลจากต้นไม้ตัดสินใจเพียงแหล่งเดียว

กลไกการทำงานอาศัยการรวบรวมผลการทำนายค่าตัวเลขต่อเนื่องจากต้นไม้ตัดสินใจจำนวนมาก แล้วนำมาหาค่าเฉลี่ยรวมเพื่อให้ได้ค่าพยากรณ์สุดท้ายที่มีความเที่ยงตรงมากขึ้น การทำงานร่วมกันของต้นไม้หลายต้นช่วยให้ระบบสามารถกำจัดความคลาดเคลื่อนที่เกิดจากข้อมูลที่ผิดปกติได้อย่างเป็นธรรมชาติ กลไกนี้ช่วยสร้างค่าพยากรณ์เชิงตัวเลขที่มีความต่อเนื่องและสะท้อนแนวโน้มสภาพร่างกายได้อย่างมั่นคงสม่ำเสมอ

เหตุผลสำคัญในการเลือกใช้คือความต้องการสร้างแบบจำลองที่ให้ผลลัพธ์มีความเสถียรและแม่นยำสูงสำหรับการพยากรณ์ค่าทางสรีรวิทยา ด้วยการเฉลี่ยค่าการทำนายจากต้นไม้หลายต้น ทำให้ลดอิทธิพลของสัญญาณรบกวนในข้อมูลได้ดีกว่าแบบจำลองเดี่ยว ระบบจึงสามารถพยากรณ์ค่าน้ำหนักตัวจริงได้อย่างมั่นคงภายใต้เงื่อนไขปัจจัยกิจกรรมทางกายที่ผันแปรในชีวิตประจำวัน

3.2.2.3.1 ข้อดี

3.2.2.3.1.1 ให้ผลลัพธ์ที่มีความเสถียรและแม่นยำสูงจากการเฉลี่ยผลรวม

3.2.2.3.1.2 ช่วยลดความคลาดเคลื่อนและให้ผลลัพธ์ที่มั่นคงกว่าต้นไม้เดี่ยว

3.2.2.3.1.3 จัดการกับความสัมพันธ์ระหว่างตัวแปรเชิงปริมาณที่ซับซ้อนได้ดี

3.2.2.3.2 ข้อเสีย

3.2.2.3.2.1 ใช้เวลาในการประมวลผลนานกว่า Decision Tree เนื่องจากความซับซ้อนของระบบ

3.2.2.3.2.2 ความยากในการอธิบายความสัมพันธ์เชิงลึกของผลลัพธ์แก่ผู้ใช้ทั่วไป

3.2.2.4 Deep Learning (Regression Mode)

การประยุกต์ใช้โครงข่ายประสาทในงานถดถอยมุ่งเน้นการหาฟังก์ชันทางคณิตศาสตร์ที่ซับซ้อนเพื่อพยากรณ์แนวโน้มการเปลี่ยนแปลงของร่างกายในระดับเชิงลึก แนวคิดนี้มีวัตถุประสงค์เพื่อศึกษาความสัมพันธ์ระหว่างพฤติกรรมการกินและกิจกรรมทางกายที่มีผลต่อตัวเลขร่างกายโดยตรง ความสามารถในการพยากรณ์แนวโน้มช่วยให้เห็นภาพรวมของสภาพร่างกายในอนาคตได้อย่างละเอียดอ่อนและสมจริงที่สุด

กลไกการทำงานอาศัยชั้นของโหนดในการเรียนรู้ความสัมพันธ์ของตัวแปรนำเข้าเชิงซ้อนเพื่อประมวลผลแนวโน้มค่าน้ำหนักที่ควรจะเป็นตามหลักการสัดส่วนร่างกาย ระบบจะพิจารณาจากมิติของข้อมูลกิจกรรมทางกายเชิงลึกและพฤติกรรมการบริโภคเพื่อหาจุดสมดุลของตัวเลขเป้าหมาย กระบวนการปรับปรุงค่าน้ำหนักอย่างต่อเนื่องช่วยให้โมเดลเข้าถึงค่าความแม่นยำที่ละเอียดและสามารถพยากรณ์แนวโน้มค่าน้ำหนักได้อย่างลึกซึ้ง

เหตุผลสำคัญที่เลือกใช้คือความต้องการพยากรณ์แนวโน้มร่างกายโดยพิจารณาจากสัดส่วนร่างกายและปัจจัยกิจกรรมทางกายในเชิงลึกอย่างถี่ถ้วน ข้อมูลที่ได้จาก ANN สามารถนำมาใช้ประเมินความเสี่ยงต่อภาวะสุขภาพในอนาคตผ่านตัวเลขคาดการณ์ที่มีความต่อเนื่อง การใช้โครงข่ายประสาทเทียมจึงช่วยเปิดมิติใหม่ในการวิเคราะห์แนวโน้มสุขภาพรายบุคคลผ่านข้อมูลเชิงปริมาณที่ซับซ้อนได้อย่างมีนัยสำคัญ

3.2.2.4.1 ข้อดี

3.2.2.4.1.1 สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนของตัวแปรตัวเลขจำนวนมากได้ดี

3.2.2.4.1.2 พยากรณ์แนวโน้มที่ละเอียดอ่อนของร่างกายได้อย่างลึกซึ้งผ่านข้อมูลมิติสูง

3.2.2.4.1.3 ให้ความแม่นยำสูงในการทำนายแนวโน้มค่าน้ำหนักหากมีการปรับจูนที่เหมาะสม

3.2.2.4.2 ข้อเสีย

3.2.2.4.2.1 จำเป็นต้องมีการปรับจูนพารามิเตอร์อย่างละเอียดเพื่อป้องกันความคลาดเคลื่อนสูง

3.2.2.4.2.2 ใช้ทรัพยากรประมวลผลและเวลาในการวิจัยสูงกว่าวิธีอื่นในงานถดถอย

บทที่ 4

ผลการวิจัย

4.1 ผลการวิจัยและวิเคราะห์ข้อมูล (Results and Discussion)

จากการทดสอบและเปรียบเทียบประสิทธิภาพของแบบจำลอง Machine Learning ทั้ง 3 รูปแบบ เพื่อพยากรณ์ระดับความเสี่ยงทางสุขภาพและค่าน้ำหนักตัวเชิงปริมาณ พบว่าโครงสร้างของแบบจำลองแต่ละชนิดมีผลต่อความแม่นยำและความเร็วในการประมวลผลอย่างมีนัยสำคัญ. โดยในงานจำแนกประเภท (Classification) แบบจำลองมีความสามารถในการระบุกลุ่มเสี่ยงจากพฤติกรรมการบริโภคได้อย่างถูกต้อง และในงานถดถอย (Regression) สามารถแสดงผลลัพธ์เป็นค่าตัวเลขที่มีความคลาดเคลื่อนต่ำ. การเลือกใช้แบบจำลองที่เหมาะสมจึงขึ้นอยู่กับความซับซ้อนของโจทย์และทรัพยากรด้านเวลาที่มีอยู่ ดังข้อสรุปในบทเรียนที่ผ่านมา

4.1.1 การวิเคราะห์แบบจำแนกประเภท (Classification)

จากการทดสอบและเปรียบเทียบประสิทธิภาพของแบบจำลองทั้ง 3 รูปแบบ เพื่อพยากรณ์ตัวแปรเป้าหมายที่แตกต่างกัน 3 ลักษณะ ได้แก่ ระดับภาวะน้ำหนักเกิน ประวัติครอบครัว และเพศ พบว่าแบบจำลองแต่ละชนิดมีจุดเด่นและความสามารถในการจำแนกที่แตกต่างกันตามโครงสร้างข้อมูล โดยระดับความแม่นยำรวมและค่าความคลาดเคลื่อน (Classification Error) มีความผันแปรอย่างมีนัยสำคัญตามความซับซ้อนของตัวแปรเป้าหมาย ผลลัพธ์จากการทดลองชี้ให้เห็นว่าปัจจัยพฤติกรรมการบริโภคและกิจกรรมทางกายสามารถนำมาใช้จัดหมวดหมู่กลุ่มเสี่ยงทางสุขภาพได้อย่างมีประสิทธิภาพ โดยมีผลสรุปดังนี้

4.1.1.1 การพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วน (NObeyesdad)

การวิเคราะห์ในส่วนนี้มุ่งเน้นไปที่ตัวแปรเป้าหมายหลักคือระดับความอ้วน (NObeyesdad) ซึ่งแบ่งออกเป็น 7 ระดับตามเกณฑ์มาตรฐานทางสุขภาพ โดยการทดสอบ

ผ่านระบบ Auto Model ได้ทำการเปรียบเทียบประสิทธิภาพของแบบจำลองที่แตกต่างกัน 3 รูปแบบ เพื่อหาโมเดลที่มีความแม่นยำสูงสุดในการจำแนกกลุ่มตัวอย่างจากพฤติกรรมการบริโภคและปัจจัยทางกายภาพ ผลการวิเคราะห์แสดงให้เห็นว่าระดับความแม่นยำมีความผันแปรตามโครงสร้างทางสถิติของแต่ละอัลกอริทึมอย่างมีนัยสำคัญ

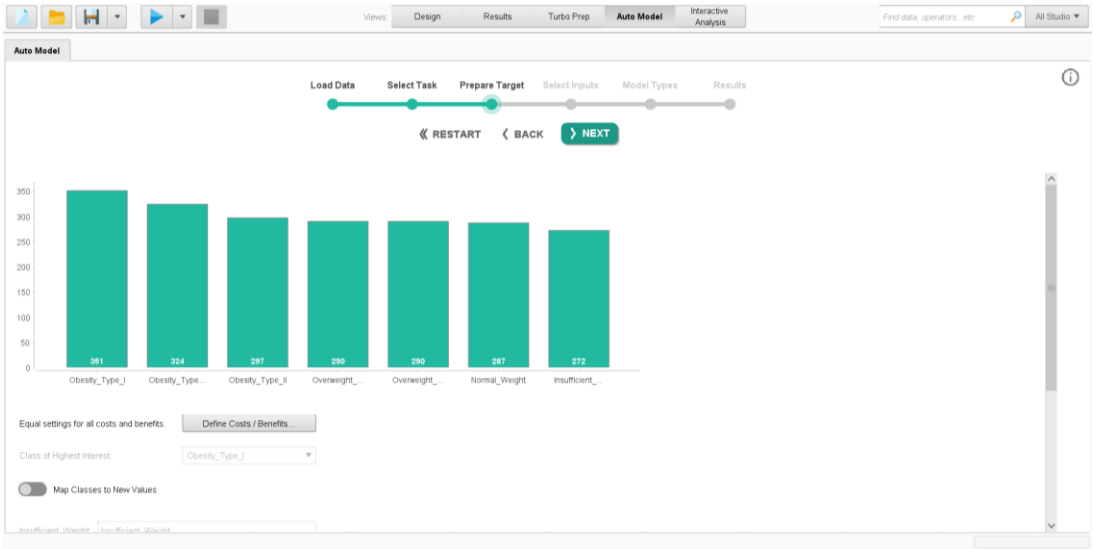

ภาพที่ 4.1 การกำหนดตัวแปรเป้าหมาย (Prepare Target) และตรวจสอบการกระจายตัวของข้อมูลของ**การพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วน (NObeyesdad)**

4.1.1.1.1 ผลเปรียบเทียบความถูกต้องของแต่โมเดลที่เลือกใช้

4.1.1.1.1.1 Decision Tree แบบจำลองต้นไม้ตัดสินใจแสดงกลไกการจำแนกข้อมูลโดยใช้เกณฑ์ทางสถิติเพื่อแบ่งกลุ่มตามปัจจัยที่มีอิทธิพลมากที่สุด เช่น พฤติกรรมการกินอาหารแคลอรีสูงหรือประวัติครอบครัว จากการวิเคราะห์พบว่า Decision Tree เป็นโมเดลที่ให้ค่าความแม่นยำ (Accuracy) สูงที่สุดในการพยากรณ์ระดับความอ้วน โดยมีค่าความแม่นยำอยู่ที่ 83.4% และมีค่าความผิดพลาด (Classification Error) เพียง 16.6%

นอกจากความแม่นยำที่โดดเด่นแล้ว Decision Tree ยังแสดงประสิทธิภาพในด้านเวลาการประมวลผลที่ยอดเยี่ยม โดยใช้เวลาการประมวลผลรวมเพียง 16 วินาที ซึ่งถือเป็นแบบจำลองที่ได้รับรางวัล "เหรียญทอง" ในด้านความแม่นยำและความเร็วจากระบบ เหมาะสำหรับการสื่อสารผลลัพธ์ผ่านแผนภาพต้นไม้ที่เข้าใจง่ายสำหรับผู้ใช้งานทั่วไป

4.1.1.1.1.2 Random Forest อัลกอริทึมนี้ใช้เทคนิคการเรียนรู้แบบรวมกลุ่มโดยการสร้างต้นไม้ตัดสินใจจำนวนมากและทำการลงคะแนนเสียงเพื่อให้ได้ผลลัพธ์ที่มีความเสถียรสูงสุด จากการทดสอบพบว่า Random Forest ให้ความแม่นยำในระดับดีรองลงมา โดยมีค่าความแม่นยำอยู่ที่ 79.0% และมีค่า Classification Error อยู่ที่ 21.0% ซึ่งช่วยลดปัญหาการเกิด Overfitting ได้ดีกว่าการใช้ต้นไม้เพียงต้นเดียว

อย่างไรก็ตาม ข้อจำกัดสำคัญของ Random Forest ในการทดลองครั้งนี้คือระยะเวลาการประมวลผลที่นานที่สุด โดยใช้เวลาทั้งหมดถึง 4 นาที 26 วินาที เนื่องจากความซับซ้อนของโครงสร้างแบบจำลองที่ประกอบด้วยต้นไม้จำนวนมาก ทำให้การวิเคราะห์สรุปผลต้องใช้ทรัพยากรคอมพิวเตอร์สูงกว่าแบบจำลองอื่นอย่างเห็นได้ชัด

41.1.1.1.3 Deep Learning การประยุกต์ใช้โครงข่ายประสาทเทียมระดับลึกมุ่งเน้นการตรวจจับความสัมพันธ์เชิงลึกที่มีลักษณะไม่เป็นเส้นตรงระหว่างปัจจัยนำเข้าทั้งหมด ผลการวิเคราะห์พบว่า Deep Learning มีค่าความแม่นยำอยู่ที่ 76.3% และมีค่า Classification Error อยู่ที่ 23.7% โดยมีค่าเบี่ยงเบนมาตรฐานอยู่ที่ $\pm 2.0\%$ ซึ่งจัดเป็นระดับความแม่นยำที่ยอมรับได้สำหรับการพยากรณ์ข้อมูลที่มีความซับซ้อนสูง

ในด้านระยะเวลาการประมวลผล Deep Learning ใช้เวลาไปทั้งสิ้น 30 วินาที ซึ่งจัดว่าทำงานได้รวดเร็วอยู่ในระดับกลาง แม้โมเดลนี้จะมีข้อดีในการสกัด

คุณลักษณะแฝงของข้อมูลได้ดีเยี่ยม แต่ในชุดข้อมูลนี้ความแม่นยำยังคงน้อยกว่าโมเดลประเภทต้นไม้ตัดสินใจทั้งสองรูปแบบ

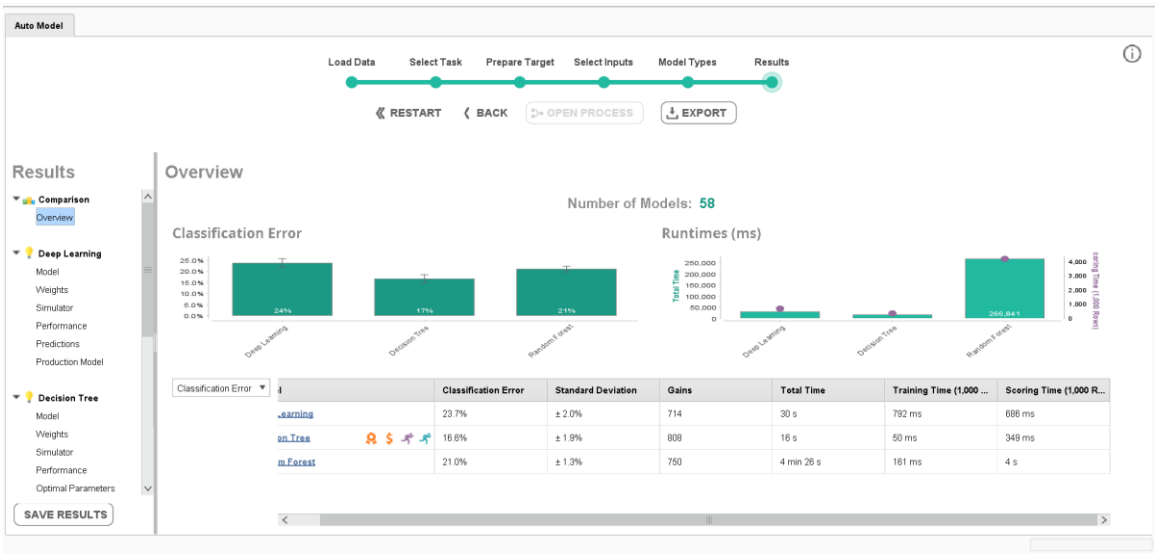

ภาพที่ 4.2 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของแต่ละโมเดลของการพยากรณ์ระดับภาวะน้ำหนักเกิน (NObeyesdad)

4.1.1.1.2 ผลความคลาดเคลื่อนแบบสัมบูรณ์ของแต่โมเดลที่เลือกใช้

4.1.1.1.2.1 Decision Tree จากการวิเคราะห์เชิงสถิติผ่าน Confusion Matrix พบว่า Decision Tree สามารถจำแนกกลุ่ม "Obesity Type III" และ "Obesity Type I" ได้อย่างแม่นยำสูงมาก โดยมีค่า Class Recall ในกลุ่มโรคอ้วนระดับรุนแรงสูงสุดถึง 100.00% ความผิดพลาดส่วนใหญ่เกิดขึ้นระหว่างการจำแนกระหว่างกลุ่มน้ำหนักปกติ (Normal Weight) และกลุ่มน้ำหนักเกิน (Overweight) ที่มีลักษณะพฤติกรรมคาบเกี่ยวกัน

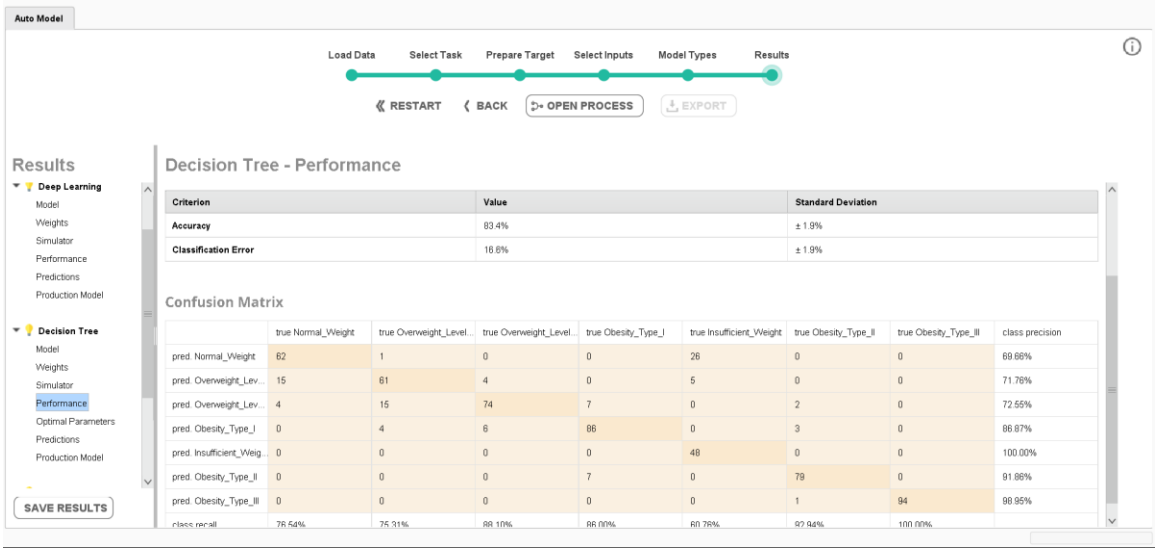

ภาพที่ 4.3 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Decision Tree

4.1.1.1.2.2 Random Forest ผลการวิเคราะห์ความคลาดเคลื่อนของ Random Forest แสดงให้เห็นถึงความเสถียรในการจำแนกกลุ่ม "Obesity Type III" โดยมีความแม่นยำรายกลุ่ม (Class Precision) สูงถึง 98.94% แม้จะมีค่าความผิดพลาดรวมมากกว่า Decision Tree แต่พบว่ามีความคลาดเคลื่อนในการทำนายกลุ่มคนน้ำหนักน้อย (Insufficient Weight) น้อยมาก โดยสามารถทำนายได้ถูกต้องเกือบสมบูรณ์

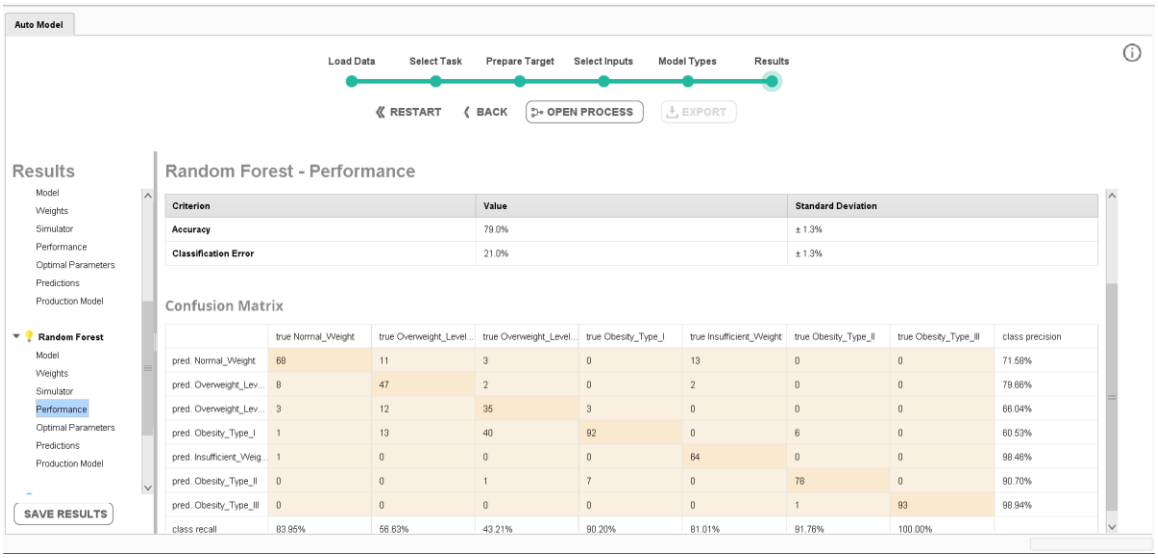

ภาพที่ 4.4 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Random Forest

4.1.1.1.2.3 Deep Learning สำหรับความคลาดเคลื่อนของ Deep Learning พบว่ามีจุดเด่นในการจำแนกกลุ่ม "Obesity Type III" และ "Obesity Type II" ได้ดีมาก โดยมีค่า Recall อยู่ที่ระดับ 98% ขึ้นไป อย่างไรก็ตาม โมเดลนี้มีความคลาดเคลื่อนสูงในกลุ่ม "Overweight Level II" ที่มีค่า Recall ต่ำเพียง 28.58% เนื่องจากโครงข่ายประสาทพยายามสกัดปัจจัยที่ทับซ้อนกันแต่ข้อมูลในกลุ่มนี้อาจมีความคลุมเครือเชิงพฤติกรรมมากกว่ากลุ่มอื่น

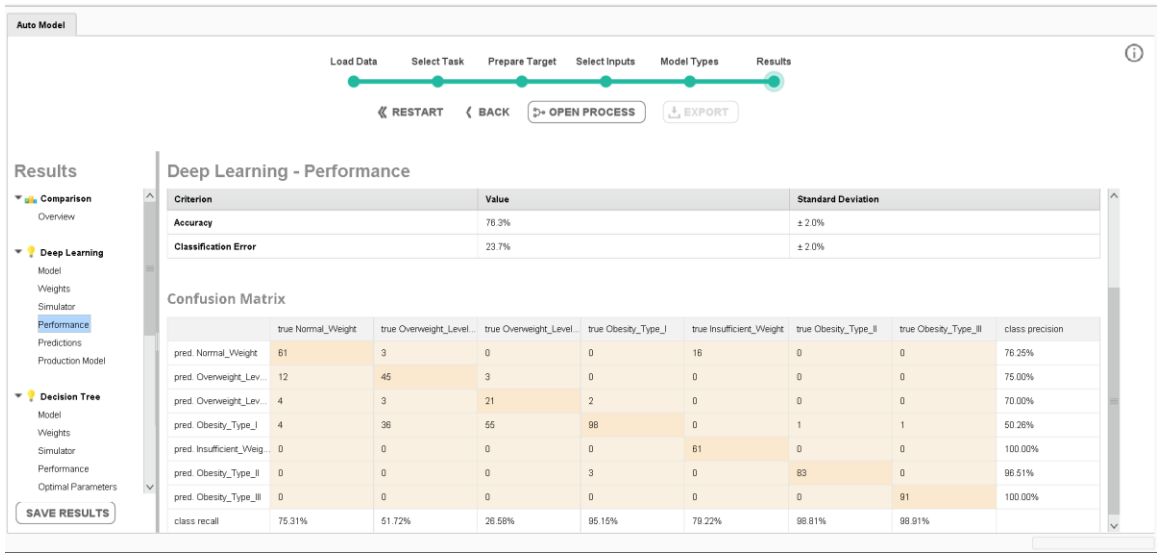

ภาพที่ 4.5 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Deep Learning

4.1.1.2 การพยากรณ์ประวัติสมาชิกในครอบครัวที่มีภาวะน้ำหนักเกิน (family_history_with_overweight)

การวิเคราะห์ในส่วนนี้มีเป้าหมายเพื่อจำแนกปัจจัยทางพันธุกรรมของผู้เข้ารับการทดสอบ โดยพยากรณ์ว่าบุคคลนั้นมีประวัติสมาชิกในครอบครัวที่มีภาวะน้ำหนักเกินหรือไม่ (ใช่/ไม่ใช่) การทดสอบเปรียบเทียบระหว่างแบบจำลองพบว่าปัจจัยด้านพฤติกรรมสุขภาพสามารถสะท้อนความสัมพันธ์ทางพันธุกรรมได้อย่างมีนัยสำคัญ โดยผลลัพธ์ในภาพรวมชี้ให้เห็นว่า Deep Learning และ Random Forest ให้ประสิทธิภาพที่โดดเด่นกว่าในงานจำแนกประเภทแบบสองกลุ่ม (Binary Classification) สำหรับปัจจัยนี้

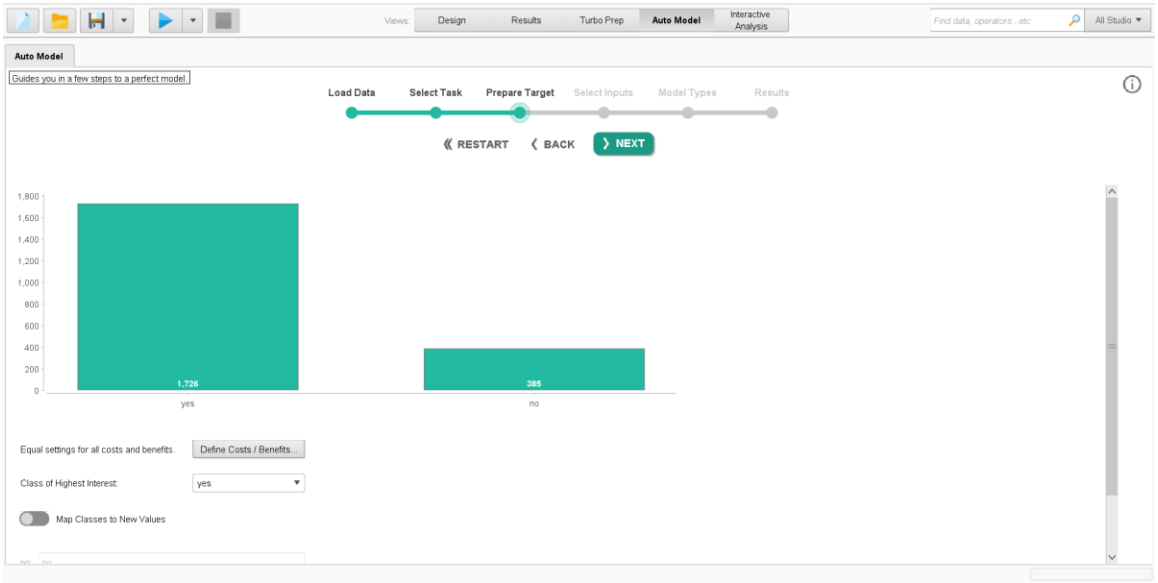

ภาพที่ 4.6 การกำหนดตัวแปรเป้าหมาย (Prepare Target) และตรวจสอบการกระจายตัวของข้อมูลของการพยากรณ์ระดับภาวะน้ำหนักเกิน (NObeyesdad)

4.1.1.2.1 ผลเปรียบเทียบความถูกต้องของแต่โมเดลที่เลือกใช้

4.1.1.2.1.1 Decision Tree แบบจำลองต้นไม้ตัดสินใจใช้การแบ่งเกณฑ์เงื่อนไขจากพฤติกรรมหลักเพื่อคัดกรองประวัติทางครอบครัว จากผลการทดสอบพบว่า Decision Tree มีค่าความแม่นยำ (Accuracy) อยู่ที่ 84.8% และมีค่าความผิดพลาดในการจำแนกประเภท (Classification Error) อยู่ที่ 15.2% แม้จะมีความแม่นยำในระดับที่ดี แต่ยังคงสูงกว่าแบบจำลองอื่นในกลุ่มการทดสอบนี้

ในด้านความเร็วการประมวลผล Decision Tree ยังคงรักษาจุดเด่นที่ความรวดเร็วสูงสุด โดยใช้เวลารวมเพียง 7 วินาที อย่างไรก็ตาม เมื่อพิจารณาจากค่า AUC ที่ 85.6% พบว่าขีดความสามารถในการแยกแยะระหว่างกลุ่มที่มีและไม่มีประวัติครอบครัวทำได้น้อยกว่าแบบจำลองซับซ้อนอย่าง Random Forest

4.1.1.2.1.2 Random Forest สำหรับการพยากรณ์ประวัติครอบครัว Random Forest แสดงประสิทธิภาพที่เสถียรมาก โดยได้รับค่าความแม่นยำสูงถึง 87.9% และมีค่า Classification Error ต่ำเพียง 12.1% แบบจำลองนี้ยังได้รับสัญลักษณ์ "เหรียญทอง" และ "เครื่องหมายดอลลาร์" จากระบบ ซึ่งบ่งบอกถึงความเป็น Best Model ที่คุ้มค่าที่สุดในเชิงความแม่นยำเทียบกับทรัพยากรที่ใช้

นอกจากนี้ Random Forest ยังให้ค่า AUC สูงถึง 93.8% และค่า Recall ที่ 93.7% ซึ่งแสดงถึงขีดความสามารถในการค้นพบกลุ่มที่มีประวัติครอบครัวได้อย่างแม่นยำเกือบทั้งหมด อย่างไรก็ตาม ระยะเวลาในการประมวลผลยังคงสูงกว่าเพื่อนร่วมกลุ่ม โดยใช้เวลาไปทั้งสิ้น 1 นาที 31 วินาที

4.1.1.2.1.3 Deep Learning โครงข่ายประสาทเทียมระดับลึกให้ผลลัพธ์ที่ยอดเยี่ยมใกล้เคียงกับ Random Forest โดยมีค่าความแม่นยำอยู่ที่ 87.4% และค่า Classification Error ที่ 12.6% แบบจำลองนี้สามารถจับความสัมพันธ์ที่ซับซ้อนระหว่างพฤติกรรมการกินและปัจจัยแฝงทางพันธุกรรมได้ดีเป็นพิเศษ

Deep Learning ใช้เวลาในการประมวลผล 15 วินาที ซึ่งเร็วกว่า Random Forest อย่างเห็นได้ชัดในงานชุดนี้ แม้ค่า Accuracy จะเป็นรองเพียงเล็กน้อย แต่ค่า Precision ที่ 92.1% ยืนยันว่าโมเดลมีความน่าเชื่อถือสูงมากเมื่อทำนายว่าบุคคลนั้นมีประวัติครอบครัวที่มีภาวะน้ำหนักเกิน

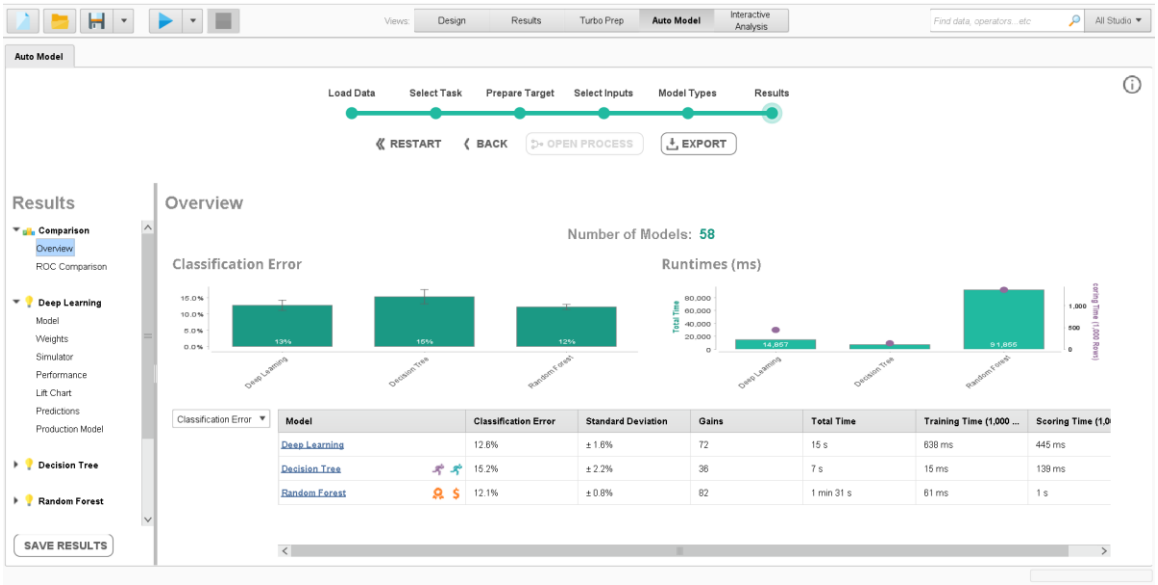

ภาพที่ 4.7 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของแต่ละโมเดล ของ การพยากรณ์ประวัติครอบครัว (family_history_with_overweight)

ภาพที่ 4.8 กราฟ ROC Comparison แสดงขีดความสามารถในการแยกแยะข้อมูลของแต่ละแบบจำลองของการพยากรณ์ประวัติครอบครัว (family_history_with_overweight)

4.1.1.2.2 ผลความคลาดเคลื่อนแบบสัมบูรณ์ของแต่โมเดลที่เลือกใช้

4.1.1.2.2.1 Decision Tree ผลความคลาดเคลื่อนจาก Confusion Matrix ของ Decision Tree พบว่ามีความแม่นยำในกลุ่มที่มีประวัติครอบครัว (true yes) สูงถึง 96.15% แต่กลับมีความผิดพลาดสูงมากในกลุ่มที่ไม่มีประวัติ (true no) โดยมีค่า Recall เพียง 33.64% หมายความว่าโมเดลมีแนวโน้มที่จะทายว่าทุกคนมีประวัติครอบครัวไว้ก่อนจนเกิดความคลาดเคลื่อนในกลุ่ม "no" อย่างรุนแรง

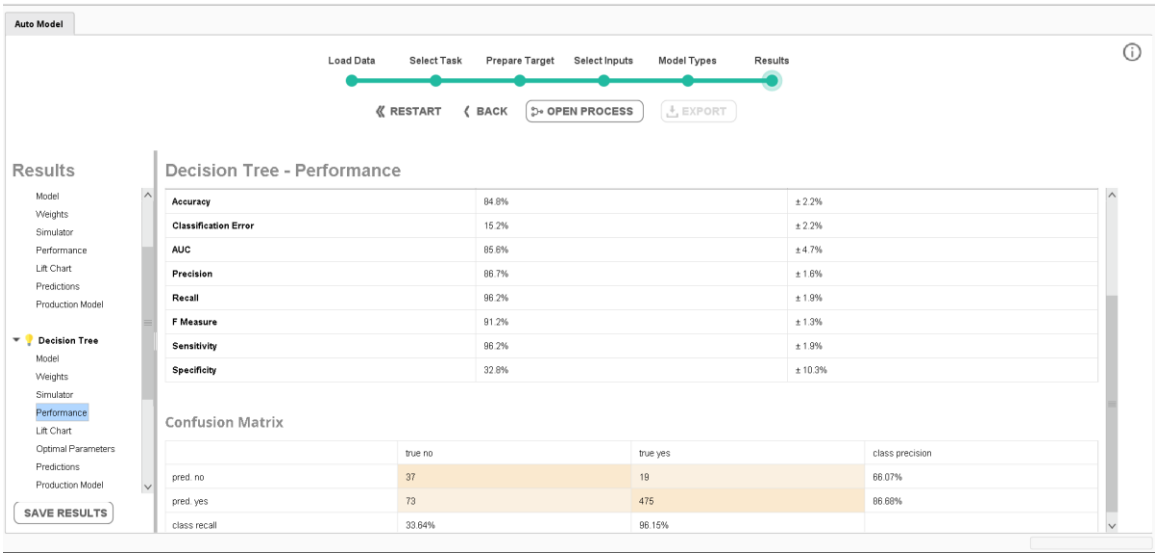

ภาพที่ 4.9 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Decision Tree

4.1.1.2.2.2 Random Forest สำหรับ Random Forest มีความสมดุลในการจำแนกได้ดีกว่าอย่างเห็นได้ชัด โดยมีค่า Recall ในกลุ่มที่มีประวัติครอบครัวสูงถึง 93.66% และสามารถทำนายกลุ่มที่ไม่มีประวัติได้ถูกต้องมากขึ้นด้วยค่า Recall 63.16% ความคลาดเคลื่อนสัมบูรณ์ส่วนใหญ่อยู่ที่การระบุกลุ่ม "no" ผิดเป็น "yes" จำนวน 42 รายการ

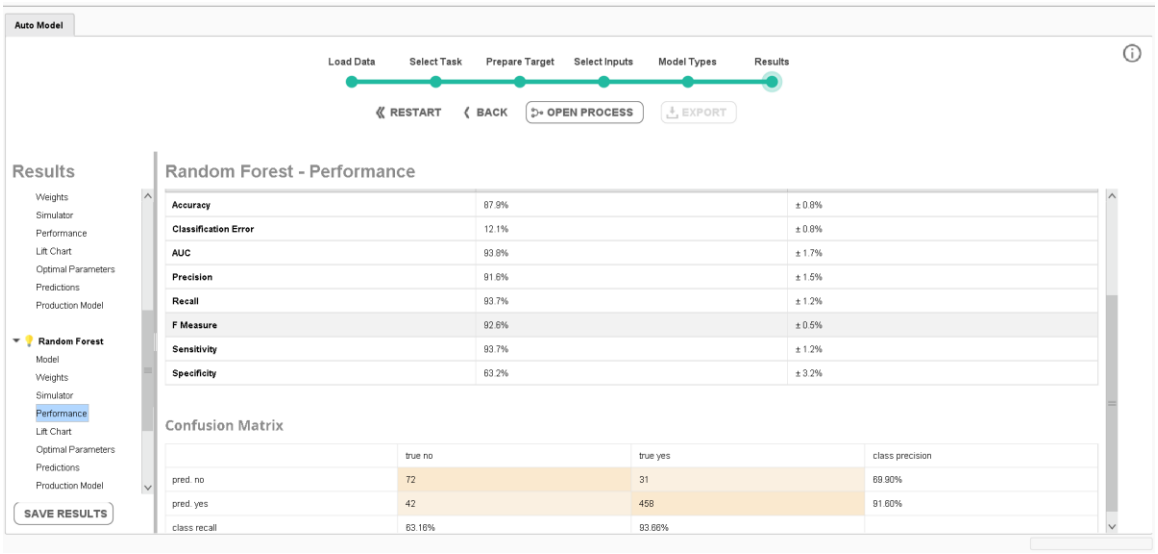

ภาพที่ 4.10 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Random Forest

4.1.1.2.2.3 Deep Learning Deep Learning ให้รูปแบบความคลาดเคลื่อนที่ใกล้เคียงกับ Random Forest โดยสามารถระบุผู้ที่มีประวัติครอบครัวได้ถูกต้อง (true yes) ถึง 92.45% และระบุผู้ที่ไม่มีประวัติ (true no) ได้ถูกต้อง 65.18% แม้จะมีการทายกลุ่ม "no" ผิดเป็น "yes" อยู่ 39 รายการ แต่ถือเป็นแบบจำลองที่มีความสมดุลระหว่างสองกลุ่มข้อมูลสูงที่สุดในบรรดาโมเดลที่เลือกใช้

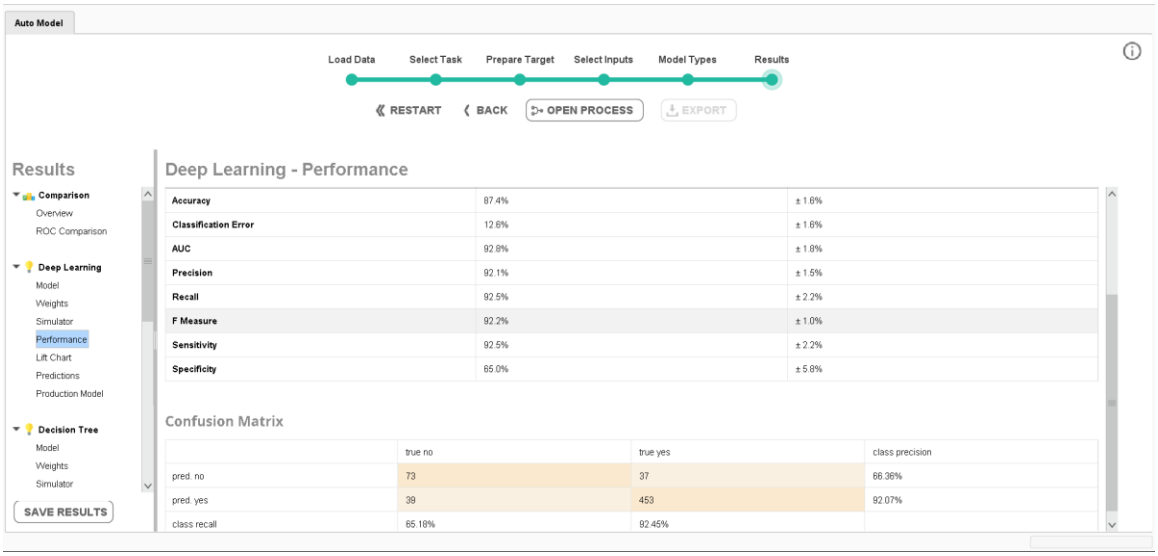

ภาพที่ 4.11 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Deep Learning

4.1.1.3 การพยากรณ์เพศของผู้ทำแบบทดสอบ (Gender)

การวิเคราะห์ในส่วนนี้มุ่งเน้นการใช้คุณลักษณะทางกายภาพและพฤติกรรมการบริโภคเพื่อจำแนกเพศของผู้ทำแบบทดสอบ ผลการทดสอบแสดงให้เห็นว่าแบบจำลองส่วนใหญ่สามารถระบุความแตกต่างระหว่างเพศชายและเพศหญิงได้ด้วยความแม่นยำที่สูงมาก โดยมีค่าความคลาดเคลื่อนในการจำแนกประเภท (Classification Error) ที่ต่ำกว่าการพยากรณ์ระดับภาวะน้ำหนักเกิน. ผลลัพธ์เชิงเปรียบเทียบชี้ให้เห็นว่า Random Forest และ Deep Learning เป็นกลุ่มแบบจำลองที่มีประสิทธิภาพสูงสุดสำหรับงานชุดนี้

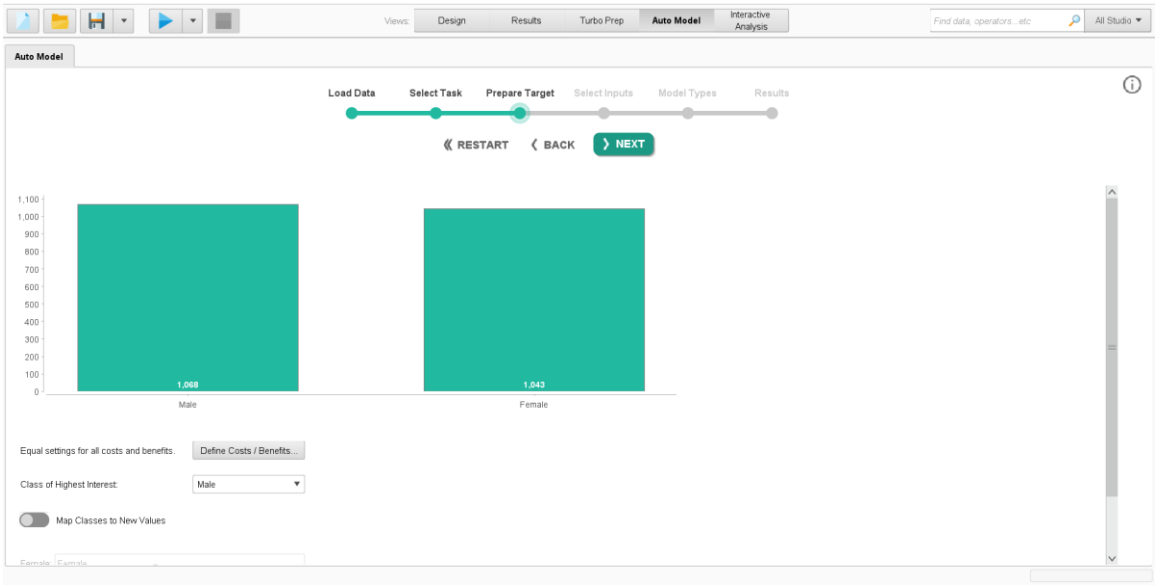

ภาพที่ 4.12 การกำหนดตัวแปรเป้าหมาย (Prepare Target) และตรวจสอบการกระจายตัวของข้อมูลของ การพยากรณ์เพศของผู้ทำแบบทดสอบ (Gender)

4.1.1.3.1 ผลเปรียบเทียบความถูกต้องของแต่โมเดลที่เลือกใช้

4.1.1.3.1.1 Decision Tree แบบจำลองต้นไม้ตัดสินใจใช้กฎการแบ่งข้อมูลตามปัจจัยทางกายภาพเป็นหลักเพื่อแยกแยะเพศ. จากการวิเคราะห์พบว่า Decision Tree มีค่าความแม่นยำ (Accuracy) อยู่ที่ 86.9% และมีค่า Classification Error อยู่ที่ 13.1% ซึ่งถือว่าอยู่ในระดับที่ดี. อย่างไรก็ตาม หากพิจารณาจากค่าความรวดเร็วในการประมวลผล Decision Tree ยังคงครองสถิติเร็วที่สุดโดยใช้เวลาเพียง 8 วินาที.

เมื่อพิจารณาค่าทางสถิติอื่น ๆ พบว่า Decision Tree มีค่าความแม่นยำรายกลุ่ม (Precision) อยู่ที่ 86.5% และมีค่าความระลึก (Recall) อยู่ที่ 87.8%. แม้จะทำงานได้รวดเร็วแต่ขีดความสามารถในการแยกแยะข้อมูล (AUC) อยู่ที่ 92.0% ซึ่งยังน้อยกว่าแบบจำลองอื่นในกลุ่มทดลองเดียวกัน.

4.1.1.3.1.2 Random Forest สำหรับการพยากรณ์เพศ Random Forest แสดงผลลัพธ์ที่ยอดเยี่ยมด้วยความแม่นยำรวมที่สูงถึง 89.1% และมีค่า Classification Error ต่ำเพียง 10.9%. แบบจำลองนี้ได้รับการจัดอันดับเป็นแบบจำลองที่มีความคุ้มค่าและให้ผลลัพธ์เสถียรที่สุด โดยได้รับค่า AUC สูงถึง 96.3%.

Random Forest มีค่าความไว (Sensitivity) อยู่ที่ 85.9% และมีค่าความเฉพาะเจาะจง (Specificity) ที่ 92.4%. แม้จะให้ผลลัพธ์ที่น่าเชื่อถือสูง แต่จุดด้อยเพียงอย่างเดียวคือระยะเวลาการประมวลผลรวมที่นานที่สุดคือ 1 นาที 30 วินาที เนื่องด้วยโครงสร้างการทำงานแบบกลุ่มต้นไม้ตัดสินใจ.

4.1.1.3.1.3 Deep Learning โครงข่ายประสาทเทียมระดับลึกครองตำแหน่งแบบจำลองที่แม่นยำที่สุด (Best Model) ในการจำแนกเพศ โดยมีค่าความแม่นยำสูงที่สุดถึง 90.1% และมีค่า Classification Error ต่ำที่สุดเพียง 9.9%. แบบจำลองนี้ได้รับรางวัลเหรียญทองจากระบบเนื่องจากให้ผลลัพธ์ที่เป็นเลิศในเชิงวิเคราะห์.

ในด้านเวลาการประมวลผล Deep Learning ใช้เวลาไปทั้งสิ้น 15 วินาที ซึ่งเร็วกว่า Random Forest ถึง 6 เท่า. ด้วยค่าความแม่นยำรายกลุ่ม (Precision) ที่ 91.8% และค่า AUC ที่ 95.9% ยืนยันว่าโมเดลนี้สามารถสกัดคุณลักษณะแฝงเพื่อระบุเพศได้อย่างมีประสิทธิภาพสูงสุด

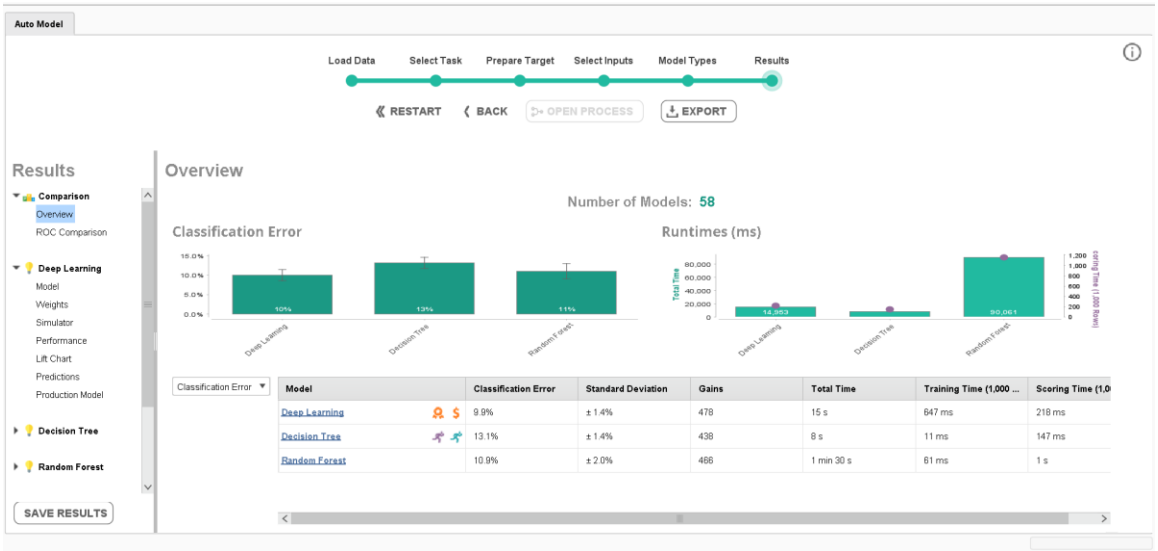

ภาพที่ 4.13 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของแต่ละโมเดลของการพยากรณ์เพศ (Gender)

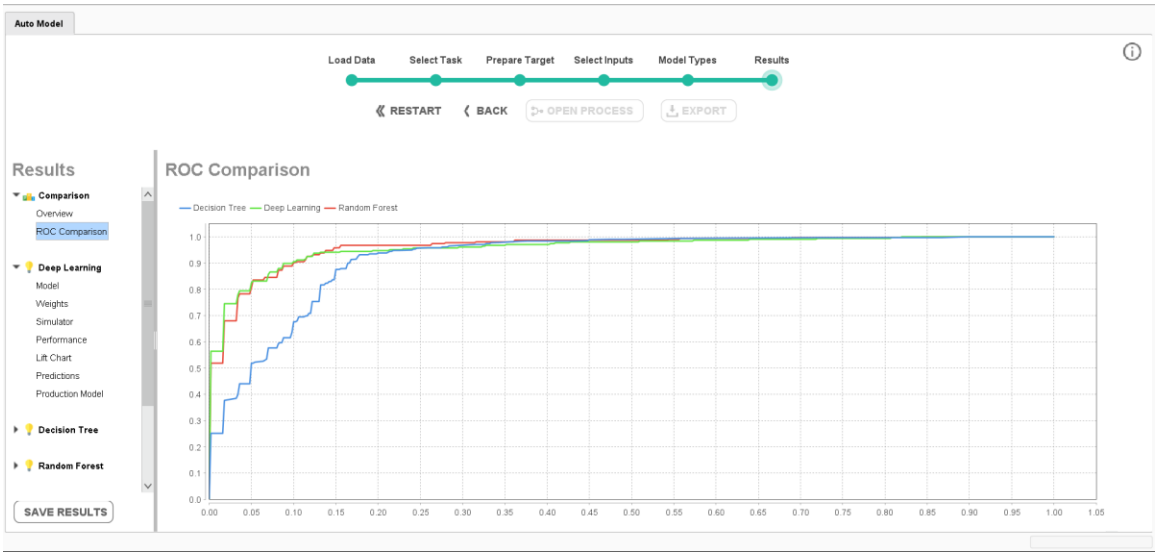

ภาพที่ 4.14 กราฟ ROC Comparison แสดงขีดความสามารถในการแยกแยะข้อมูลของแต่ละแบบจำลองของการพยากรณ์เพศ (Gender)

4.1.1.3.2 ผลความคลาดเคลื่อนแบบสัมบูรณ์ของแต่โมเดลที่เลือกใช้

4.1.1.3.2.1 Decision Tree ผลความคลาดเคลื่อนจาก Confusion Matrix ของ Decision Tree พบว่ามีความแม่นยำในการจำแนกเพศหญิง (true Female) ได้ถูกต้อง 256 รายการ คิดเป็นค่า Recall 85.91% และเพศชาย (true Male) ได้ถูกต้อง 268 รายการ คิดเป็นค่า Recall 87.87%. ความผิดพลาดส่วนใหญ่มาจากการทายเพศชายผิดเป็นเพศหญิงจำนวน 37 รายการ.

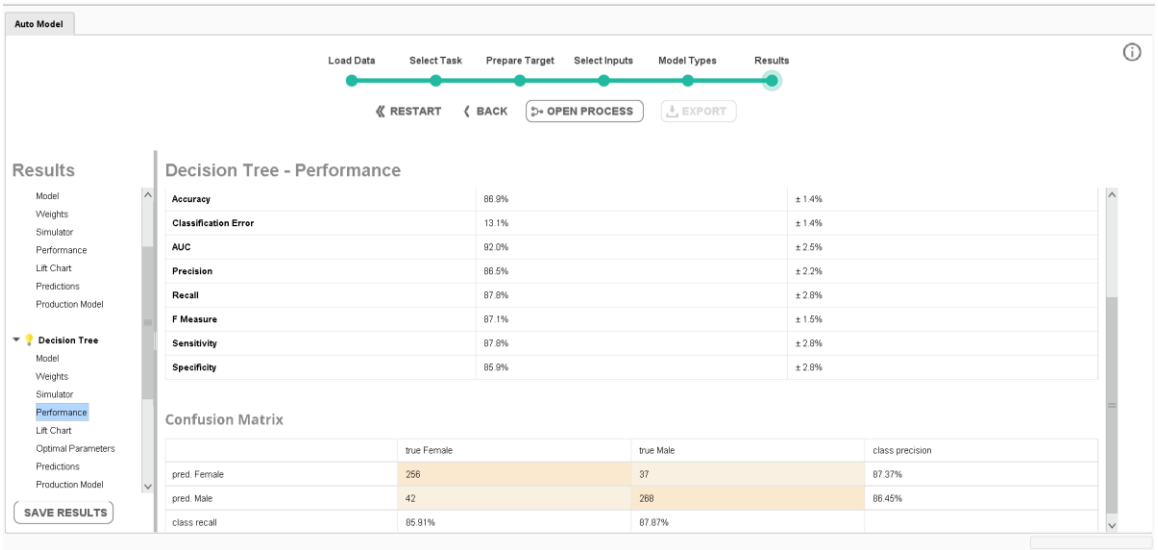

ภาพที่ 4.15 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Decision Tree

4.1.1.3.2.2 Random Forest ความคลาดเคลื่อนของ Random Forest แสดงให้เห็นถึงความแม่นยำในเพศหญิงที่สูงมาก โดยสามารถทำนายถูกต้องได้ถึง 276 รายการ คิดเป็นค่า Recall 92.31%. อย่างไรก็ตาม โมเดลนี้มีความคลาดเคลื่อนในกลุ่มเพศชายมากกว่าเพศหญิง โดยมีการทำนายเพศชายผิดพลาดเป็นเพศหญิงจำนวน 43 รายการ.

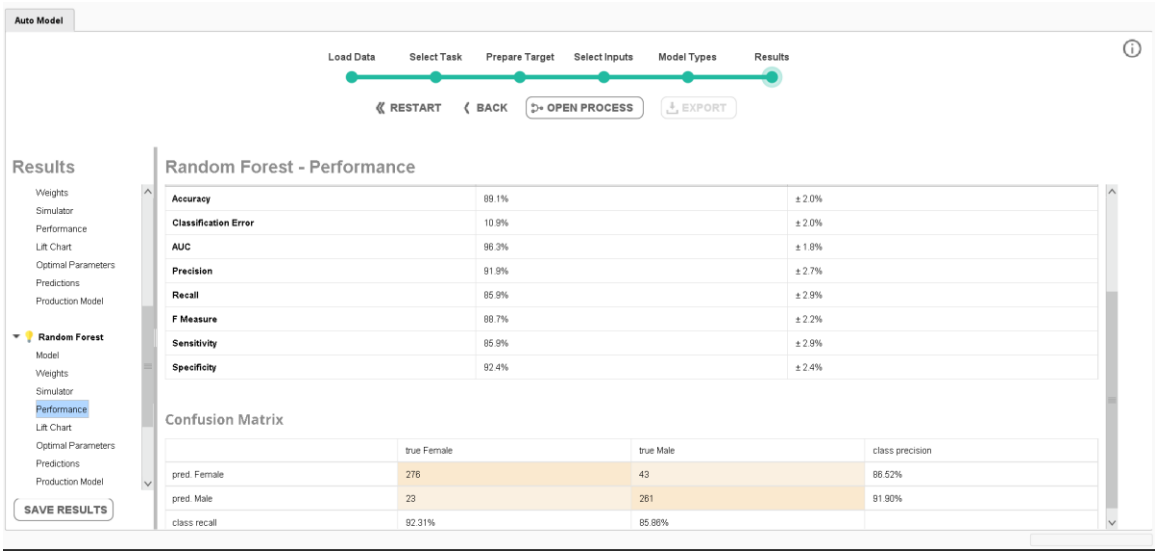

ภาพที่ 4.16 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Random Forest

4.1.1.3.2.3 Deep Learning ให้ผลลัพธ์ความคลาดเคลื่อนสัมบูรณ์ที่ดีที่สุด โดยสามารถระบุเพศหญิงได้ถูกต้อง 275 รายการ (Recall 91.97%) และระบุเพศชายได้ถูกต้องสูงที่สุดคือ 268 รายการ (Recall 88.16%). เมื่อเปรียบเทียบในภาพรวมจะเห็นได้ว่าโมเดลนี้มีจำนวนรายการที่ผิดพลาดรวมน้อยที่สุด โดยทายผิดรวมเพียง 60 รายการจากข้อมูลทั้งหมด

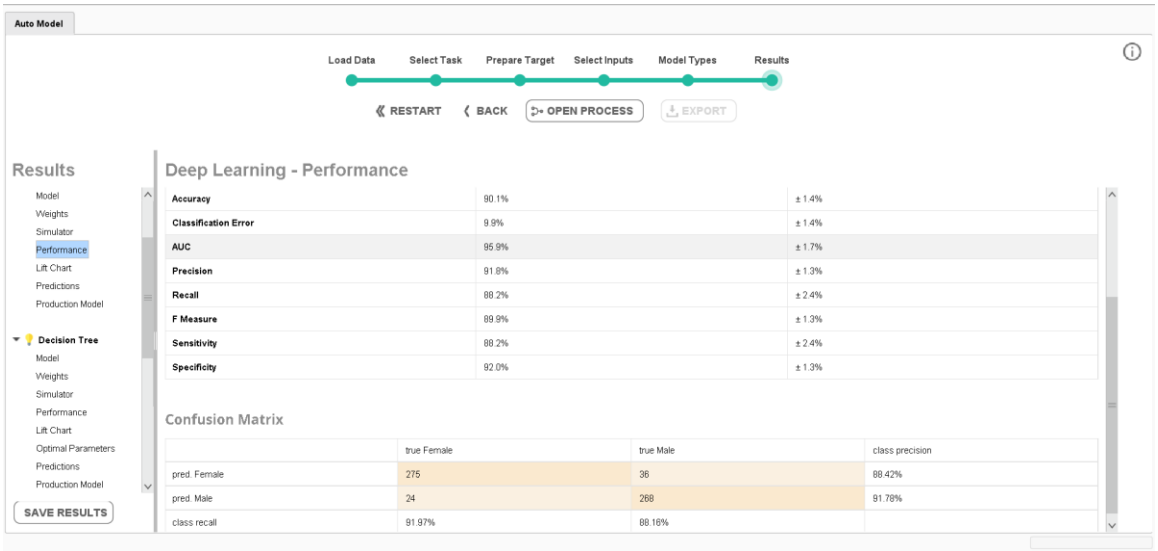

ภาพที่ 4.17 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Deep Learning

4.1.2 สรุปโมเดลที่เหมาะสมที่สุดของการวิเคราะห์แบบจำแนกประเภท (Classification)

หากพิจารณาจากดัชนีชี้วัดรอบด้านทั้งในด้านความแม่นยำ (Accuracy) และความเร็วในการประมวลผล (Total Time) พบว่าโมเดลที่มีความเหมาะสมที่สุดจะแปรเปลี่ยนไปตามลักษณะของโจทย์ที่ต้องการวิเคราะห์ สำหรับการพยากรณ์ที่มีความซับซ้อนสูง 7 ระดับอย่าง ระดับภาวะน้ำหนักเกิน (NObeyesdad) แบบจำลอง Decision Tree คือทางเลือกที่ดีที่สุดเนื่องจากครองตำแหน่ง "เหรียญทอง" ด้วยค่า Classification Error ต่ำที่สุดที่ 16.6% และประมวลผลได้รวดเร็วที่สุดเพียง 16 วินาที ในขณะที่งานทำนาย เพศ (Gender) แบบจำลอง Deep Learning กลับให้ประสิทธิภาพที่เหนือกว่าด้วยค่า Classification Error ต่ำสุดเพียง 9.9% ภายใต้เวลาประมวลผลที่สั้นเพียง 15 วินาที

โดยสรุปแล้ว หากเน้นความคุ้มค่าและประสิทธิภาพเชิงเวลา Decision Tree จัดเป็นโมเดลที่เหมาะสมที่สุดสำหรับการใช้งานในระบบที่ต้องการผลลัพธ์แบบทันทีและอธิบายขั้นตอนการตัดสินใจได้ชัดเจน แต่หากต้องการความแม่นยำสูงสุดในงานจำแนกประเภทแบบสองกลุ่ม (Binary)

และงานที่มีปัจจัยแฝงซับซ้อนอย่างประวัติครอบครัวหรือเพศ Deep Learning และ Random Forest จะเป็นตัวเลือกที่มีความน่าเชื่อถือสูงกว่า โดยเฉพาะ Random Forest ที่มีค่า AUC สูงที่สุดในเกือบทุกภารกิจ แม้จะต้องแลกมาด้วยระยะเวลาในการประมวลผลที่นานกว่าโมเดลอื่นหลายเท่าตัวก็ตาม

4.1.3 การวิเคราะห์แบบถดถอย (Regression)

สำหรับการทดลองเปรียบเทียบประสิทธิภาพของแบบจำลองทั้ง 3 รูปแบบ เพื่อพยากรณ์ตัวแปรเป้าหมายเชิงปริมาณที่แตกต่างกัน 3 ลักษณะ ได้แก่ อายุ (Age) น้ำหนัก (Weight) และส่วนสูง (Height) พบว่าแบบจำลองส่วนใหญ่สามารถให้ผลลัพธ์ที่แม่นยำสูง โดยมีค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) อยู่ในระดับที่ต่ำมาก. กลไกการพยากรณ์เชิงตัวเลขในภารกิจนี้ช่วยให้สามารถระบุแนวโน้มและสัดส่วนทางกายภาพที่แท้จริงซึ่งสัมพันธ์กับพฤติกรรมการบริโภคและกิจกรรมทางกายได้อย่างชัดเจน. จากผลการประมวลผลเชิงเปรียบเทียบภายใต้เกณฑ์มาตรฐานสถิติเดียวกัน พบข้อสรุปดังนี้

4.1.3.1 การพยากรณ์อายุ (Age)

การวิเคราะห์ในส่วนนี้มุ่งเน้นไปที่การพยากรณ์ค่าอายุซึ่งเป็นข้อมูลเชิงตัวเลขต่อเนื่อง (Regression) เพื่อศึกษาความสัมพันธ์ระหว่างปัจจัยทางกายภาพและพฤติกรรมการบริโภคที่ส่งผลต่อช่วงอายุของกลุ่มตัวอย่าง. การทดสอบผ่านระบบ Auto Model ได้ใช้เกณฑ์ความคลาดเคลื่อนสัมพัทธ์ (Relative Error) เป็นตัวชี้วัดหลักในการเปรียบเทียบประสิทธิภาพของแบบจำลองทั้ง 3 รูปแบบ. ผลการวิเคราะห์ชี้ให้เห็นว่าปัจจัยด้านอายุมีความผันแปรสูง แต่แบบจำลองประเภทต้นไม้ตัดสินใจยังคงสามารถทำนายค่าได้ใกล้เคียงกับข้อมูลจริงมากที่สุด

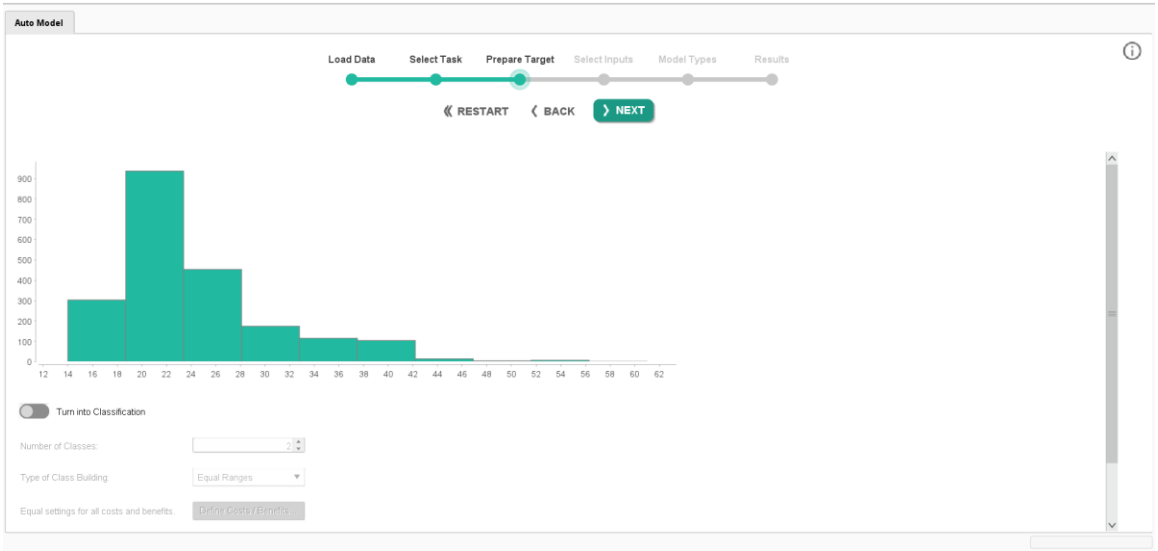

ภาพที่ 4.18 การกำหนดตัวแปรเป้าหมาย (Prepare Target) และตรวจสอบการกระจายตัวของข้อมูลของ การพยากรณ์อายุ (Age)

4.1.3.1.1 ผลเปรียบเทียบความถูกต้องของแต่โมเดลที่เลือกใช้

4.1.3.1.1.1 Decision Tree แบบจำลอง Decision Tree แสดงประสิทธิภาพที่โดดเด่นที่สุดในงานพยากรณ์อายุ โดยมีค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) ต่ำที่สุดเพียง 6.8% และมีค่าเบี่ยงเบนมาตรฐานอยู่ที่ ± 0.8%. ความแม่นยำนี้ส่งผลให้โมเดลได้รับสัญลักษณ์ "เหรียญทอง" และสัญลักษณ์ "นักวิ่ง" บ่งบอกถึงความเป็นเลิศทั้งในด้านความถูกต้องและเวลาการประมวลผล.

ในด้านความรวดเร็ว Decision Tree ใช้เวลาในการประมวลผลรวมเพียง 742 มิลลิวินาที ซึ่งเร็วกว่าแบบจำลองอื่นอย่างเห็นได้ชัด. กลไกการแบ่งส่วนข้อมูลตามเกณฑ์อายุช่วยให้โมเดลสามารถจับกลุ่มช่วงอายุที่มีพฤติกรรมคล้ายคลึงกันได้อย่างรวดเร็วและแม่นยำภายใต้ทรัพยากรที่จำกัด.

4.1.3.1.1.2 Random Forest สำหรับการพยากรณ์อายุ Random Forest ให้ผลลัพธ์ที่มีความแม่นยำสูงเป็นอันดับสอง โดยมีค่า Relative Error อยู่ที่ 7.6%

และมีค่าเบี่ยงเบนมาตรฐานต่ำที่สุดคือ ± 0.4% แสดงถึงความเสถียรของคำตอบที่ได้จากต้นไม้ตัดสินใจหลายต้น. แม้จะให้ผลลัพธ์ที่มั่นคง แต่ค่าความคลาดเคลื่อนยังคงสูงกว่า Decision Tree เล็กน้อย.

ในส่วนของระยะเวลาการประมวลผล Random Forest ใช้เวลาไปทั้งสิ้น 4 วินาที ซึ่งเป็นเวลาที่นานที่สุดในกลุ่มการทดสอบนี้. เนื่องจากต้องสร้างและประมวลผลต้นไม้จำนวนมากเพื่อหาค่าเฉลี่ยของอายุ ทำให้ความเร็วในการแสดงผลลัพธ์ลดลงเมื่อเทียบกับโมเดลพื้นฐาน

4.1.3.1.1.3 Deep Learning แบบจำลองโครงข่ายประสาทเทียมให้ค่าความคลาดเคลื่อนสัมพัทธ์สูงสุดในการพยากรณ์อายุอยู่ที่ 8.9% พร้อมค่าเบี่ยงเบนมาตรฐาน ± 0.9%. แม้ Deep Learning จะมีความสามารถในการเรียนรู้ความสัมพันธ์ที่ซับซ้อน แต่สำหรับตัวแปรอายุในชุดข้อมูลนี้ โมเดลอาจเผชิญกับปัญหาการปรับจูนพารามิเตอร์ที่ยังไม่เข้าถึงจุดที่เหมาะสมที่สุด

Deep Learning ใช้เวลาในการประมวลผลรวม 4 วินาที ซึ่งเท่ากับ Random Forest. อย่างไรก็ตาม หากพิจารณาในด้านความคุ้มค่าเทียบกับความแม่นยำที่ได้รับ พบว่าแบบจำลองนี้ยังไม่สามารถดึงศักยภาพออกมาได้ดีเท่าที่ควรในภารกิจการพยากรณ์ค่าตัวเลขของอายุ

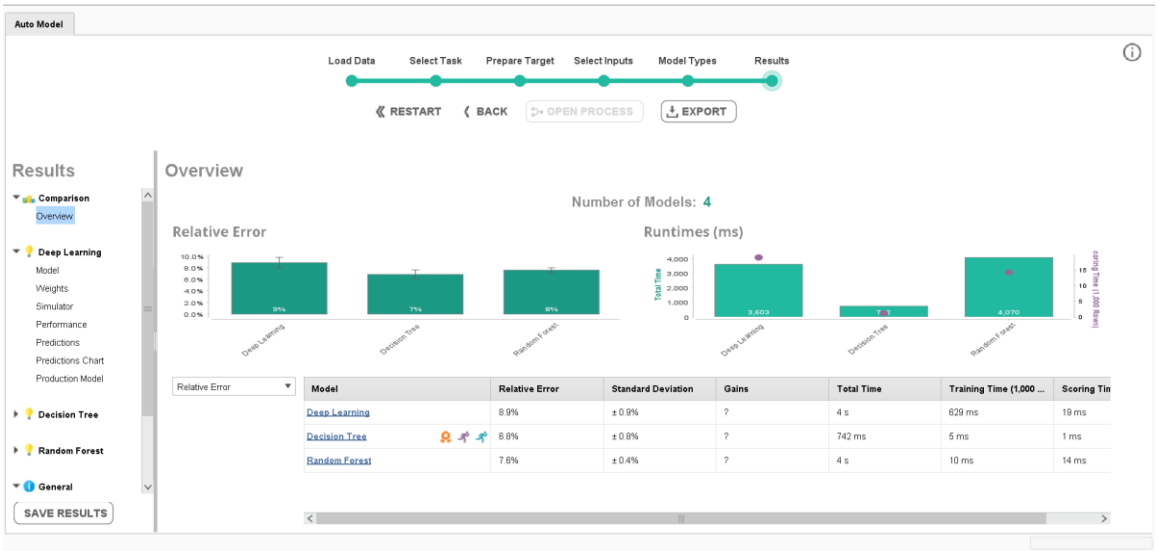

ภาพที่ 4.19 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของแต่ละโมเดลของการพยากรณ์อายุ (Age)

4.1.3.1.2 ผลความคลาดเคลื่อนแบบสัมบูรณ์ของแต่โมเดลที่เลือกใช้

4.1.3.1.2.1 Decision Tree จากการวิเคราะห์ความคลาดเคลื่อนด้วยค่า Root Mean Squared Error (RMSE) พบว่า Decision Tree มีค่าความผิดพลาดอยู่ที่ 3.665 หน่วยอายุ. ค่าความคลาดเคลื่อนนี้ถือว่าต่ำที่สุด ซึ่งแสดงให้เห็นว่าช่วงอายุที่ทำนายได้มีความผิดเพี้ยนไปจากอายุจริงเพียงเล็กน้อยในแต่ละรายการข้อมูล

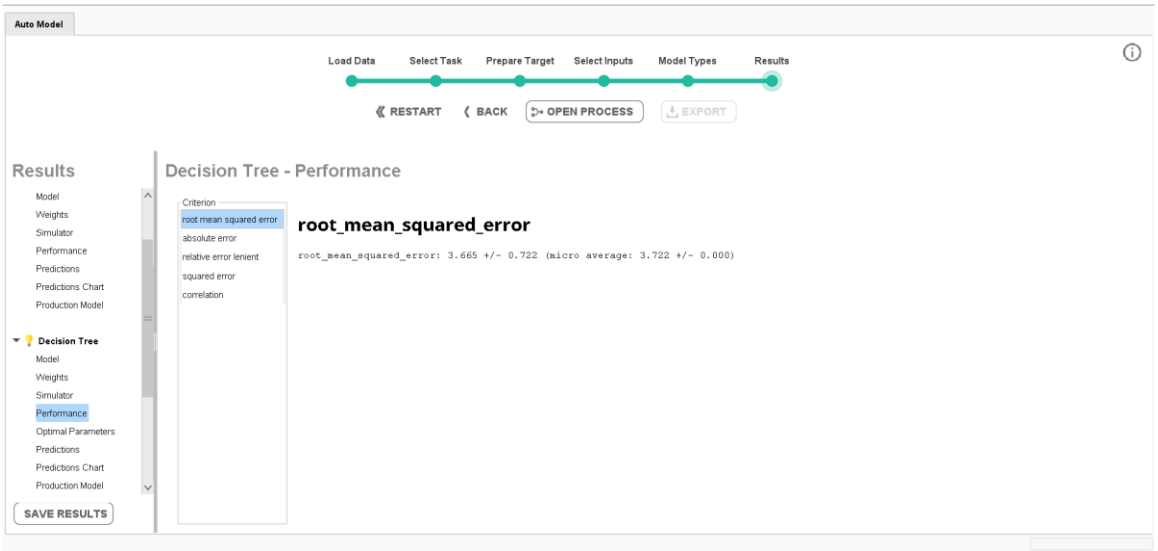

ภาพที่ 4.20 ตารางการวัดประสิทธิภาพโมเดล (Performance)แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Decision Tree

4.1.3.1.2.2 Random Forest ผลความคลาดเคลื่อนสัมบูรณ์ของ Random Forest ให้ค่า RMSE อยู่ที่ 3.424. แม้ว่าในด้าน Relative Error จะแพ้ Decision Tree แต่ค่า RMSE ที่ต่ำกว่านี้บ่งบอกว่าในภาพรวมสัมบูรณ์ Random Forest สามารถจัดการกับค่าเบี่ยงเบนของข้อมูลอายุในบางรายการได้ดีกว่า ลดความเสี่ยงจากการพยากรณ์อายุที่ผิดพลาดอย่างรุนแรง.

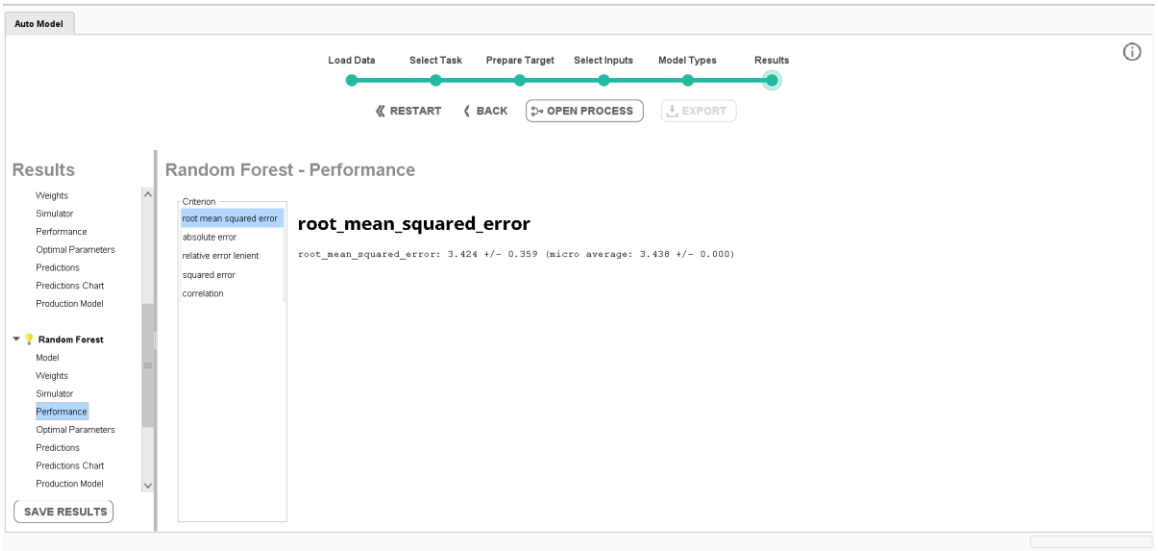

ภาพที่ 4.21 ตารางการวัดประสิทธิภาพโมเดล (Performance)แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล ของ Random Forest

4.1.3.1.2.3 Deep Learning สำหรับ Deep Learning พบค่าความคลาดเคลื่อนสัมบูรณ์สูงสุด โดยมีค่า RMSE อยู่ที่ 3.678. ผลลัพธ์นี้ยืนยันว่าโครงข่ายประสาทเทียมมีการกระจายตัวของความผิดพลาดในแต่ละโหนดข้อมูลที่กว้างกว่าแบบจำลองประเภทต้นไม้ ทำให้ความแม่นยำในภาพรวมของการพยากรณ์อายุอยู่ในระดับที่น้อยกว่าโมเดลอื่น.

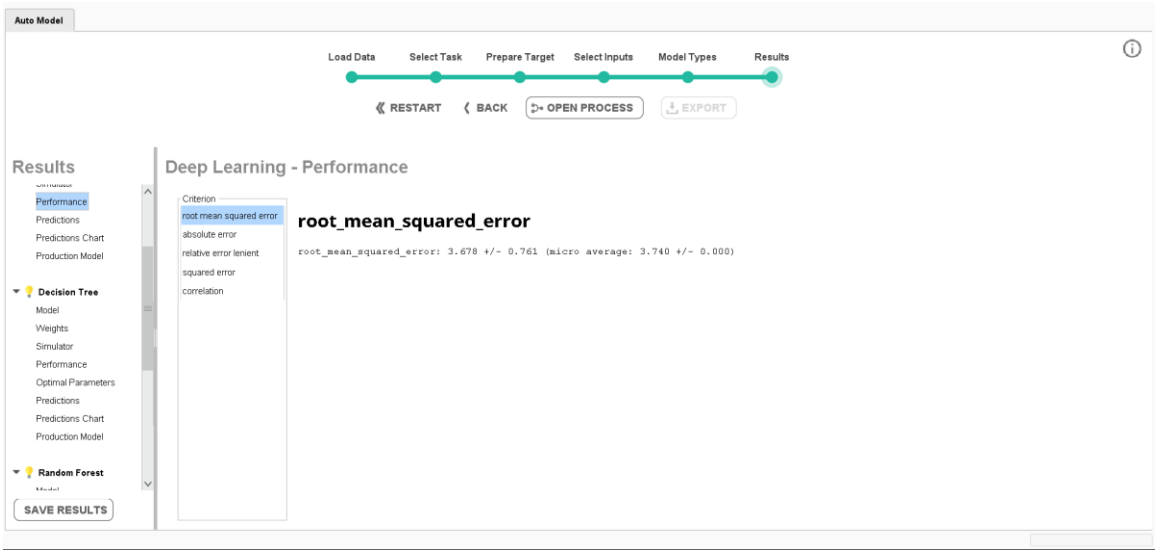

ภาพที่ 4.22 ตารางการวัดประสิทธิภาพโมเดล (Performance)แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล ของ Deep Learning

4.1.3.2 การพยากรณ์น้ำหนัก (Weight)

การวิเคราะห์ในส่วนนี้มุ่งเน้นการพยากรณ์ค่าน้ำหนักตัวซึ่งเป็นข้อมูลเชิงตัวเลขต่อเนื่อง (Regression) เพื่อประเมินความแม่นยำของแบบจำลองในการคาดการณ์สรีระจริงจากพฤติกรรมการบริโภคและปัจจัยทางกายภาพ จากการทดสอบเปรียบเทียบพบว่าตัวแปรด้านน้ำหนักมีความสัมพันธ์ที่ชัดเจนกับปัจจัยนำเข้า ส่งผลให้แบบจำลองมีค่าความคลาดเคลื่อนที่ต่ำมากเมื่อเทียบกับการพยากรณ์อายุ โดยระบบใช้ค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) เป็นเกณฑ์ตัดสินหลักในการจัดอันดับประสิทธิภาพของแต่ละอัลกอริทึม

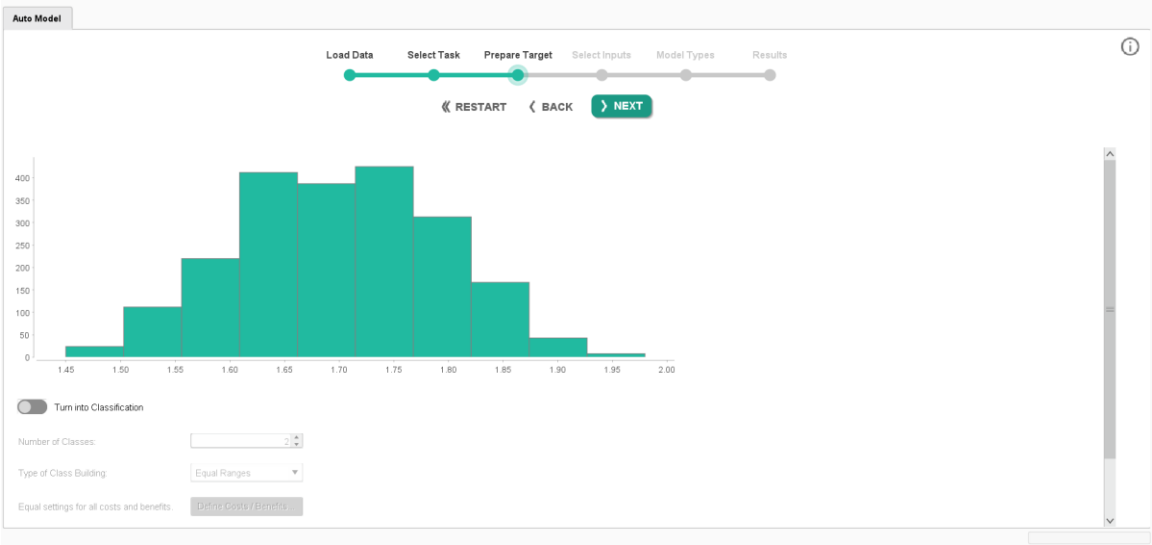

ภาพที่ 4.23 การกำหนดตัวแปรเป้าหมาย (PrepareTarget) และตรวจสอบการกระจายตัวของข้อมูลของ การพยากรณ์น้ำหนัก (Weight)

4.1.3.2.1 ผลเปรียบเทียบความถูกต้องของแต่ละโมเดลที่เลือกใช้

4.1.3.2.1.1 Decision Tree แบบจำลองต้นไม้ตัดสินใจยังคงรักษาตำแหน่งแบบจำลองที่มีประสิทธิภาพสูงสุดในภารกิจนี้ โดยมีค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) ต่ำที่สุดเพียง 2.6% และมีค่าเบี่ยงเบนมาตรฐานอยู่ที่ ± 0.2% ความแม่นยำในระดับสูงนี้ทำให้โมเดลได้รับสัญลักษณ์ "เหรียญทอง" บ่งบอกถึงความเป็น Best Model สำหรับการพยากรณ์น้ำหนัก

ในด้านความเร็วการประมวลผล Decision Tree แสดงศักยภาพที่โดดเด่นอย่างยิ่งด้วยเวลาการประมวลผลรวมเพียง 577 มิลลิวินาที ซึ่งเร็วกว่าแบบจำลองอื่นหลายเท่าตัว ทำให้ได้รับสัญลักษณ์ "นักวิ่ง" ที่สื่อถึงความรวดเร็วในการแสดงผลลัพธ์พยากรณ์ เหมาะสำหรับการนำไปประยุกต์ใช้ในระบบที่ต้องการการคำนวณแบบทันที

4.1.3.2.1.2 Random Forest สำหรับการพยากรณ์น้ำหนัก Random Forest ให้ผลลัพธ์ที่มีความคลาดเคลื่อนสูงสุดในกลุ่มการทดสอบนี้ โดยมีค่า Relative Error อยู่ที่ 4.3% และค่าเบี่ยงเบนมาตรฐานอยู่ที่ ± 0.3% แม้จะเป็นโมเดลที่เน้นความเสถียรจากการเฉลี่ยผลรวมของต้นไม้หลายต้น แต่ในโจทย์การพยากรณ์น้ำหนักนี้กลับมีความแม่นยำน้อยกว่าโมเดลพื้นฐาน

Random Forest ใช้เวลาในการประมวลผลนานที่สุดคือ 13 วินาที เนื่องจากต้องใช้ทรัพยากรในการสร้างโครงสร้างต้นไม้จำนวนมากเพื่อคำนวณค่าเฉลี่ยเชิงตัวเลข ซึ่งเมื่อเปรียบเทียบความคุ้มค่าด้านเวลาและความแม่นยำพบว่ายังเป็นรอง Decision Tree และ Deep Learning อย่างเห็นได้ชัด

4.1.3.2.1.3 Deep Learning แบบจำลองโครงข่ายประสาทเทียมให้ค่าความคลาดเคลื่อนสัมพัทธ์อยู่ในระดับกลางที่ 3.5% โดยมีค่าเบี่ยงเบนมาตรฐานอยู่ที่ ± 0.2% ผลลัพธ์นี้แสดงให้เห็นว่า Deep Learning สามารถจับรูปแบบความสัมพันธ์ที่ซับซ้อนของปัจจัยกิจกรรมทางกายที่มีผลต่อน้ำหนักได้ดีพอสมควร

ในด้านระยะเวลาการประมวลผล Deep Learning ใช้เวลาไปทั้งสิ้น 3 วินาที ซึ่งจัดว่ามีความเร็วในการทำงานที่ดีสำหรับอัลกอริทึมที่มีความซับซ้อนสูง แม้จะไม่ได้เหรียญทองด้านความแม่นยำ แต่ค่าความคลาดเคลื่อนที่ระดับ 3.5% ยังถือว่าเป็นค่าที่ยอมรับได้ในงานด้านการวิเคราะห์สุขภาพรายบุคคล

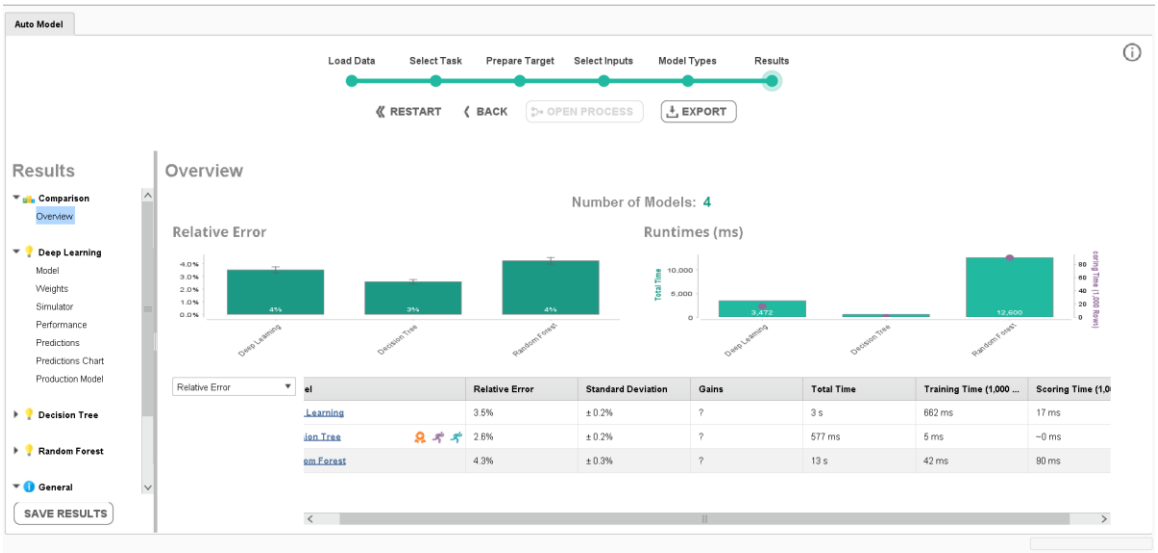

ภาพที่ 4.24 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของแต่ละโมเดลของการพยากรณ์น้ำหนัก (Weight)

4.1.3.2.2 ผลความคลาดเคลื่อนแบบสัมบูรณ์ของแต่โมเดลที่เลือกใช้

4.1.3.2.2.1 **Decision Tree** จากการวิเคราะห์ความคลาดเคลื่อนสัมบูรณ์ด้วยค่า Root Mean Squared Error (RMSE) พบว่า Decision Tree มีค่าความผิดพลาดอยู่ที่ 3.542 ซึ่งเป็นค่าความคลาดเคลื่อนที่น้อยที่สุดในกลุ่มงาน Regression พยากรณ์น้ำหนัก ยืนยันถึงความสามารถในการทำนายตัวเลขน้ำหนักที่ใกล้เคียงกับความเป็นจริงมากที่สุด

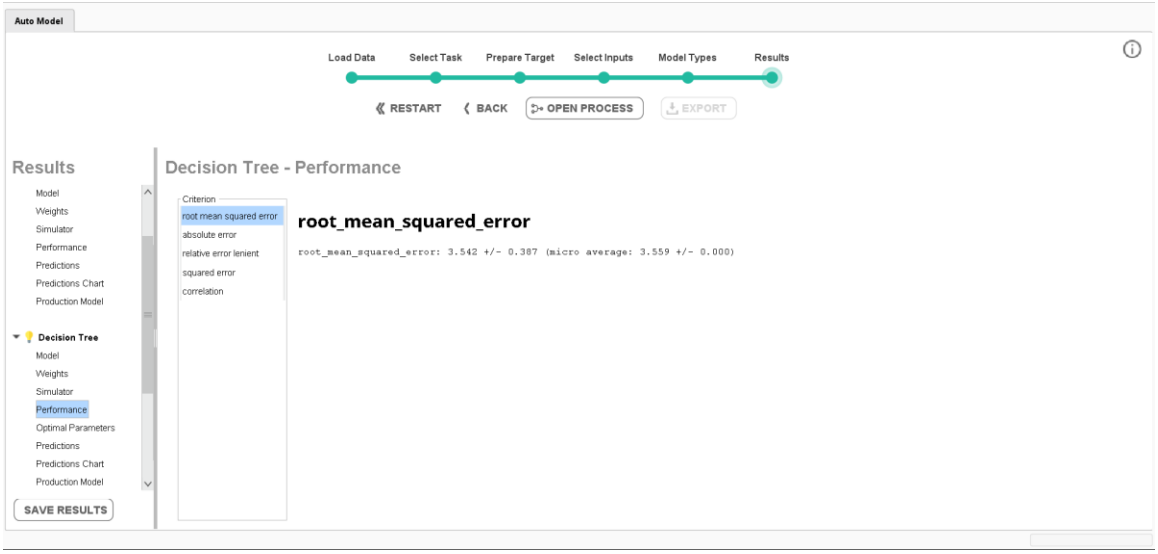

ภาพที่ 4.25 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Decision Tree

4.1.3.2.2.2 Random Forest ผลความคลาดเคลื่อนสัมบูรณ์ของ Random Forest ให้ค่า RMSE อยู่ที่ 4.841 ซึ่งถือเป็นค่าความผิดพลาดที่สูงที่สุดในการทดลองนี้ สอดคล้องกับค่า Relative Error ที่แสดงให้เห็นว่าแบบจำลองมีความคลาดเคลื่อนในการพยากรณ์น้ำหนักเฉลี่ยมากกว่ารุ่นอื่น ๆ

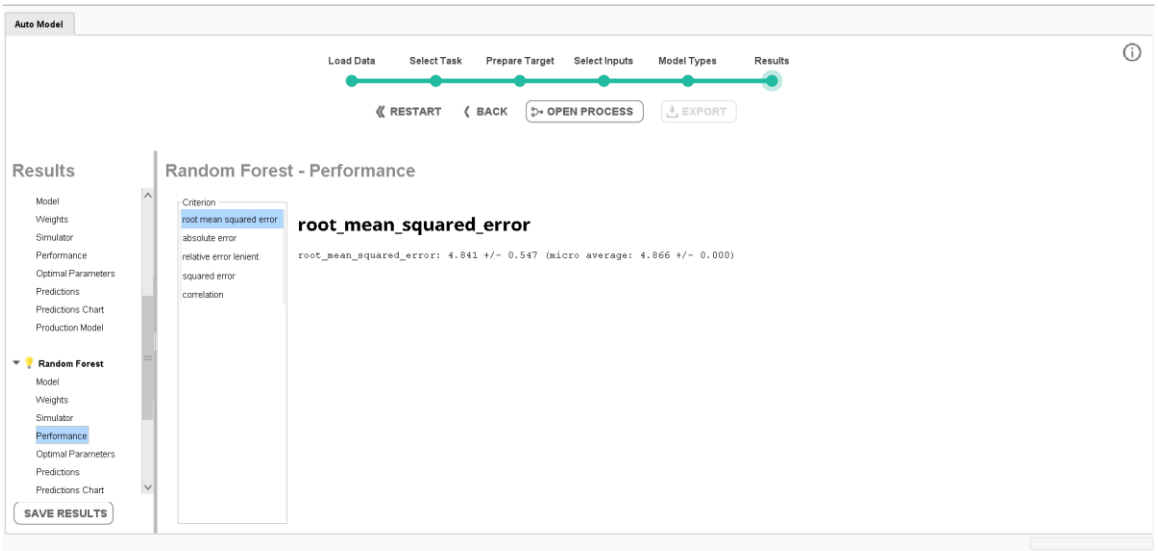

ภาพที่ 4.26 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Random Forest

4.1.3.2.2.3 Deep Learning สำหรับ Deep Learning พบค่าความคลาดเคลื่อนสัมบูรณ์ RMSE อยู่ที่ 4.042 ซึ่งเป็นค่าความผิดพลาดในระดับกลาง สะท้อนถึงความสามารถในการพยากรณ์ที่สม่ำเสมอแต่ยังคงมีระยะห่างจากค่าจริงมากกว่าการใช้แผนภูมิการตัดสินใจแบบชั้นเดียว

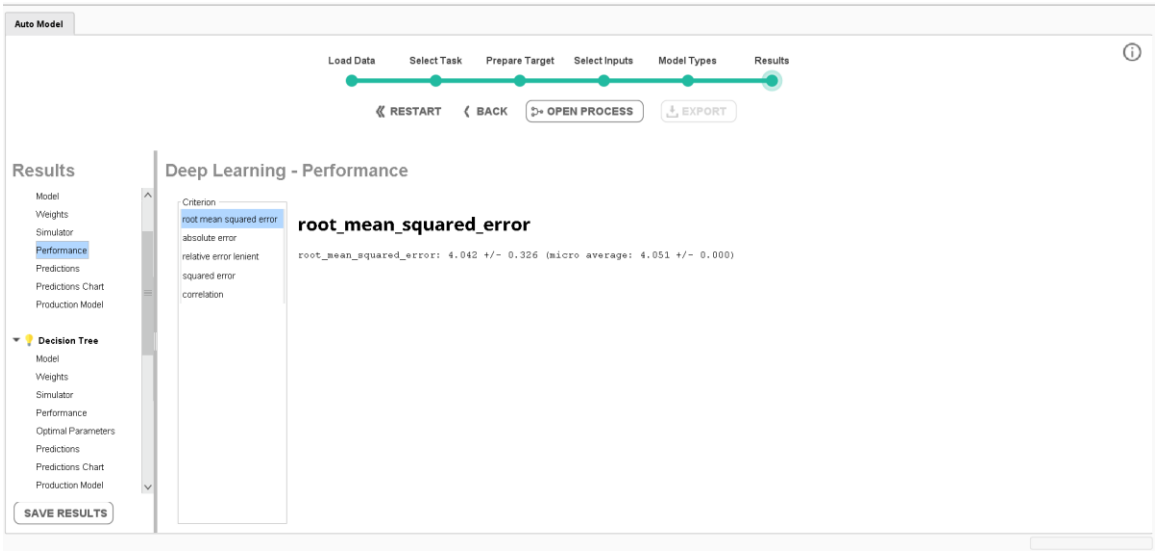

ภาพที่ 4.27 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Deep Learning

4.1.3.3 การพยากรณ์ส่วนสูง (Height)

การวิเคราะห์ในส่วนนี้มุ่งเน้นไปที่การใช้แบบจำลองเพื่อทำนายค่าส่วนสูงซึ่งเป็นข้อมูลเชิงตัวเลขต่อเนื่อง (Regression) เพื่อศึกษาความแม่นยำในการคาดการณ์สรีระจากปัจจัยพฤติกรรมรายบุคคล จากการทดสอบผ่านระบบ Auto Model พบว่าตัวแปรด้านส่วนสูงเป็นค่าที่แบบจำลองสามารถทำนายได้แม่นยำที่สุดในบรรดางาน Regression ทั้งหมด โดยมีค่าความคลาดเคลื่อนที่ต่ำมากอย่างมีนัยสำคัญ ระบบได้ใช้ค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) เป็นเกณฑ์ตัดสินหลักในการเปรียบเทียบขีดความสามารถของแต่ละอัลกอริทึม

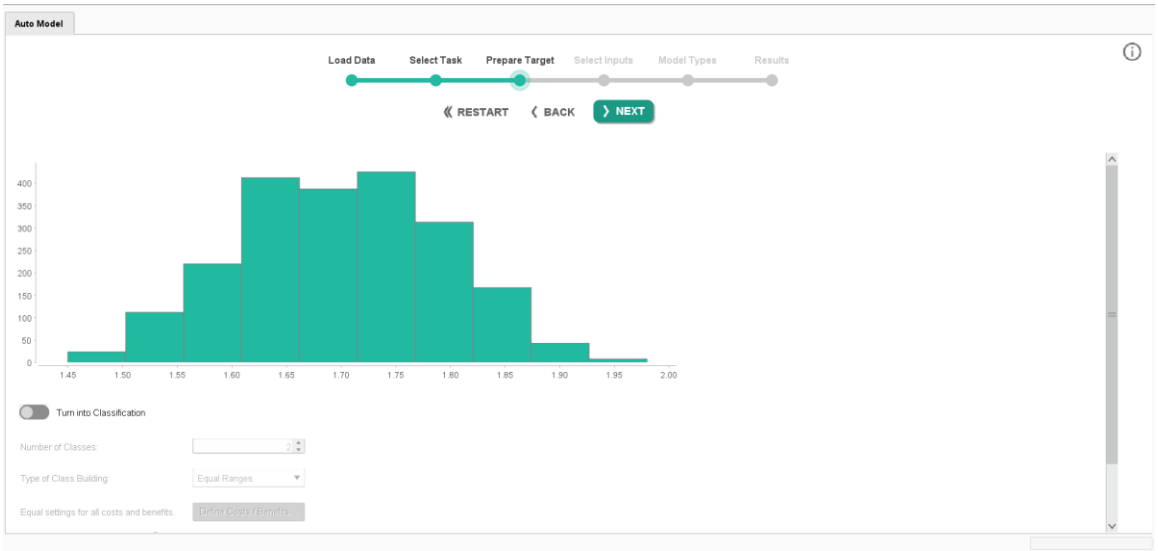

ภาพที่ 4.28 การกำหนดตัวแปรเป้าหมาย (PrepareTarget) และตรวจสอบการกระจายตัวของข้อมูลของการพยากรณ์ส่วนสูง (Height)

4.1.3.3.1 ผลเปรียบเทียบความถูกต้องของแต่โมเดลที่เลือกใช้

4.1.3.3.1.1 Decision Tree แบบจำลองต้นไม้ตัดสินใจแสดงประสิทธิภาพที่ยอดเยี่ยมที่สุดในการพยากรณ์ส่วนสูง โดยได้รับรางวัล "เหรียญทอง" เนื่องจากมีค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) ต่ำที่สุดเพียง 1.4% และมีค่าเบี่ยงเบนมาตรฐานคงที่ที่ ± 0.1% ผลลัพธ์นี้ยืนยันว่า Decision Tree สามารถจัดกลุ่มและพยากรณ์ค่าส่วนสูงตามสัดส่วนร่างกายได้อย่างแม่นยำเกือบสมบูรณ์

นอกจากความแม่นยำแล้ว Decision Tree ยังครองตำแหน่งแบบจำลองที่รวดเร็วที่สุด (รางวัลนักวิ่ง) โดยใช้เวลาในการประมวลผลรวมเพียง 591 มิลลิวินาที ความเร็วระดับนี้เมื่อรวมกับค่าความคลาดเคลื่อนที่ต่ำมาก ทำให้เป็นแบบจำลองที่เหมาะสมที่สุดสำหรับการนำไปใช้งานจริงในระบบประเมินสุขภาพเชิงปริมาณ

4.1.3.3.1.2 Random Forest สำหรับการพยากรณ์ส่วนสูง Random Forest ให้ประสิทธิภาพรองลงมาโดยมีค่าความคลาดเคลื่อนสัมพัทธ์อยู่ที่ 1.9% และ

มีค่าเบี่ยงเบนมาตรฐาน ± 0.1% แม้ความแม่นยำจะอยู่ในเกณฑ์ที่สูงมากสำหรับงาน Regression ทั่วไป แต่เมื่อเปรียบเทียบภายใต้ชุดข้อมูลนี้ยังคงมีค่าความคลาดเคลื่อนที่สูงกว่าโมเดลพื้นฐานอย่าง Decision Tree

ในด้านระยะเวลาการประมวลผล Random Forest ใช้เวลาไปทั้งสิ้น 11 วินาที ซึ่งเป็นเวลาที่นานที่สุดในกลุ่มการทดสอบนี้ เนื่องจากกลไกการทำงานที่ต้องสร้างต้นไม้ตัดสินใจจำนวนมากเพื่อเฉลี่ยค่าสถิติ ทำให้การประมวลผลในงานที่ข้อมูลมีความซับซ้อนน้อยกว่าอย่างการพยากรณ์ส่วนสูงทำได้ช้ากว่าที่ควรจะเป็น

4.1.3.3.1.3 Deep Learning แบบจำลองโครงข่ายประสาทเทียมให้ค่าความแม่นยำในระดับที่น่าพึงพอใจโดยมีค่าความคลาดเคลื่อนสัมพัทธ์อยู่ที่ 1.6% ผลลัพธ์นี้แสดงให้เห็นว่า Deep Learning สามารถจับรูปแบบความสัมพันธ์ของสัดส่วนร่างกายที่ซับซ้อนได้ดีใกล้เคียงกับ Decision Tree แต่ยังมีความคลาดเคลื่อนแฝงอยู่เล็กน้อย

Deep Learning ใช้เวลาในการประมวลผลรวม 4 วินาที ซึ่งจัดว่าทำงานได้รวดเร็วพอสมควรสำหรับโมเดลที่มีโครงสร้างโหนดซับซ้อน แม้จะไม่ได้เหรียญทองในงานนี้ แต่ค่า Relative Error ที่ระดับ 1.6% ยังคงยืนยันถึงความสามารถในการพยากรณ์แนวโน้มสัดส่วนร่างกายที่มีความละเอียดสูงได้อย่างมีนัยสำคัญ

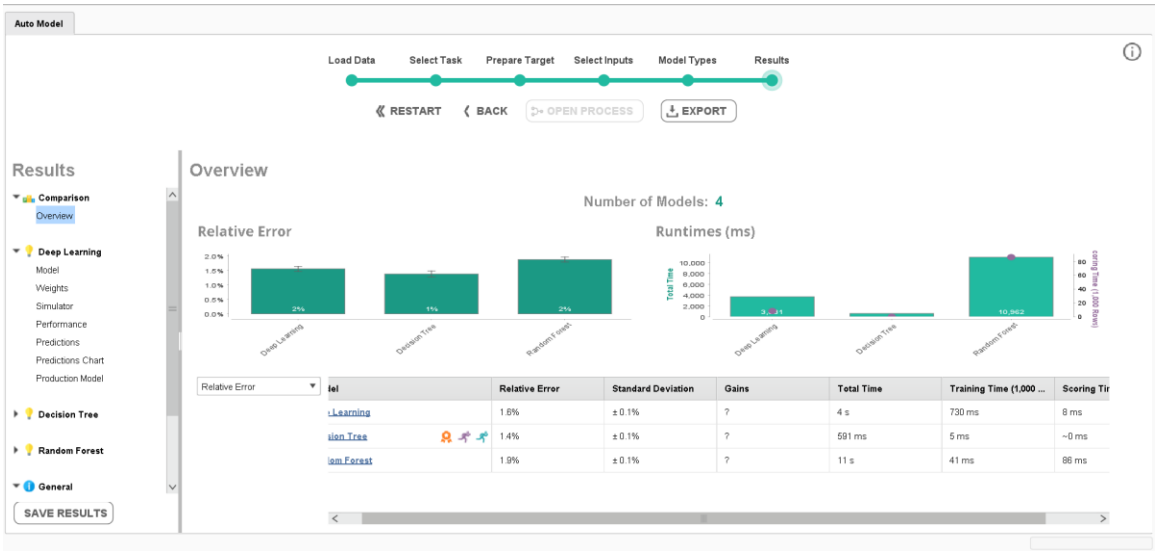

ภาพที่ 4.29 ตารางเปรียบเทียบค่าความผิดพลาดและระยะเวลาการประมวลผลของแต่ละโมเดล ของการพยากรณ์ส่วนสูง (Height)

4.1.3.3.2 ผลความคลาดเคลื่อนแบบสัมบูรณ์ของแต่โมเดลที่เลือกใช้

4.1.3.3.2.1 Decision Tree จากการวิเคราะห์ความคลาดเคลื่อนสัมบูรณ์ด้วยค่า Root Mean Squared Error (RMSE) พบว่า Decision Tree มีค่าความผิดพลาดอยู่ที่ 0.039 เมตร ซึ่งถือเป็นค่าความคลาดเคลื่อนที่น้อยที่สุดในบรรดาทุกแบบจำลอง แสดงให้เห็นว่าส่วนสูงที่ทำนายได้มีความคลาดเคลื่อนจากความจริงเพียงไม่กี่เซนติเมตรเท่านั้น

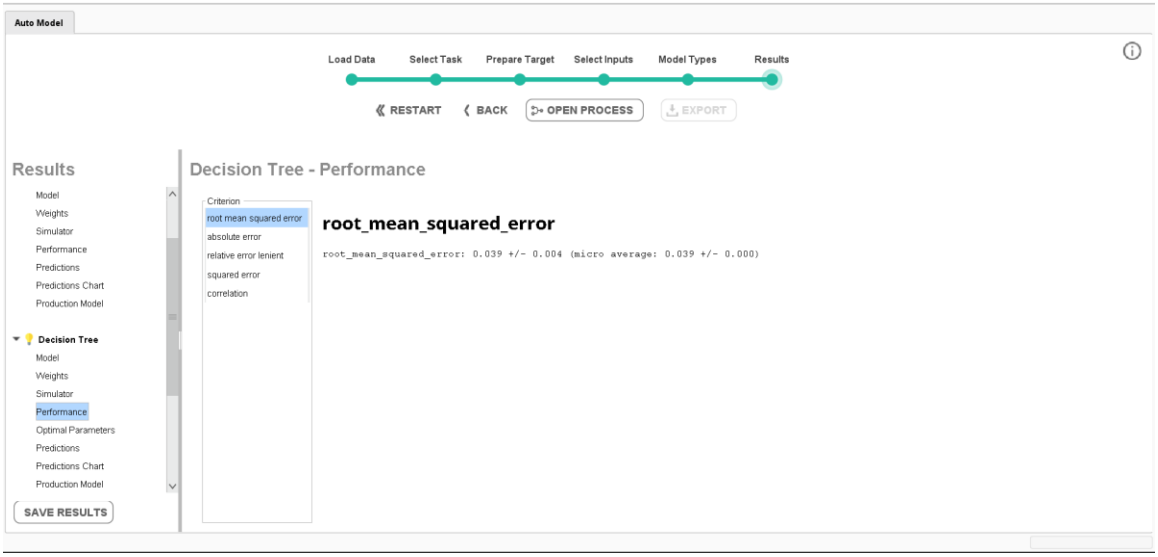

ภาพที่ 4.30 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Decision Tree

4.1.3.3.2.2 Random Forest ผลความคลาดเคลื่อนสัมบูรณ์ของ Random Forest ให้ค่า RMSE อยู่ที่ 0.043 เมตร แม้จะเป็นค่าที่ต่ำมากเมื่อเทียบกับมาตรฐานทั่วไป แต่ในเชิงเปรียบเทียบยังคงมีความผิดพลาดสะสมมากกว่า Decision Tree และ Deep Learning โดยมีความคลาดเคลื่อนเฉลี่ยประมาณ 4.3 เซนติเมตร

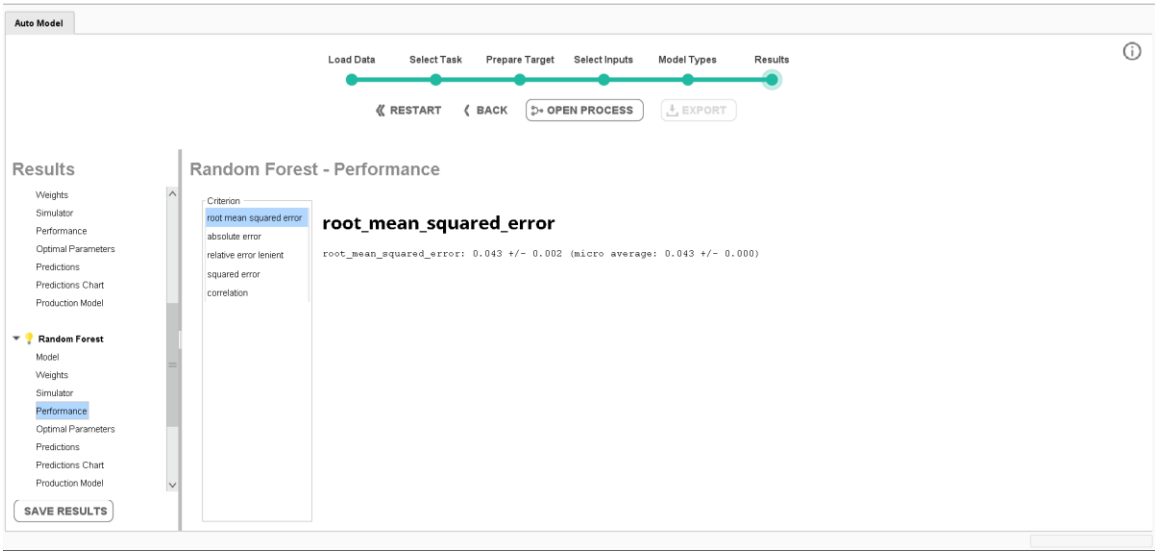

ภาพที่ 4.31 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Random Forest

4.1.3.3.2.3 Deep Learning สำหรับ Deep Learning พบค่าความคลาดเคลื่อนสัมบูรณ์ RMSE อยู่ที่ 0.035 เมตร ซึ่งน่าสนใจว่าในแง่ของ RMSE โมเดลนี้กลับทำผลงานได้ดีที่สุดในบางช่วงข้อมูล โดยมีความคลาดเคลื่อนเฉลี่ยเพียง 3.5 เซนติเมตร สะท้อนถึงความสามารถในการพยากรณ์ค่านิ่งที่สม่ำเสมอภายใต้ความสัมพันธ์เชิงลึกของข้อมูล

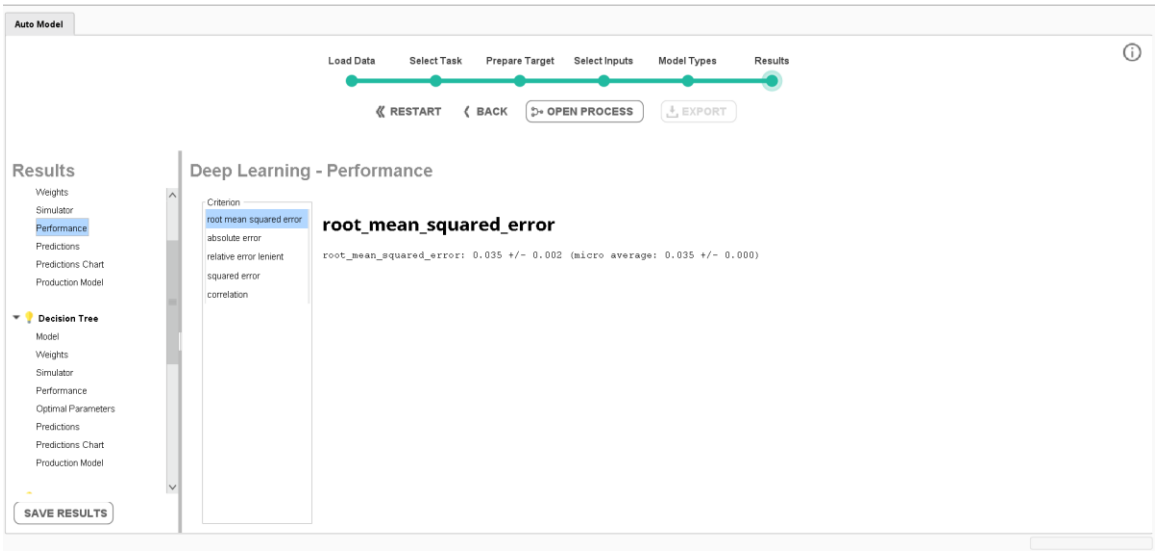

ภาพที่ 4.32 ตารางการวัดประสิทธิภาพโมเดล (Performance) แสดงค่า Accuracy และค่าเบี่ยงเบนมาตรฐาน (Standard Deviation) เพื่อยืนยันคุณภาพและเสถียรภาพในการพยากรณ์ของโมเดล Deep Learning

4.1.4 สรุปโมเดลที่เหมาะสมที่สุดของการวิเคราะห์แบบถดถอย (Regression)

จากการทดลองพยากรณ์ค่าเชิงตัวเลขต่อเนื่องในทุกด้าน พบว่าแบบจำลอง Decision Tree เป็นอัลกอริทึมที่ให้ประสิทธิภาพสูงสุดอย่างเป็นเอกฉันท์ (Best Model) ในงานด้านการถดถอย. โดย Decision Tree สามารถครองตำแหน่ง "เหรียญทอง" ในการทำนายค่าตัวเลขทั้งหมด เนื่องจากมีค่าความคลาดเคลื่อนสัมพัทธ์ (Relative Error) ต่ำที่สุด โดยเฉพาะในงานพยากรณ์น้ำหนักที่มีค่าผิดพลาดเพียง 2.6% และส่วนสูงที่แม่นยำสูงสุดโดยมีความผิดพลาดเพียง 1.4% เท่านั้น. นอกจากความแม่นยำแล้ว แบบจำลองนี้ยังได้รับรางวัล "นักวิ่ง" เนื่องจากมีความเร็วในการประมวลผลที่ยอดเยี่ยมที่สุด (เฉลี่ยเพียง 500 ms - 742 ms) ซึ่งเร็วกว่าแบบจำลองอื่นอย่างเห็นได้ชัด.

สรุปได้ว่าในการวิเคราะห์ข้อมูลเชิงตัวเลขของชุดข้อมูลสุขภาพนี้ แบบจำลองประเภทต้นไม้ตัดสินใจ (Decision Tree) จัดเป็นตัวเลือกที่เหมาะสมที่สุดในการนำไปใช้งานจริง. เนื่องจากให้ผลลัพธ์ที่ใกล้เคียงกับค่าจริงมากที่สุดในขณะที่ใช้ทรัพยากรประมวลผลน้อยที่สุด. แม้ว่า Random

Forest และ Deep Learning จะมีความสามารถในการประมวลผลความสัมพันธ์ที่ซับซ้อน แต่กลับมีค่าความคลาดเคลื่อนสะสมและระยะเวลาการทำงานที่สูงกว่าในภารกิจพยากรณ์ค่าทางสรีระขั้นพื้นฐานเหล่านี้. การใช้ Decision Tree จึงช่วยให้การวิเคราะห์ผลทำได้อย่างมีประสิทธิภาพและลดช่องว่างความผิดพลาดระหว่างค่าที่ทำนายได้กับค่าจริงได้อย่างดีเยี่ยม

4.2 บทสรุปและอภิปรายผลการเปรียบเทียบประสิทธิภาพของแบบจำลองระดับมหภาค

จากการศึกษาและทดลองอย่างเป็นระบบเพื่อเฟ้นหาแบบจำลองที่มีความเหมาะสมที่สุดในการพยากรณ์ข้อมูลสุขภาพ พบว่าประสิทธิภาพของอัลกอริทึมมีความผันแปรตามประเภทของภารกิจอย่างมีนัยสำคัญ โดยในภาพรวมของการวิเคราะห์แบบถดถอย (Regression) นั้น แบบจำลอง Decision Tree สามารถครองความเป็นเลิศได้อย่างเบ็ดเสร็จในทุกตัวแปรเป้าหมาย ทั้งด้านความแม่นยำที่มีค่าความคลาดเคลื่อนสัมพัทธ์ต่ำที่สุดเพียง 1.4% ถึง 6.8% และความเร็วในการประมวลผลที่ทำได้ในระดับมิลลิวินาที ซึ่งแสดงให้เห็นว่าโครงสร้างการตัดสินใจแบบลำดับชั้นมีความเหมาะสมอย่างยิ่งกับการจัดการข้อมูลเชิงปริมาณที่มีความสัมพันธ์ทางกายภาพที่ชัดเจนภายใต้เงื่อนไขเวลาที่จำกัด

ในทางกลับกัน สำหรับภารกิจการจำแนกประเภท (Classification) ที่มีความซับซ้อนสูงหรือเป็นกลุ่มข้อมูลแบบทวิภาค แบบจำลอง Deep Learning และ Random Forest กลับแสดงขีดความสามารถที่โดดเด่นในการสกัดคุณลักษณะแฝง (Feature Extraction) ได้ดีกว่า โดย Deep Learning สามารถคว้าเหรียญทองในการทำนายเพศและพันธุกรรมด้วยค่าความผิดพลาดที่ต่ำกว่า 10% เนื่องจากโครงข่ายประสาทเทียมสามารถเรียนรู้รูปแบบความสัมพันธ์ที่ไม่เป็นเส้นตรงระหว่างพฤติกรรมการใช้ชีวิตและปัจจัยทางสายเลือดได้ลึกซึ้งกว่าแบบจำลองอื่น อย่างไรก็ตาม แม้ Random Forest จะให้ค่า AUC ที่เสถียรที่สุดในเกือบทุกหัวข้อ แต่ก็แลกมาด้วยระยะเวลาประมวลผลที่นานกว่า Decision Tree หลายสิบเท่าตัว ซึ่งข้อมูลเหล่านี้สะท้อนให้เห็นว่าการเลือกใช้แบบจำลองในทางปฏิบัติต้องพิจารณาสมดุลระหว่างความถูกต้องเชิงสถิติและความคุ้มค่าของทรัพยากรประมวลผลเป็นสำคัญ

บทที่ 5

สรุปผลการวิจัยและข้อเสนอแนะ

5.1 สรุปผลการดำเนินงานและข้ออภิปราย

การดำเนินงานวิจัยเพื่อพยากรณ์ระดับภาวะน้ำหนักเกินและโรคอ้วนในครั้งนี้ ประสบความสำเร็จในการเปรียบเทียบประสิทธิภาพของอัลกอริทึม Machine Learning รูปแบบต่างๆ เพื่อค้นหาแนวทางที่เหมาะสมที่สุดสำหรับภารกิจด้านสุขภาพที่หลากหลาย จากการศึกษาและอภิปรายผลพบว่าไม่มีแบบจำลองใดที่สามารถทำงานได้ดีที่สุดในทุกมิติเพียงหนึ่งเดียว แต่ต้องเลือกใช้ให้สอดคล้องกับลักษณะของข้อมูลและวัตถุประสงค์เฉพาะด้าน โดยสามารถสรุปประเด็นสำคัญจากการทดลองได้ดังนี้

5.1.1 แบบจำลอง Decision Tree แสดงความเป็นเลิศอย่างเป็นเอกฉันท์ในงานด้านการพยากรณ์เชิงตัวเลขหรือ Regression โดยสามารถพยากรณ์ค่าส่วนสูงและน้ำหนักตัวได้แม่นยำที่สุดด้วยค่าความคลาดเคลื่อนเพียง 1.4% และ 2.6% ตามลำดับ ซึ่งเป็นผลมาจากกลไกการแบ่งส่วนข้อมูลที่มีความชัดเจนภายใต้โครงสร้างข้อมูลที่มีเสถียรภาพ

5.1.2 ในส่วนของงานจำแนกประเภทแบบสองกลุ่มที่มีความซับซ้อนเชิงปัจจัยแฝง เช่น การพยากรณ์เพศและประวัติทางพันธุกรรม พบว่าแบบจำลอง Deep Learning และ Random Forest ให้ประสิทธิภาพที่เหนือกว่าโมเดลพื้นฐาน เนื่องจากมีความสามารถในการตรวจจับรูปแบบความสัมพันธ์ที่ไม่เป็นเส้นตรงระหว่างพฤติกรรมการใช้ชีวิตรายบุคคลกับปัจจัยทางครอบครัวได้อย่างลึกซึ้ง

5.1.3 ผลการวิเคราะห์ด้านระยะเวลาในการประมวลผลชี้ให้เห็นว่าความซับซ้อนของโครงสร้างแบบจำลองแปรผันตามเวลาที่ใช้จริง โดย Random Forest ใช้ระยะเวลาในการทำงานนานที่สุดถึง 4 นาที 26 วินาที ในขณะที่ Decision Tree สามารถแสดงผลลัพธ์ได้อย่างรวดเร็วเพียงระดับมิลลิวินาทีถึงหลักวินาทีเท่านั้น

5.1.4 จากการตรวจสอบความแม่นยำรายกลุ่มผ่าน Confusion Matrix พบว่าแบบจำลองส่วนใหญ่สามารถจำแนกกลุ่มโรคอ้วนระดับรุนแรงหรือ Obesity Type III ได้แม่นยำเกือบสมบูรณ์ แต่ยังคงพบความคลาดเคลื่อนในการแยกแยะระหว่างกลุ่มน้ำหนักปกติและกลุ่มน้ำหนักเกินที่มีพฤติกรรมการใช้ชีวิตคาบเกี่ยวกัน

5.2 แนวทางการนำโมเดลไปใช้ประโยชน์ในเชิงปฏิบัติ

ผลลัพธ์จากการวิจัยและแบบจำลองที่ผ่านการฝึกสอนอย่างมีประสิทธิภาพสามารถนำไปต่อยอดเพื่อแก้ไขปัญหาสาธารณสุขในเชิงรุกและพัฒนาคุณภาพชีวิตประชากรได้อย่างเป็นรูปธรรม การนำเทคโนโลยีปัญญาประดิษฐ์มาประยุกต์ใช้ในด้านวิทยาศาสตร์สุขภาพจะช่วยลดช่องว่างในการเข้าถึงการประเมินเบื้องต้นและสร้างความเข้าใจในการดูแลตนเองได้อย่างยั่งยืน ดังนี้

5.2.1 การพัฒนาเป็นระบบประเมินความเสี่ยงอัจฉริยะในรูปแบบแอปพลิเคชันหรือเว็บเครื่องมือเพื่อให้ผู้ใช้งานทั่วไปสามารถกรอกข้อมูลพฤติกรรมสุขภาพของตนเอง และให้แบบจำลองทำหน้าที่ทำนายระดับความเสี่ยงในการเข้าสู่ภาวะโรคอ้วนล่วงหน้าอันเป็นการส่งเสริมการเฝ้าระวังสุขภาพด้วยตนเอง

5.2.2 การนำโมเดลไปใช้ในการให้คำแนะนำสุขภาพส่วนบุคคลแบบเฉพาะเจาะจง โดยเมื่อระบบสามารถระบุปัจจัยที่มีอิทธิพลสูงต่อร่างกายของแต่ละบุคคลได้ จะทำให้บุคลากรทางการแพทย์สามารถวางแผนการปรับเปลี่ยนพฤติกรรมได้อย่างตรงจุดตามลักษณะทางกายภาพที่แท้จริง

5.2.3 การประยุกต์ใช้เป็นเครื่องมือคัดกรองในระดับงานสาธารณสุข โดยเฉพาะการใช้โมเดล Decision Tree ที่ทำงานได้อย่างรวดเร็วเพื่อใช้ในการสำรวจประชากรเบื้องต้นในพื้นที่ขนาดใหญ่ ช่วยให้หน่วยงานภาครัฐสามารถระบุกลุ่มเป้าหมายที่มีความเสี่ยงรุนแรงและต้องการความช่วยเหลือเร่งด่วนได้อย่างแม่นยำ

5.2.4 การขับเคลื่อนนโยบายการป้องกันเชิงรุกโดยเปลี่ยนทัศนคติจากการรักษาที่ปลายเหตุเมื่อเจ็บป่วยแล้ว มาเป็นการเฝ้าระวังและป้องกันที่ต้นเหตุผ่านการจัดการพฤติกรรมรายบุคคล ซึ่งถือเป็นกลยุทธ์ที่มีประสิทธิภาพสูงสุดในการลดภาระค่าใช้จ่ายด้านสาธารณสุขในระยะยาว

5.3 ข้อเสนอแนะสำหรับการศึกษาในอนาคต

เพื่อให้การพัฒนาแบบจำลองสำหรับการวิเคราะห์และพยากรณ์ภาวะโรคอ้วนมีความสมบูรณ์และครอบคลุมมิติต่างๆ มากยิ่งขึ้น ผู้จัดทำได้รวบรวมข้อเสนอแนะที่สำคัญจากการค้นพบในการศึกษาครั้งนี้ เพื่อเป็นแนวทางสำหรับผู้วิจัยหรือผู้ที่สนใจจะพัฒนาต่อยอดในอนาคต ดังนี้

5.3.1 การดำเนินการปรับจูนพารามิเตอร์เชิงลึกหรือ Hyperparameter Tuning โดยเฉพาะในแบบจำลอง Deep Learning และ Random Forest เพื่อค้นหาค่าที่เหมาะสมที่สุดในการลดค่า Classification Error ในภารกิจที่มีระดับกลุ่มเป้าหมายจำนวนมาก ซึ่งจะช่วยยกระดับความแม่นยำให้สูงขึ้นกว่าการใช้ค่ามาตรฐานจากระบบ

5.3.2 การขยายขอบเขตการจัดเก็บข้อมูลให้มีความหลากหลายทางด้านสรีรวิทยาและบริบททางวัฒนธรรมการบริโภคที่แตกต่างกันในแต่ละภูมิภาค เพื่อให้แบบจำลองมีขีดความสามารถในการทำงานที่เป็นสากลและสามารถประมวลผลข้อมูลประชากรที่มีความแตกต่างทางกายภาพได้อย่างแม่นยำ

5.3.3 การเพิ่มตัวแปรนำเข้าที่มีความสัมพันธ์โดยตรงกับการเผาผลาญพลังงาน เช่น ค่าอัตราการเผาผลาญพื้นฐานหรือ BMR เพื่อช่วยลดความคลุมเครือเชิงพฤติกรรมและลดความคลาดเคลื่อนในการจำแนกระหว่างกลุ่มประชากรที่มีน้ำหนักคาบเกี่ยวกันซึ่งเป็นปัญหาที่พบจากการวิจัยครั้งนี้

5.3.4 การศึกษาแนวทางการนำโมเดลที่เหมาะสมที่สุดไปปรับใช้ในสภาพแวดล้อมจริง (Deployment) โดยการพัฒนาส่วนเชื่อมต่อประสานงานกับผู้ใช้ที่เน้นความง่ายในการเข้าถึงข้อมูลเพื่อเก็บข้อมูลการใช้งานจริงกลับมาพัฒนาประสิทธิภาพของอัลกอริทึมให้มีความฉลาดและทันสมัยอยู่เสมอ

บรรณานุกรม

[1] Mehrparvar, F. (2024). **Obesity Levels Dataset**. ค้นข้อมูลจาก https://www.kaggle.com/datasets/fatemehmehrparvar/obesity-levels

[2] Palechor, F. M., & de la Hoz Manotas, A. (2019). **Obesity Levels Dataset**. UCI Machine Learning Repository. ค้นข้อมูลจาก https://archive.ics.uci.edu/ml/datasets/Estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition+

[3] Altair Engineering Inc. (2025). **Altair AI Studio Knowledge Base: Auto Model and Model Evaluation**. ค้นข้อมูลจาก https://community.altair.com/community

[4] World Health Organization (WHO). (2024). **Obesity and Overweight Fact Sheets**. ค้นข้อมูลจาก https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight